



И.М. ШАРОВИН,
Н.И. СМЕРНОВ,
(МЭИ)
А.И. РЕПИН,
(ООО “Энергоавтоматика”)

Применение искусственных нейронных сетей для адаптации САР в процессе их эксплуатации

Рассматривается метод адаптации настроечных параметров регулятора в одноконтурной САР при изменении динамических свойств объекта регулирования. В основу процесса адаптации положены современные технологии искусственного интеллекта, включающие эволюционные алгоритмы оптимизации и искусственные нейронные сети (ИНС). Разработанный алгоритм аппроксимации функциональных зависимостей параметров регулятора от параметров объекта регулирования с использованием ИНС предлагается использовать для адаптации САР в процессе их эксплуатации.

Ключевые слова: искусственная нейронная сеть, адаптивная САР, сигмоидальная функция, ПИД регулятор.

Введение

Для оптимального синтеза САР необходимо располагать исходной информацией о динамических характеристиках объекта регулирования. Наличие такой априорной информации позволяет синтезировать систему автоматического регулирования с заданными критериями качества и показателями запаса устойчивости.

В процессе эксплуатации САР исходной информации о свойствах объекта может оказаться недостаточно из-за неизбежного их изменения, что может привести к заметному снижению качественных показателей, а в ряде случаев и к потере устойчивости. Оптимизированная в процессе проектирования САР в реальных условиях может оказаться не работоспособной. В связи с этим, заключительный этап оптимального синтеза САР приходится переносить на стадию ввода системы в работу на реальном объекте, а в дальнейшем процессе эксплуатации необходимо иметь возможность корректировать настроечные параметры при изменениях динамических характеристик объекта. Выполняемые при этом действия принято называть *адаптацией*. Часто математическую модель динамики объекта на стадии проектного синтеза САР вообще не удается получить. В этом случае адаптация, осуществляемая в действующей САР, является единственным путем решения задачи ее оптимального синтеза [1–3].

Как правило, большинство адаптивных систем регулирования реализуют адаптацию с активной идентификацией объекта. В работе [4] предложен метод настройки систем регулирования с помощью поисковых

методов глобальной оптимизации. Несмотря на свою эффективность, такой подход имеет ряд недостатков, самыми существенными из которых являются относительно большое время расчета и стохастический характер работы алгоритма оптимизации.

Первый недостаток не является сколько-нибудь существенным, что ограничивало бы внедрение глобальных методов оптимизации на практике. Это обусловлено тем, что скорость изменения характеристик объекта регулирования, как правило, значительно меньше скорости адаптации. Второй недостаток, связанный со стохастическим характером работы алгоритма оптимизации, является более существенным. Как показала практика, при повторных вычислениях одной и той же задачи, результат оказывается “разбросанным” в пределах заданной точности решения. Кроме того, при моделировании замкнутой системы регулирования с помощью численных методов поверхность отклика целевой функции становится более неровной по сравнению с аналитическими методами. В этом случае повышается вероятность того, что результат может оказаться в локальном экстремуме. С учетом отмеченного, в реальных адаптивных системах, реализованных с помощью программно-технических средств, желательно иметь детерминированную функциональную зависимость между настроечными параметрами регулятора и параметрами объекта регулирования.

В качестве такой функциональной зависимости предлагается использовать специально обученную искусственную нейронную сеть, на вход которой подаются параметры объекта, определенные на этапе

идентификации, а на выходе получаются настроечные параметры регулятора, обеспечивающие требуемое качество регулирования при соблюдении заданного запаса устойчивости.

В статье затрагиваются вопросы архитектуры таких нейронных сетей, приемы формирования обучающих выборок для их настройки, а также вопросы, связанные с их практической реализацией.

Постановка задачи

Как уже отмечалось выше, априорная динамика объекта регулирования, принятая на стадии проектного синтеза САР, может заметно отличаться от реальной. Поэтому при вводе системы регулирования в эксплуатацию наладчик старается загрузить настроечные параметры регулятора с целью получения более глубокого запаса устойчивости, пренебрегая при этом с одной стороны потерями качества, а с другой стороны, возможностями математического аппарата теории автоматического управления. В простейшем случае настройки регулятора выставляются зачастую интуитивно, с постепенным увеличением пропорциональной составляющей регулятора и уменьшением постоянной времени интегрирования до того момента, пока по субъективным представлениям наладчика переходный процесс регулирования станет удовлетворительным. При этом дифференциальная составляющая регулятора практически исключается.

В сложившейся ситуации адаптивные САР призваны устранить подобный подход к настройке регуляторов, обеспечивая оптимальность в широком диапазоне изменения параметров объекта регулирования. Ниже рассматривается адаптивная система автоматического регулирования, структурная схема которой представлена на рисунке 1.

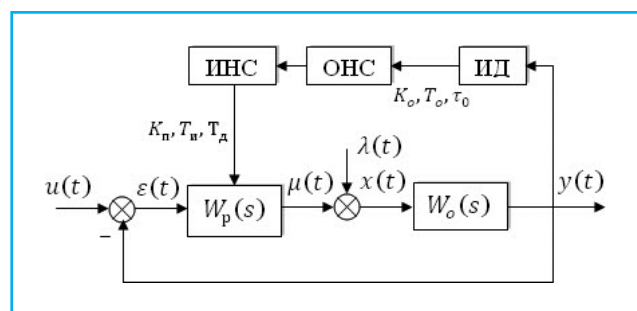


Рис. 1. Структурная схема адаптивной САР

Структурная схема предлагаемой системы включает в себя следующие блоки: ИД – блок идентификации объекта, ОНС – блок обучения нейронной сети, ИНС – искусственная нейронная сеть, реализующая функциональную зависимость, связывающую настроечные параметры регулятора с параметрами идентифицированной модели объекта.

На этапе первоначального ввода системы регулирования в эксплуатацию производится выбор структуры

модели объекта и осуществляется идентификация ее параметров. По окончании идентификации найденные коэффициенты принимаются в качестве базовых при формировании обучающей выборки для нейронной сети. Блок-схема алгоритма формирования обучающей выборки и обучения ИНС приведена на рисунке 2.

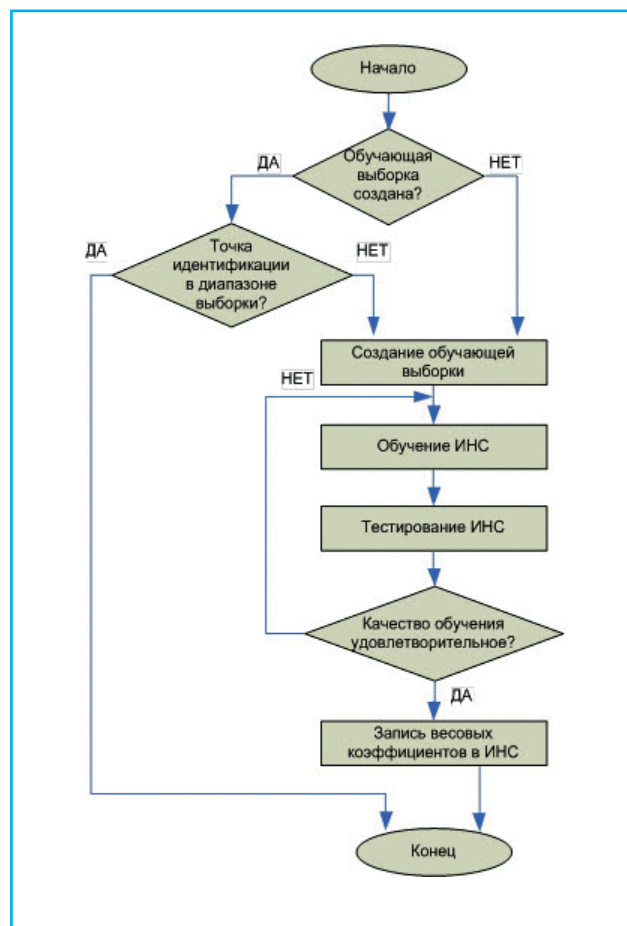


Рис. 2. Блок-схема алгоритма обучения и настройки ИНС

По окончании настройки обученная нейронная сеть включается в работу и определяет настроечные параметры регулятора в соответствии с параметрами модели объекта, полученными на этапе идентификации. Таким образом, поставленная задача формулируется в виде оптимального синтеза адаптивной системы регулирования, в которой ИНС воспроизводит с максимальной достоверностью параметры настройки регулятора в заданном диапазоне варьирования параметров объекта.

Идентификация модели объекта регулирования

Блок идентификации первоначально запускается при включении системы регулирования в работу. В дальнейшем, блок идентификации включается периодически с заданным интервалом времени и, в случае необходимости, осуществляется коррекция настроечных параметров регулятора. В соответствии с принципом системного подхода к синтезу САР, процедура идентификации проводится не над отдельно взятым объектом,

а над системой в целом. На вход системы подается специально организованное внешнее идентифицирующее воздействие в виде изменения задания регулятору и осуществляется параметрическая оптимизация принятой структуры математической модели объекта по характеристикам поведения замкнутой САР. Ниже приводится последовательность основных операций идентификации.

1. Устанавливаются предварительные настроечные параметры на регуляторе и его модели, заведомо гарантирующие углубленный запас устойчивости, после чего регулятор включается в работу.

2. Убедившись в прогнозируемом характере процесса регулирования, на вход регулятора подается внешнее ступенчатое идентифицирующее воздействие по заданию, необходимое для формирования выборки регулируемого параметра.

3. Производится запись в базу данных величины возмущения, выборки регулируемого параметра и фиксированных интервалов времени.

4. Реализуется процедура параметрической идентификации для принятой структуры модели объекта в соответствии с полученной выборкой.

С позиции системного подхода принятая математическая модель объекта будет считаться удовлетворительной, если при подаче на вход системы с действительным объектом и системы с моделью объекта одного и того же воздействия разность их выходных величин окажется достаточно малой. Критерий идентификации формируется в виде интеграла квадратов разности выходов реальной АСР и ее модели. После того, как параметры для принятой структуры математической модели объекта будут определены, осуществляется процедура параметрической оптимизации выбранного регулятора.

Процедура определения параметров идентифицируемой модели и настроечных параметров регулятора в процессе адаптации базируется на численных методах с использованием эволюционного алгоритма "Optim-MGA" [5].

Как показали исследования, проведенные авторами, в большинстве случаев наиболее приемлемой оказывается аппроксимирующая модель в виде двух последовательно соединенных А-звеньев и звена транспортного запаздывания для объектов с самовыравниванием или в виде последовательно соединенных И-звена, А-звена и звена транспортного запаздывания для объектов без самовыравнивания [6]. Такая относительно загруженная аппроксимация позволяет снизить чувствительность САР по сравнению с настройками, полученными по моделям более высокого порядка.

Формирование обучающей выборки

Параметры объекта регулирования, определенные в результате идентификации, поступают в блок обучения нейронной сети (ОНС), где на этапе инициализации производится расчет параметров настройки регулятора. Дальнейший анализ проводится применительно

к реальному ПИД регулятору, передаточная функция которого имеет вид [7]:

$$W_p(s) = k_p + \frac{k_p}{T_i \cdot s} + \frac{k_p \cdot T_d \cdot s}{\left(\frac{T_d}{K_\Phi} \cdot s + 1\right)^2}, \quad (1)$$

где: k_p – коэффициент пропорциональной части регулятора; T_i – постоянная времени интегрирования; T_d – постоянная времени дифференцирования; K_Φ – коэффициент, определяющий постоянную времени фильтра, как долю от T_d .

В качестве критерия оптимальности в алгоритме параметрической оптимизации регулятора выбран интеграл по модулю отклонения регулируемой величины в переходном процессе при ступенчатом возмущении по каналу регулирующего органа $\lambda(t)$ [8]:

$$I_{\lambda, \lambda} = \int_0^{\tau_{\text{пр}}} \lambda(t) \cdot |y_M(t)| dt \rightarrow \min \quad (2)$$

где: $y_M(t)$ – регулируемый параметр на выходе модели; $\tau_{\text{пр}}$ – длительность переходного процесса.

Для окончательного формирования целевой функции интеграл (2) дополняется ограничением в виде функции штрафа на допустимую величину частотного показателя колебательности $M \leq M_{\text{доп}}$:

$$F = \begin{cases} I_{\lambda, \lambda} \left\{ 1 + \left| M_{\text{доп}} - A_{\text{зс}}(\omega_p) \right| \right\}, & \text{если } A_{\text{зс}}(\omega_p) > M_{\text{доп}}, \\ I_{\lambda, \lambda}, & \text{если } A_{\text{зс}}(\omega_p) \leq M_{\text{доп}}, \end{cases} \quad (3)$$

где: $A_{\text{зс}}(\omega_p)$ – максимальное значение амплитудно-частотной характеристики (АЧХ) для замкнутого контура регулируемой величины $y(t)$ на резонансной частоте ω_p ; $M_{\text{доп}}$ – заданное значение показателя колебательности, определяющее допустимый запас устойчивости.

Промежуточным результатом расчетов в блоке ОНС является создание базовой точки (центр эксперимента) в области параметров объекта регулирования со значениями параметров настройки регулятора (табл.1).

Таблица 1

Параметры объекта регулирования			Параметры настройки ПИД-регулятора		
k_0	T_0	τ_0	k_p	T_i	T_d

Для создания обучающей выборки, необходимой для обучения ИНС, используются методы планирования эксперимента [9]. Планирование производится на двух уровнях, обеспечивающих ортогональность матрицы планирования и ротабельность уравнения регрессии. Размеры интервалов варьирования Δx_i приняты не жесткими. В зависимости от параметров объекта представляется возможным расширять или сужать их с помощью специально введенного коэффициента k :

$$\Delta x_i = x_{i0} \cdot k, \quad (4)$$

где: x_{i0} – базовая точка; k – коэффициент интервала варьирования; Δx_i – интервал варьирования.

$$x_{iH} = x_{i0} - \Delta x_i; \quad (5)$$

$$x_{iB} = x_{i0} + \Delta x_i, \quad (6)$$

где x_{iH} и x_{iB} – нижние и верхние уровни факторов.

Путем последовательного перебора всех возможных сочетаний уровней варьирования составляется полная матрица планирования, представляющая собой набор входных (параметры объекта регулирования) и выходных (параметры настроек ПИД регулятора) значений для обучения ИНС.

Искусственные нейронные сети и их обучение

Нейронные сети, как правило, используются для аппроксимации зависимостей, в которых неизвестен точный аналитический вид связей между входами и выходами [10, 11]. Поставленная задача решается в процессе обучения нейронной сети, которое состоит из следующих этапов:

- обучение ИНС;
- проверка расчетных данных в диапазоне обучения ИНС;
- проверка расчетных данных вне диапазона обучения ИНС.

Высоким качеством обучения ИНС считают приобретенную ей способность моделировать функцию, связывающую значения входных и выходных переменных за пределами обучающей выборки. Сеть с подобными особенностями можно впоследствии использовать для прогнозирования в ситуации, когда выходные значения неизвестны.

Процедура обучения ИНС состоит в идентификации ее весовых коэффициентов, иначе называемых *синаптическими весами*. Особенностью ИНС является ее способность к модификации параметров и структуры в процессе обучения. Элементарным функциональным звеном, из множества которых состоит ИНС, является нейрон. В прикладных задачах управления находят применение модели непрерывных нейронов.

Математической формализацией искусственного нейрона являются уравнение сумматора

$$s_k = \sum_{j=1}^n w_{j,k} \cdot x_j + b_k, \quad (7)$$

и уравнение активационного блока

$$\gamma_k = f(s_k), \quad (8)$$

где для k -го нейрона: x_1, x_2, \dots, x_n – входные сигналы; $w_{1,k}, w_{2,k}, \dots, w_{n,k}$ – синаптические веса; b_k – уровень

опорного сигнала; s_k – сигнал на выходе линейного сумматора; $f(s_k)$ – функция преобразования активационного блока; γ_k – выходной сигнал.

Непрерывная модель нейрона работает следующим образом. Входные сигналы, каждый со своим коэффициентом, поступают на вход линейного сумматора. Выходной сигнал сумматора поступает на вход активационного нелинейного блока.

Характер преобразования сигнала нейронной сетью зависит от числа скрытых промежуточных слоев и числа нейронов в них. Из-за нелинейных свойств активационных блоков в сети создаются условия, в которых один или несколько нейронов могут отключаться, обеспечивая изменения в топологии ИНС. Это существенно расширяет спектр преобразующих свойств сети.

Формально не существует ограничений на типы активационных функций. Они могут быть как одинаковыми для всех слоев и нейронов, так и различными. Как показали проведенные исследования, для поставленной задачи наилучшее качество обеспечивают сигмоидальные функции (9), (рис. 3), ограничивающие выходной сигнал нейрона в диапазоне $[0, 1]$:

$$f(s) = \frac{1}{1 + e^{-s}}. \quad (9)$$

Число нейронов промежуточного слоя рекомендуется брать равным полусумме числа входных и выходных нейронов сети [10].




Рис. 3. Сигмоидальная функция активационного блока

В ходе обучения нейросети изменяются значения синаптических коэффициентов $w_{i,j}$ для каждого нейрона с целью минимизации среднеквадратичной ошибки сети между выходным и эталонными векторами.

Задача обучения ИНС является многоэкстремальной, поэтому все классические методы оптимизации, основанные на градиенте целевой функции, не могут гарантировать нахождение наилучшего решения. Поэтому для повышения качества аппроксимации рекомендуется использовать эволюционные алгоритмы глобальной оптимизации. Самыми известными из них являются генетические алгоритмы (ГА). В приведенном ниже примере для обучения нейросети использовалась авторская версия эволюционного алгоритма оптимизации "Optim-MGA" [12].

Имея в наличии все достаточные предпосылки для использования ИНС (связь между входными и выходными значениями, пренебрежительно малые помехи в обучающей выборке, достаточность выборки для обучения), был произведен выбор структуры ИНС. Для ПИД регулятора (1), удовлетворяющей по качеству воспроизведения обучающей выборки, опытным путем была выбрана полностью связанная, прямонаправленная трехслойная нейронная сеть со структурой типа NN3-4-3 с сигмоидальной активационной функцией нейронов (рис. 4).




Рис. 4. Модель искусственной нейронной сети

Использование скрытых слоев позволяет ИНС осуществлять нелинейные преобразования вход-выход любой сложности или извлекать из выходных данных статистические показатели высоких порядков. Однако усложнение структуры ИНС значительно увеличивает машинное время расчета весовых коэффициентов, при этом качественного уменьшения ошибки прогноза на обучающем множестве не происходит.

Критерием настройки ИНС был выбран минимум среднемодульного отклонения анализируемой величины:

$$S_x = \frac{1}{n} \sum_{i=1}^n \frac{|x_i^{MGA} - x_i^{ИНС}|}{x_i^{MGA}} \cdot 100\% . \quad (10)$$

где: n – это количество точек обучающей выборки; x_i^{MGA} , $x_i^{ИНС}$ – параметры настройки регулятора, полученные с помощью программы “Optim-MGA” и искусственной нейронной сети, соответственно.

Пример реализации адаптивной САР с использованием ИНС

Представленная адаптивная САР в структуре программно-технического комплекса (ПТК) реализована с использованием пакета взаимодействующих между собой прикладных программ. Идентификация объекта регулирования, с использованием передаточной функции (11), осуществляется на инженерной станции путем обработки трендов переходных процессов в авто-рской программе “TunePID” [13].

$$W_o(s) = k_0 \frac{\exp(-\tau_0 \cdot s)}{(T_0 + 1)^2}, \quad (11)$$

Таблица 2

k_0	T_0	τ_0
1	10	2

Результаты идентификации представляются в виде параметров объекта регулирования k_0, T_0, τ_0 , которые принимаются

за базовую точку (табл. 2).

Параметры базовой точки используются для формирования обучающей выборки на основе полного факторного эксперимента. Для каждой точки обучающей выборки, рассчитываются параметры настройки реального ПИД регулятора с передаточной функцией (1).

Обучение ИНС, с минимизацией среднемодульного отклонения искомым параметров, представляет собой поиск синаптических коэффициентов нейросети в программе “Optim-MGA”. Обучающая выборка и результаты обучения настроенной сети для объекта регулирования (11) приведены в таблице 3.

Из таблицы 3 видно, что настроечные параметры регулятора, найденные с помощью программы “Optim-MGA” и ИНС, практически идентичны. Более показательным, в данном случае, будет представление результатов обучения нейронной сети в виде таблицы 4 с указанием среднемодульного отклонения параметров объекта обучения ИНС (10).

При получении удовлетворительного результата обучения нейросети ее коэффициенты по

Таблица 3

№ точки	Параметры объекта регулирования			Параметры настройки ПИД-регулятора, полученные с помощью					
				MGA			ИНС		
	k_0	T_0	τ_0	k_p	$T_{и}$	T_d	k_p	$T_{и}$	T_d
1	0.9	9	1.8	6.092	9.467	3.414	5.921	8.87	3.414
2	1.1	9	1.8	4.876	8.626	3.563	4.804	8.657	3.55
3	0.9	11	1.8	6.987	9.445	4.261	7.115	10.325	4.028
4	1.1	11	1.8	5.619	8.987	4.35	5.74	10.115	4.223
5	0.9	9	2.2	5.102	10.36	3.434	4.873	10.03	3.5
6	1.1	9	2.2	4.085	9.202	3.757	3.983	9.789	3.669
7	0.9	11	2.2	6.098	11.82	3.973	5.945	11.522	4.19
8	1.1	11	2.2	4.942	11.16	4.272	4.8	11.312	4.359
9	0.75	7.5	1.5	7.265	7.709	2.786	7.626	7.23	2.751
10	1.25	7.5	1.5	4.336	7.519	2.836	4.593	6.888	2.708
11	0.75	12.5	1.5	11.46	10.62	4.11	11.43	10.48	4.112
12	1.25	12.5	1.5	6.868	10.53	4.208	6.777	10.027	4.436
...
23	0.5	15	3	10.87	15.14	5.704	10.902	14.674	5.428
24	1.5	15	3	3.641	15.53	5.579	4.036	14.386	5.364

Таблица 4

Параметры регулятора	k_p	T_u	T_d
Критерий настройки S_x	4.817	4.44	3.089

ОРС-протоколу записываются в ПТК. В качестве примера на рисунке 5 приведена реализация функционального блока “INS_PID”, реализующего нейросетевую часть адаптивной САР в программной среде “Control Builder F” системы “Freelance 800F” компании “ABB”.

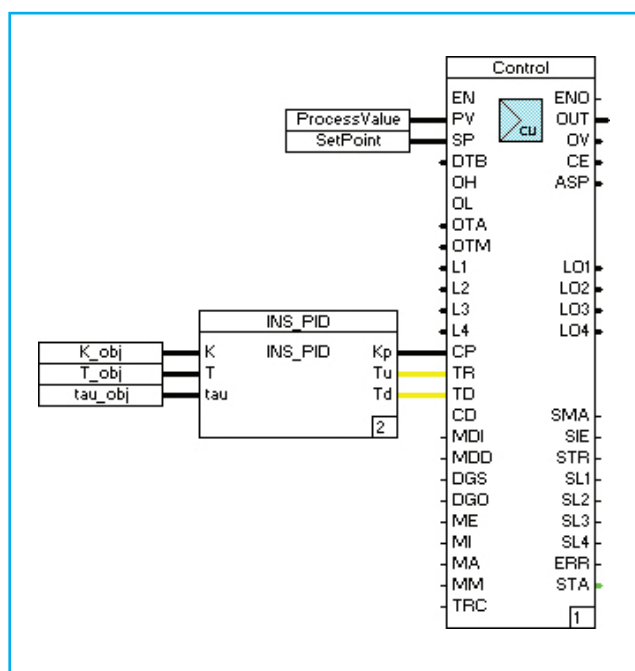


Рис. 5. Адаптивная система (АББ)

Необходимо заметить, что высоким качеством обучения ИНС стоит считать не приобретенную ею способность точно воспроизводить параметры настройки регулятора в указанном диапазоне параметров объектов регулирования, а возможность синтеза оптимальных параметров в большем диапазоне варьирования параметров объекта регулирования.

Заключение

Проведенные исследования позволяют сделать вывод о том, что настраивать ИНС предпочтительнее на широкий диапазон варьирования параметров объекта регулирования для обеспечения постоянства заданного запаса устойчивости системы, а также минимизации выбранного критерия качества переходного процесса. В заключение следует отметить, что применение обучаемой нейронной сети позволяет сравнительно точно, просто и практически мгновенно реализовывать адаптивные настроечные параметры, обеспечивающие заданные критерии качества и показатели запаса устойчивости САР в процессе ее функционирования.

Список литературы

1. Чураков Е.П. Оптимальные и адаптивные системы // Учебное пособие для вузов. М.: Энергоатомиздат, 1987.
2. Аналитические самонастраивающиеся системы автоматического управления. // Под ред. В.В. Солодовникова, Москва, Машиностроение, 1965 г.
3. Ротач В.Я. Теория автоматического управления // учебник для вузов. М.: Издательский дом МЭИ, 2008.
4. Репин А.И., Смирнов Н.И., Сабанин В.Р. Идентификация и адаптация САР с использованием эволюционных алгоритмов оптимизации. // Промышленные АСУ и контроллеры. № 3, 2008. ООО Издательство НАУЧТЕХИЗДАТ.
5. Сабанин В.Р., Смирнов Н.И., Репин А.И. Модифицированный генетический алгоритм для задач оптимизации и управления. // Exponenta Pro. Математика в приложениях. 2004, № 3 – 4.
6. Смирнов Н.И., Сабанин В.Р., Репин А.И. О корректности настройки ПИД регулятора при аппроксимации переходной характеристики объекта регулирования апериодическим звеном с транспортным запаздыванием. // Промышленные АСУ и контроллеры. № 1, 2007. ООО Издательство НАУЧТЕХИЗДАТ. Смирнов Н.И., Репин А.И., Сабанин В.Р. Чувствительность и робастная настройка ПИД регуляторов с реальным дифференцированием. // Теплоэнергетика. № 10, 2007. М.: ООО МАИК “НАУКА/ИНТЕРПЕРИОДИКА”.
7. Смирнов Н.И., Репин А.И., Сабанин В.Р. Чувствительность и робастная настройка ПИД регуляторов с реальным дифференцированием. // Теплоэнергетика. № 10, 2007. М.: ООО МАИК “НАУКА/ИНТЕРПЕРИОДИКА”.
8. Смирнов Н.И., Шаровин И.М. О выборе критерия оптимальности в численных методах расчета САР с ПИД регулятором // Промышленные АСУ и контроллеры. 2010, № 2.
9. Мойсюк Б.Н. Основы теории планирования эксперимента. М.: Издательство МЭИ, 2005.
10. Репин А.И., Сабанин В.Р., Смирнов Н.И., Андреев С.Н. Диагностика информационных подсистем АСУТП с использованием технологий искусственного интеллекта. // Теплоэнергетика. № 6, 2006. М.: ООО МАИК “НАУКА/ИНТЕРПЕРИОДИКА”.
11. Haykin S. Neural Networks. A comprehensive foundation. – New York, NY: Macmillan, 1994.
12. <http://www.systemautomation.ru/programmnye-produkty/optim-mga>.
13. Репин А.И., Смирнов Н.И., Сабанин В.Р., Максимов А.Н., Игнатенко А.Н. Математическое и программное обеспечение алгоритмов идентификации и адаптации АСР и их реализация в современных ПТК. // Сборник трудов конференции Control 2008. М.: Издательство МЭИ, 2008.

Игорь Михайлович Шаровин – аспирант,
e-mail: sharovin@gmail.com.

Николай Иванович Смирнов – канд. техн. наук,
Московский энергетический институт.

Репин Андрей Иванович – канд. техн. наук,
старший научный сотрудник ООО “Энергоавтоматика”.