

ФГБОУ ВПО
Национальный Исследовательский Университет
«МЭИ»

На правах рукописи

Шаровин Игорь Михайлович

**РАЗРАБОТКА МАТЕМАТИЧЕСКОГО И ПРОГРАММНОГО
ОБЕСПЕЧЕНИЯ НЕЙРОСЕТЕВЫХ АЛГОРИТМОВ
АДАПТИВНЫХ АСР**

05.13.06 Автоматизация и управление технологическими процессами и
производствами (по отраслям: энергетика)

Диссертация
на соискание ученой степени
кандидата технических наук

Научный руководитель
к.т.н., доц. Смирнов Н.И.

МОСКВА - 2013

ОГЛАВЛЕНИЕ

СПИСОК СОКРАЩЕНИЙ.....	6
ВВЕДЕНИЕ.....	7
ГЛАВА 1 ОБЗОР МЕТОДОВ АВТОМАТИЗИРОВАННОГО И АДАПТИВНОГО УПРАВЛЕНИЯ В ПРОМЫШЛЕННЫХ АСУ ТП	16
1.1 Классификация методов идентификации объектов регулирования ..	16
1.2 Методы адаптивной настройки, реализуемые в отечественных и зарубежных контроллерах	19
1.2.1 Методы адаптивной настройки, разработанные на кафедре АСУ ТП НИУ «МЭИ».....	19
1.2.2 Реализация адаптивной настройки регуляторов в ПТК ведущих производителей.....	20
1.3 Программные средства настройки АСР.....	24
1.4 Нечеткая логика.....	25
1.4.1 Принципы построения нечеткого регулятора	27
1.4.2 Принципы автоподстройки реализуемого регулятора	31
1.5 Искусственные нейронные сети	32
1.5.1 Подражающее нейроуправление.....	33
1.5.2 Инверсное нейроуправление	34
1.5.3 Гибридное нейроуправление.....	36
1.6 Генетические алгоритмы	40
1.7 Выводы	43
ГЛАВА 2 ОПТИМАЛЬНАЯ НАСТРОЙКА РЕГУЛЯТОРОВ	45
2.1 Структуры исследуемых регуляторов, показатели качества работы АСР	45
2.1.1 Структуры исследуемых регуляторов.....	45
2.1.2 Выбор показателя запаса устойчивости.....	48
2.1.3 Интегральные критерии качества оптимальной настройки регуляторов	49
2.2 Численные методы расчета настроечных параметров регуляторов .	52

2.2.1	Расчет оптимальных параметров ПИ регулятора	52
2.2.2	Расчет оптимальных параметров ПИД регулятора.....	58
2.3	Выводы	66
ГЛАВА 3 СИНТЕЗ НЕЙРОСЕТЕВЫХ КОМПОНЕНТ СИСТЕМЫ АДАПТИВНОГО УПРАВЛЕНИЯ		67
3.1	Особенности синтезируемой адаптивной АСР на базе нейросетевых компонент идентификации и адаптации	69
3.1.1	Структура предлагаемой адаптивной АСР	69
3.1.2	Процедуры идентификации и адаптации в составе адаптивной АСР	71
3.1.3	Поэтапный синтез предлагаемой адаптивной АСР	74
3.2	Синтез нейросети параметрической идентификации объекта регулирования	76
3.2.1	Формирование тренировочного множества для обучения нейросети	77
3.2.2	Определение достаточного количества обучающих данных для воспроизведения параметров объекта регулирования	79
3.2.3	Выбор архитектуры и обучение нейросети	85
3.3	Синтез адаптивной нейросети для аппроксимации функционала настроенных параметров регуляторов.....	88
3.3.1	Создание тренировочного множества с применением полного факторного эксперимента для обучения нейросети	89
3.3.2	Выбор класса и структуры нейросети, обучение ИНС.....	91
3.4	Выводы	95
ГЛАВА 4 ОБУЧЕНИЕ ИСКУССТВЕННЫХ НЕЙРОННЫХ СЕТЕЙ ИДЕНТИФИКАЦИИ И АДАПТАЦИИ.....		97
4.1	Обучение нейросети параметрической идентификации объекта регулирования	97
4.1.1	Проведение активного эксперимента для создания тренировочного множества для обучения нейросети	97

4.1.2	Обучение нейросети параметрической идентификации	101
4.2	Обучение нейросетей адаптивной настройки реализуемых регуляторов.....	102
4.2.1	Обучение нейросетей тренировочными множествами, состоящими из одного полного факторного эксперимента.....	102
4.2.2	Обучение нейросетей тренировочными множествами, состоящими из нескольких полных факторных экспериментов.....	103
4.2.3	Влияние количества нейронов в скрытом слое нейросети на результаты воспроизведения тренировочных множеств	106
4.2.4	Реализация нейросети воспроизведения настроечных параметров идеального ПИД регулятора с возможностью изменения частотного показателя колебательности.....	109
4.2.5	Реализация адаптивной нейросети в составе двухконтурной каскадной АСР.....	113
4.3	Рекомендации поэтапного синтеза нейросетей идентификации и адаптации применительно к задачам синтеза адаптивных АСР теплоэнергетических объектов.....	120
4.4	Синтез адаптивной АСР на базе нейросетевых компонент в эмуляторе программируемого логического контроллера	121
4.5	Выводы	125
ГЛАВА 5 ПРАКТИЧЕСКАЯ РЕАЛИЗАЦИЯ АДАПТИВНОЙ АСР.....		127
5.1	Обучение нейросети параметрической идентификации объекта регулирования	127
5.1.1	Подготовительный этап реализации искусственных нейросетей.....	127
5.1.2	Синтез и обучение нейросети идентификации	129
5.1.3	Синтез и обучение нейросети адаптации.....	131
5.2	Реализация адаптивной АСР на базе нейросетевых компонент в ПЛК	132
5.3	Проверка качества настроенной адаптивной АСР.....	135

5.4 Выводы	137
ОСНОВНЫЕ ВЫВОДЫ ПО РАБОТЕ	140
СПИСОК ЛИТЕРАТУРЫ.....	141
ПРИЛОЖЕНИЯ.....	151
Приложение А. Обучение тренировочными множествами, полученными на минимум интегрального критерия по модулю, искусственных нейросетей на воспроизведение настроечных параметров исследуемых регуляторов	152
Приложение Б. Обучение тренировочными множествами, полученными на минимум интегрального критерия по модулю, искусственной нейросети на воспроизведение настроечных параметров регуляторов каскадной адаптивной системы регулирования	176
Приложение В. Реализация имитационной модели одноконтурной АСР и поиск оптимальных настроечных параметров реального ПИД регулятора.....	178
Приложение Г. Реализация нейросети параметрической идентификации объекта регулирования с самовыравниванием.....	185
Приложение Д. Реализация адаптивной нейросети для аппроксимации функциональной зависимости «параметры объекта регулирования, частотный показатель колебательности» - «пропорциональная составляющая регулятора»	191
Приложение Е. Реализация ИНС идентификации и адаптации в ПЛК ПТК АСУ ТП на примере адаптивной АСР температуры электропечи....	197
Е1. Функциональный блок реализации ИНС параметрической идентификации	197
Е2. Функциональный блок адаптивной ИНС, воспроизводящей оптимальные параметры ПИ регулятора с возможностью изменения частотного показателя колебательности.....	204

СПИСОК СОКРАЩЕНИЙ

АНР – адаптивная настройка регуляторов

АСР – автоматическая система регулирования

АСУ ТП – автоматизированная система управления технологическим процессом

АЧХ – амплитудно-частотная характеристика

БОН – блок обучения нейросети

ИМ – исполнительный механизм

ИНС – искусственная нейронная сеть

МЭО – механизм электрический однооборотный

МЭК – международная электротехническая комиссия

ПИ – пропорционально–интегрально составляющие регулятора

ПИД – пропорционально–интегрально–дифференциальные составляющие регулятора

ПК – персональный компьютер

ПЛК – программируемый логический контроллер

ПО – программное обеспечение

ПТК – программно–технический комплекс

ПФБ – пользовательский функциональный блок

ПФЭ – полный факторный эксперимент

РО – регулирующий орган

ТО – технологический объект

ТП – технологический процесс

FBD – Function block Diagram (язык функциональных блоков для программирования ПЛК согласно МЭК 61131-3)

NN – neural network (нейронная сеть)

Optim-MGA (MGA) – эволюционный алгоритм многопараметрической многоэкстремальной оптимизации

ST – Structured Text (язык структурированного текста для программирования ПЛК согласно МЭК 61131-3)

ВВЕДЕНИЕ

Современный уровень развития автоматизации характеризуется неуклонной интенсификацией технологических процессов (ТП), увеличением мощности единичных агрегатов, повышением требований к качеству процессов управления, увеличением доли нестационарных и нелинейных объектов управления. Типичным становится случай, когда отсутствует точное математическое описание технологического объекта или со временем происходит изменение его параметров неизвестным образом в широких пределах.

Автоматические системы регулирования (АСР), реализуемые в автоматизированных системах управления технологическими процессами (АСУ ТП) с фиксированными настроечными параметрами, уже не могут обеспечить во многих случаях качественного, а иногда и просто устойчивого управления. В подобных условиях большими возможностями обладает адаптивный подход к построению АСР. Адаптивные системы являются бурно развивающейся областью современной теории управления, что отражает объективную тенденцию современной автоматизации к решению все более сложных и универсальных задач управления теплоэнергетическими процессами.

Процесс создания оптимальной АСР принято разделять на несколько этапов:

- получение сведений о динамических характеристиках объекта регулирования;
- выбор структуры АСР;
- оценочный расчет настроечных параметров регуляторов в выбранной структуре АСР;
- установка полученных настроечных параметров непосредственно в регулятор;
- оценка качества регулирования на действующем объекте и сравнение его с теоретически ожидаемым.

Если качество регулирования оказывается неудовлетворительным, то приходится делать выбор между повторным прохождением всех этапов, начиная с поиска оптимальных настроечных параметров реализуемых в системе регуляторов или же прибегать к усложнению структурной схемы существующей АСР.

Для оптимальной настройки АСР необходимо располагать сведениями о динамических характеристиках системы и характеристиках действующих в системе возмущений. Многие возмущения являются неизмеряемыми, характеризовать которые можно лишь на основе анализа процессов изменения выходной величины действующей системы. Следует отметить, что немало важной особенностью теплоэнергетических объектов является изменение внутренних свойств объектов и, как следствие, динамических характеристик с течением времени.

Параметры настройки систем регулирования, полученные в результате предварительного расчета, с помощью математических моделей, часто нуждаются в коррекции непосредственно на действующих системах регулирования. Это вызвано как организационными, так и принципиальными ограничениями, накладываемыми на возможность получения достоверной математической модели объекта, а также некоторыми особенностями работы оборудования на стадии ввода АСР в действие, таким образом условия эксплуатации теплоэнергетического оборудования накладывает специфические требования к методике проведения адаптивной настройки АСР:

- процесс настройки не должен сопровождаться значительными нарушениями нормального режима работы технологического оборудования и должен допускать частичную или полную автоматизацию;
- процесс адаптации должен быть минимизирован по времени без существенной потери качества полученных результатов настройки;
- методика должна быть универсальной для настройки АСР с различными структурами и с различными динамическими характеристиками объектов;

- методика также должна обладать достаточной защищенностью от помех и ошибок эксперимента.

Выполнение вышеобозначенных требований в полной мере обеспечивает реализацию адаптивных методов настройки АСР с применением технологий искусственных нейронных сетей (ИНС), при этом совсем не обязательно чтобы система была предварительно настроена любым из известных методов (Ziegler-Nichols, Cohen-Coon, CHR (Chien, Hrones и Reswick), по эмпирическим формулам и т.д.).

В настоящее время производительность микропроцессорной техники позволяет внедрять алгоритмы адаптивных АСР в программируемые логические контроллеры (ПЛК), входящие в состав программно-технического комплекса (ПТК) АСУ ТП. Несмотря на это, большинство из существующих методов настройки регуляторов требуют непосредственного участия инженера-наладчика, причем обязательным условием является наличие персонального компьютера, в котором производится расчет настроечных параметров регуляторов и оценка качества регулирования.

Для внедрения методов автоматизированной настройки в промышленную эксплуатацию АСУ ТП требуется решить ряд вопросов как методического, так и практического характера с учетом современных тенденций разработки технологий искусственного интеллекта. Первоначально необходимо оценить возможность применения нейросетевых технологий и их эффективность в алгоритмах адаптивной настройки регуляторов для традиционно применяемых систем регулирования, используемых в АСУ ТП теплоэнергетических объектов с учетом их динамических характеристик.

Цель диссертационной работы

Исследование возможности применения искусственных нейронных сетей для задач параметрической идентификации теплоэнергетических объектов регулирования и адаптивной коррекции настроечных параметров реализуемых регуляторов.

Для достижения цели решается ряд задач:

- 1) Разработка общей структуры адаптивной АСР на базе искусственных нейронных сетей;
- 2) Исследование критериев оптимальной настройки регуляторов с построением линий заданного запаса устойчивости ($M=const$) в плоскости настроечных параметров регуляторов и нанесением поверхностей отклика критериев оптимальности для доказательства корректности полученных расчетных значений;
- 3) Синтез тренировочных множеств с применением полного факторного эксперимента (ПФЭ) и специально введенным коэффициентом интервала варьирования для обучения нейросетей идентификации и адаптации;
- 4) Исследование возможности обучения адаптивных нейросетей несколькими видами обучающих выборок, минимизирующих рассматриваемые в работе критерии качества;
- 5) Синтез адаптивных нейросетей, воспроизводящих функциональную зависимость между параметрами объекта регулирования и настроечными параметрами регулятора с возможностью изменения частотного показателя колебательности;
- 6) Проведение опытных испытаний с реализацией адаптивной АСР на базе ИНС в ПЛК для демонстрации состоятельности методики синтеза предлагаемой структуры адаптивной АСР и возможность её реализации на производстве.

Методы исследований

Для решения поставленных задач применялись численные методы имитационного моделирования с использованием эволюционного алгоритма многопараметрической многоэкстремальной оптимизации, методы математического

моделирования, методы планирования эксперимента, также применялись современные технологии искусственного интеллекта.

Научная новизна

Предложена методика обучения искусственных нейросетей с помощью тренировочных множеств, состоящих из одного или нескольких полных факторных экспериментов. Синтезированы нейросети, реализующие параметрическую идентификацию объекта регулирования по его переходной характеристике, также синтезированы нейросети для решения задач параметрической адаптации настроечных параметров в АСР для ряда стандартных регуляторов как в одноконтурной, так и в многоконтурной АСР с возможностью варьирования частотного показателя колебательности.

Основные положения и результаты, выносимые на защиту

- методика обучения нейросетей для задач параметрической идентификации и адаптации;
- реализация нейросетей параметрической идентификации объекта с самовывравниванием и нейросетей адаптации настроечных параметров рассматриваемых регуляторов;
- реализация получивших на практике наибольшее распространение АСР для теплоэнергетических процессов на базе адаптивных систем с использованием нейросетевых компонент;
- реализация адаптивной АСР в ПЛК ПТК АСУ ТП для регулирования температуры электропечи.

Практическая значимость

Для сокращения времени пуско-наладочных работ необходимо не только располагать исходными данными об исследуемом объекте регулирования, но и автоматизировать процесс оптимальной настройки АСР должным образом.

Обеспечить систему требуемым запасом устойчивости, добиться высокого качества регулирования. Предложенные автором алгоритмы работы для адаптивной АСР на базе искусственных нейронных сетей позволяют:

- производить оптимальную настройку регулятора уже после первого эксперимента, проведенного непосредственно на объекте регулирования;
- вычислять оптимальные настроечные параметры для реализованных регуляторов для изменившихся условий эксплуатации;
- на базе разработанных методик нейросетевых компонентов предложена реализация каскадной адаптивной АСР.

Апробация работы и публикации

Результаты научных исследований по теме диссертационной работы докладывались и обсуждались на заседании кафедры АСУ ТП НИУ «МЭИ», двадцать четвертой международной научной конференции «Математические методы в технике и технологиях» (г. Киев, 2011 г.), третьей научно-практической конференции «Совершенствование качества и безопасности отечественных продуктов питания, как важный аспект в развитии АПК в период кризиса» (г. Можайск, 2010 г.), пятнадцатой, шестнадцатой, семнадцатой, восемнадцатой (дважды) и девятнадцатой международной научно-технической конференции студентов и аспирантов «Радиоэлектроника, электротехника и энергетика» (г. Москва, 2009, 2010, 2011, 2012, 2013 гг.).

Основные положения диссертации отражены в 13 публикациях, в том числе 4 публикации в научных журналах, две из которых опубликованы в рецензируемом ВАК РФ журнале «Промышленные АСУ и контроллеры».

Структура и основное содержание диссертации

Работа состоит из введения, пяти основных глав, заключения. Исследование включает в себя 64 рисунка, 23 таблицы, 12 формул и 6 приложений. Объем работы составляет 206 страниц, список литературы содержит 111 наименований.

Во введении обоснована актуальность темы диссертационной работы, сформулированы цели и задачи исследования, показаны его научная новизна и практическая значимость, дано краткое изложение работы.

В первой главе проведен аналитический обзор различных подходов к задачам автоматизированного и адаптивного управления, представлено краткое описание наиболее распространенных на практике систем адаптивного управления. Выделены достоинства и недостатки, присущие каждой из рассматриваемых методик. Обозначен качественный рост производительности микропроцессорных контролеров, который позволяет применять все более эффективные алгоритмы адаптивного управления непосредственно в ПЛК. Отмечено, что решение задачи адаптивного управления с применением ИНС как для идентификации объекта регулирования, так и для адаптивной настройки регуляторов является перспективным направлением для исследований.

Во второй главе приводится расширенное описание структур реализуемых регуляторов, для которых создаются искусственные нейронные сети. Рассматриваются вопросы выбора целей и критериев качества регулирования. Демонстрируются, как частный случай, расчеты оптимальной настройки пропорционально-интегрального (ПИ) и идеального и реального пропорционально-интегрально-дифференциального (ПИД) регуляторов на рассматриваемые критерии качества регулирования, приводятся графические результаты проведенного исследования (поверхности отклика анализируемых критериев качества с нанесением линий заданного запаса устойчивости, переходные процессы и амплитудно-частотные характеристики). Произведен синтез присоединяемых программ для расчета оптимальных настроечных параметров рассматриваемых регуляторов.

В третьей главе рассматривается структура предлагаемой адаптивной АСР, приводится алгоритм введения системы в работу и процедура определения параметров идентифицируемой модели и настроечных параметров регулятора в процессе адаптации на базе численных методов с использованием эволюционного алгоритма “Optim-MGA”. Продемонстрирована методика проведе-

ния полного факторного эксперимента по созданию обучающих выборок для тренировки нейросетей идентификации и адаптации с использованием коэффициента интервала варьирования, также продемонстрирован способ синтеза нейросетей для параметрической идентификации объекта регулирования с самовыравниванием.

Продemonстрирован возможный способ синтеза нейросетей с различными архитектурами для аппроксимации функционала настроечных параметров как ПИ, так и ПИД регуляторов с заданным частотным показателем колебательности или возможностью его изменения в заданном диапазоне. Предлагается использовать созданную автором библиотеку присоединяемых программ для быстрого поиска оптимальных настроечных параметров реализуемых регуляторов.

В четвертой главе приводятся результаты исследовательской работы по обучению нейросетей идентификации и адаптации. Рассматривается пример реализации нейросети параметрической идентификации объекта регулирования. Проводится сравнительный анализ обучения различных видов ИНС тренировочными множествами, состоящими как из одного так и из серии полных факторных экспериментов с различными коэффициентами интервалов варьирования. В этом же ключе рассматривается качество воспроизведения нейронными сетями оптимальных (для каждого из рассматриваемых интегральных критериев оптимальности) настроечных параметров регуляторов. Рассматривается возможность реализации каскадной адаптивной АСР на базе нейросетевых технологий. Приводятся программные реализации адаптивной АСР в эмуляторе ПЛК.

В пятой главе описывается синтез адаптивной АСР на базе нейросетевых компонент для АСР температуры электрической печи в ПЛК ПТК АСУ ТП. Приводится описание процедур, необходимых для соблюдения алгоритма работы компонентов идентификации и адаптации. Приведены основные результаты опытного эксперимента, представлена реализация рассматриваемой адаптивной АСР в ПЛК.

В приложениях приведены основные результаты обучения различных видов нейросетей, представлены графики сравнения переходных процессов, полученных в замкнутом контуре АСР с регуляторами, настроенными с помощью алгоритма оптимизации, а также регуляторами, настроенными с помощью предварительно обученных нейросетей. Также приводятся программы имитационного моделирования систем автоматического регулирования для оптимальной настройки реализуемых регуляторов, представлены программы для обучения рассматриваемых в работе ИНС в программном пакете MathCAD. Также приводится программный код нейросетей параметрической идентификации и адаптации, реализованный в ПЛК в виде функциональных блоков адаптивной АСР по регулированию температуры электропечи для апробации результатов проделанной работы.

Диссертационная работа выполнена на кафедре Автоматизированных Систем Управления Тепловыми Процессами Национального Исследовательского Университета «МЭИ». Автор благодарен своему руководителю к.т.н., доц. Н.И. Смирнову за ценные рекомендации и постоянное внимание к выполняемой работе, к.т.н., с.н.с. ООО «Энергоавтоматика» А.И. Репину за сотрудничество и своевременные замечания на различных этапах проводимых исследований, к.т.н., доц. В.Ф. Кузищину за ценные советы и замечания, сделанные при рецензировании диссертационной работы.

ГЛАВА 1

ОБЗОР МЕТОДОВ АВТОМАТИЗИРОВАННОГО И АДАПТИВНОГО УПРАВЛЕНИЯ В ПРОМЫШЛЕННЫХ АСУТП

Естественным развитием класса ПИ и ПИД алгоритмов регулирования является класс адаптивных ПИ и ПИД регуляторов, который стал распространяться на предприятиях при появлении контроллеров с вычислительной мощностью, достаточной для реализации объемных задач. Значение автоматической адаптации параметров регуляторов определяется тем, что в реальности не существует такого технологического объекта (ТО), параметры которого оставались бы постоянными за длительное время его функционирования. Принятое при настройке регуляторов допущение о постоянстве параметров ТО базируется на том, что обычно изменение параметров объекта происходит хоть и по-разному для различных объектов, но всегда достаточно медленно и поэтому может отслеживаться персоналом и соответственно корректироваться перенастройкой параметров реализованных регуляторов.

Фактически область применения данного класса регуляторов полностью совпадает с областью применения обычных ПИ и ПИД регуляторов, но их применение тем более эффективно, чем менее стабильны параметры объекта во времени. Ниже рассматриваются наиболее популярные в настоящее время методы адаптивного управления.

1.1 Классификация методов идентификации объектов регулирования

Для оптимального синтеза АСР необходимо располагать исходной информацией о динамических характеристиках объекта регулирования. Наличие такой априорной информации позволяет синтезировать систему автоматического регулирования с заданными критериями качества и

показателями запаса устойчивости.

В процессе эксплуатации АСР исходной информации о свойствах объекта может оказаться недостаточно из-за неизбежного их изменения, что может привести к заметному снижению качественных показателей, а в ряде случаев и к потере устойчивости. Оптимизированная в процессе проектирования АСР в реальных условиях может оказаться не работоспособной. В связи с этим, заключительный этап оптимального синтеза АСР приходится переносить на стадию ввода системы в работу на реальном объекте, а в дальнейшем процессе эксплуатации необходимо иметь возможность корректировать настроечные параметры реализованных регуляторов при изменениях динамических характеристик объекта. Выполняемые при этом действия принято называть адаптацией. Часто математическую модель динамики объекта на стадии проектного синтеза АСР вообще не удается получить. В этом случае адаптация, осуществляемая в действующей АСР, является единственным путем решения задачи ее оптимального синтеза [2, 5, 73]. Стоит также отметить, что адаптация, предполагающая участие в ней человека-наладчика, называется автоматизированной [57].

Различают несколько характерных ситуаций, для которых необходимо применять различные методы идентификации:

1) Линейные и нелинейные системы регулирования (как известно линейные системы легче идентифицировать, поскольку они обладают свойствами суперпозиции).

2) Системы с постоянными или изменяющимися параметрами во времени (системы могут считаться стационарными, если их параметры меняются медленно по сравнению со временем, которое требуется для точной идентификации).

3) Системы часто делятся на дискретные и непрерывные, хотя преобразовать непрерывную формулировку задачи в дискретную обычно довольно просто.

4) Системы с одним или несколькими входными воздействиями. Это деле-

ние целесообразно вводить потому, что методы идентификации значительно упрощаются, если на систему подается лишь одно входное воздействие, по сравнению со случаем, когда на систему действует одновременно комбинация нескольких возмущений или входных воздействий.

5) Детерминированные или стохастические процессы. При идентификации последних ориентируются в основном на вероятностные представления о точном состоянии системы (на практике все результаты измерений засорены шумом и для точной идентификации необходимо осуществить фильтрацию или сглаживание).

6) Наличие или отсутствие априорной информации о системе.

В основу указанной классификации положена по существу степень сложности идентификации. Очевидно, идентифицировать детерминированный линейный стационарный процесс известного порядка с одним входом существенно проще, чем аналогичный стохастический процесс неизвестного порядка, который может быть нелинейным и нестационарным.

Невозможно применять один и тот же метод идентификации для различных ситуаций. Каждый метод имеет свою область или области применения. Для теплоэнергетических объектов наиболее распространенными являются активные методы идентификации, которые, в свою очередь, можно поделить на единовременные (проведение одного активного эксперимента) и продолжительные по времени (выбор возмущающего воздействия, адекватный объем необходимых реализаций, время проведения эксперимента).

На практике невозможно обеспечить качественное управление системой, если её математическая модель не известна с достаточной точностью. Для построения математической модели могут быть использованы как теоретические, так и экспериментальные методы. Опыт, накопленный при проектировании систем управления, убедительно свидетельствует о том, что нельзя построить математическую модель, адекватную реальной системе, только на основе теоретических исследований физических процессов. Сформированная таким образом математическая модель, как правило, значительно отличается от реальной

системы, что приводит, соответственно, к снижению качества управления. Поэтому в процессе проектирования АСР одновременно с теоретическими исследованиями проводятся эксперименты по определению и уточнению математической модели объекта.

Методы определения математических моделей по результатам экспериментальных исследований являются предметом теории идентификации. В зависимости от объема априорной информации о системе различают задачи идентификации в широком и узком смысле. При решении задач идентификации в широком смысле априорная информация о системе либо незначительна, либо вообще отсутствует. Система представляется в виде «черного ящика», и для её идентификации необходимо решение ряда дополнительных задач, связанных с выбором класса модели, оценкой стационарности, линейности и др.

Стоит отметить, что погрешности и ошибки идентификации, естественно, приводят к ошибкам в управлении или в требуемом выходном параметре системы, но эти ошибки могут быть использованы для дальнейшего улучшения идентификации.

1.2 Методы адаптивной настройки, реализуемые в отечественных и зарубежных контроллерах

1.2.1 Методы адаптивной настройки, разработанные на кафедре АСУ ТП НИУ «МЭИ»

На практике широкое распространение получили методы адаптивной настройки регуляторов на базе итерационной процедуры «идентификация-оптимизация», разработанные на кафедре АСУ ТП НИУ «МЭИ», основы которых изложены в [12, 17, 25, 26, 58]. Эти методы используют косвенные показатели оптимальности, определяемые в реальной системе методом активной идентификации в сочетании с итерационной процедурой движения к оптимуму. Методы адаптивной настройки в нескольких упрощенных модификациях реализованы в ряде промышленных контроллеров [27, 59, 60].

Ниже приводится краткое описание работы алгоритма:

- происходит непрерывное вычисление скользящей текущей дисперсии регулируемой величины, при превышении заданного значения которой срабатывает сигнализация на начало действий по корректировке настроечных параметров регулятора;
- на вход объекта подается скачкообразный сигнал или ряд специальных калиброванных сигналов импульсной или синусоидальной формы, амплитуда которых должна быть различима на фоне имеющихся возмущений и, в то же время, быть настолько малой, чтобы не приводить к существенным колебаниям регулируемой величины;
- измеряется реакция регулируемой величины на поступившее возмущение и, по полученным данным, производится расчет передаточной функции объекта регулирования;
- по заданному алгоритму на основе полученной передаточной функции объекта вычисляются и устанавливаются новые параметры регулятора. Обычно расчет производится по критерию минимума средней квадратичной погрешности регулируемой величины при заданном ограничении на запас устойчивости.

Параметры настройки систем регулирования, полученные в результате расчета аналитическими методами по известной модели объекта [1, 3, 14, 18, 22, 33, 51-53, 55, 56, 98], часто нуждаются в коррекции непосредственно на действующих системах регулирования. Это вызвано как организационными, так и принципиальными ограничениями, накладываемыми на возможность получения достоверной математической модели объекта, а также особенностями работы оборудования на стадии ввода АСР в действие.

1.2.2 Реализация адаптивной настройки регуляторов в ПТК ведущих производителей

Не смотря на то, что количество производителей ПТК неуклонно растет и

количество предлагаемых систем перекрывает всевозможные ниши для реализации АСУ ТП на базе технических комплексов до сих пор рынок крупнейших игроков, чьи системы имеют возможность внедряться на крупных энергоблоках, достаточно узок. Наибольшее распространение в Российской Федерации в теплоэнергетической отрасли получили следующие производители ПТК:

- ООО «Siemens» (ПТК «SPPA-T3000»);
- ООО «ABB» (ПТК «800xA IndustrialIT»);
- Группа компаний «Текон» (ПТК «ТЕКОН»);
- ОАО «НИИТеплоприбор» (ПТК «Квинт»);
- ЗАО «НВТ-Автоматика» (ПТК «САРГОН»);
- ООО «Emerson» (ПТК «Ovation»);
- ООО «Rockwell Automation» (торговая марка Allen Bradley, контроллеры серии Logic с пакетом программирования RSLogix 5000);
- ООО «Honeywell» (контроллеры MasterLogic-200 с пакетом программирования SoftMaster);
- ООО «Omron» (контроллеры серии CJ с пакетом программирования CX-One);
- ООО «Schneider Electric» (контроллеры серии Quantum с пакетом программирования Unity Pro).

У всех представленных производителей, помимо базовых функционального и аппаратного набора решений и компонент системы, имеются визитные карточки в виде наработок в области адаптивной настройки регуляторов (практически у всех производителей данные функциональные блоки не входят в базовую комплектацию ПТК и их необходимо приобретать дополнительно). Зачастую способ адаптивной настройки регуляторов не раскрывается, либо затрагивается вскользь, без рассмотрения «внутренностей» функциональных блоков, что, несомненно, усложняет их внедрение на производстве и требует определенной сноровки в подключении и настройке от пуско-наладочного персонала. Здесь также необходимо уточнить, что данные блоки, насколько бы они ни были универсальны, не подходят для адаптивной настройки сложных АСР.

Так, например, в функциональном блоке «Autotune», компании «**Schneider Electric**», реализованы эвристические правила метода Зиглера-Никольса. Сначала на интервале времени, равном $2.5 \cdot T_{nn}$ (T_{nn} – время переходного процесса для разомкнутого контура) выполняется анализ процесса для его идентификации в первом приближении при данной постоянной времени. Далее, с помощью этой модели вычисляется ряд параметров настройки на основе эвристических правил и экспериментальных данных.

Предварительно выбранный диапазон параметров затем уточняется либо по критерию оптимального быстродействия, либо по критерию устойчивости. Алгоритм применим к следующим типам процессов:

- процессы в системах с одним входом и одним выходом;
- процессы с самовыравниванием и без самовыравнивания;
- ассиметричные процессы в пределах допуска ПИД алгоритма;
- в системах с ШИМ регулятором.

Основные выполняемые функции: вычисление параметров настройки стандартных функциональных блоков ПИ и ПИД регуляторов, диагностика, настройка, выбор параметров, оценка качества динамики настройки синтезируемой системы, восстановление прежней настройки. Используются два варианта настройки: горячая и холодная автонастройка.

Адаптация в контроллерах фирмы «**Honeywell**» выполняется с помощью предварительной идентификации модели, так и на основе правил. Идентификация выполняется по отклику на скачок. Величину приращения уставки относительно рабочей точки задает пользователь. Эксперимент выполняется в разомкнутом контуре. Величина задержки определяется как время от начала эксперимента до момента, когда выходная переменная достигнет некоторого малого, наперед заданного значения.

В процессе эксперимента отслеживается величина производной от выходной переменной. Если производная все время уменьшается, то выбирается модель первого порядка, параметры которой идентифицируются по нескольким точкам переходной характеристики. Идентификация выполняется на интервале,

равному $1/3$ постоянной времени, и заканчивается до того, как процесс в системе установится. Если производная имеет максимум, выбирается модель второго порядка и идентификация выполняется на интервале времени, включающем установившееся состояние объекта регулирования.

В контроллерах фирмы «АВВ» адаптация основана на частотной релейной идентификации. Первоначально устанавливается желаемое рабочее значение входной переменной для объекта, затем оператор нажимает кнопку автонастройки. Регулятор сначала измеряет уровень шума, затем в контур регулирования включается реле с гистерезисом, при этом алгоритм регулирования временно отключается. Величина гистерезиса устанавливается автоматически, на основе измеренного уровня шума на выходе объекта. Чем меньше измеренный уровень шума, тем меньше может быть амплитуда колебаний в системе в режиме релейного регулирования. Амплитуда колебаний автоматически настраивается на такую величину, чтобы быть выше уровня шума. После получения колебаний с установившейся амплитудой и частотой эксперимент прерывается и по его результатам вычисляется частота колебаний и коэффициент передачи объекта на этой частоте методом гармонической линеаризации.

Частотная идентификация в режиме релейного регулирования выполняется с применением реле с регулируемым гистерезисом, что позволяет задавать частоту колебаний ниже частоты ω_{180} . По умолчанию колебания задаются такими, чтобы петлевое усиление контура на частоте колебаний ω_0 было равно $R(j\omega_0) \cdot P(j\omega_0) = 0.5 \cdot \exp(-j \cdot 135^\circ)$. Поскольку частотная идентификация дает только два параметра (частоту и коэффициент передачи), а ПИД регулятор имеет три параметра, то используется дополнительное соотношение $T_u = 4T_\partial / K^2$.

Описанная процедура идентификации иногда дает очень большое усиление для объектов с малой задержкой. В этом случае используется ПИ регулятор с коэффициентами, которые рассчитываются по формулам $K = 0.5 / |P(j\omega)|$, $T_u = 4 / \omega_0$. Для объектов с большой задержкой используются формулы $K = 0.25 / |P(j\omega)|$, $T_u = 1.6 / \omega_0$.

Для идентификации параметров в режиме релейного регулирования используются два узкополосных фильтра, настроенных на частоту колебаний в системе ω_0 . Один из них фильтрует сигнал на входе объекта, второй — на его выходе. Фильтры позволяют получить первую гармонику ряда Фурье, которая используется в методе гармонического баланса. Эта частота предварительно находится также из эксперимента с колебаниями в релейном регуляторе методом наименьших квадратов.

В последних версиях контроллеров АВВ после идентификации, в режиме релейного регулирования, используется дополнительный этап идентификации по реакции объекта на скачок для определения статического коэффициента передачи.

В контроллерах АВВ используется также табличное управление, которое применяется практически во всех промышленных контроллерах и других производителей. Переменные, от которых зависят коэффициенты регулятора, выбираются пользователем. Ими могут быть управляющее воздействие на объект, выходная переменная системы или внешний сигнал. В последних версиях регуляторов были существенно расширены размеры таблиц, в которые записываются настроечные параметры регулятора после применения процедуры автонастройки для нужных режимов работы объекта [16].

1.3 Программные средства настройки АСР

Типовая система для настройки регулятора состоит из персонального компьютера (ПК) с установленным специализированным программным обеспечением (ПО) и непосредственно программируемого логического контроллера. Объект включается в контур регулирования после чего система настраивается заданным способом, затем полученные настроечные параметры записываются непосредственно в регулятор, реализованный в ПЛК. Благодаря пользовательскому интерфейсу, большой производительности компьютера и отсутствию ограничений на алгоритмы идентификации системы удается получить параметры регулятора, близкие к оптимальным.

В настоящее время на рынке автоматизации имеется достаточно большое количество коммерческих продуктов [98] для настройки регуляторов. Среди них — Protuner (Techmation Inc.), Lab VIEW Control Toolset (National Instruments), Intelligent Tuner (Fisher-Rosemount), Profit PID (Honeywell), P.I.D.-expert («Техноконт») и другие.

Среди аналитических методов настройки в этих программах наиболее распространены лямбда-тюнинг [84] или метод регулятора с внутренней моделью. Подавляющее большинство программ для описания объекта регулирования использует передаточную функцию объекта регулирования первого порядка с запаздыванием.

Развитие описываемых средств идет в направлении расширения диапазона поддерживаемых регуляторов, применения методов искусственного интеллекта и методов диагностики, развития пользовательского интерфейса.

Программы автоматической коррекции настроечных параметров регуляторов часто дополняется функциональными возможностями анализа износа регулирующих клапанов, автоматической генерирования отчетов с параметрами контуров автоматического регулирования, построения графиков спектральной плотности мощности и функций авто- и взаимной корреляции, оптимизации инверсной модели объекта управления и т.п. [16].

1.4 Нечеткая логика

Управление на основе методов теории нечетких множеств [42, 61, 70, 94] используется при недостаточном знании объекта управления, но при наличии опыта управления им, в нелинейных системах, идентификация которых слишком трудоемка, а также в случаях, когда по условию задачи необходимо использовать знания эксперта.

Поскольку информация, полученная от эксперта, выражена словесно, для ее использования в регуляторах применяют лингвистические переменные и аппарат теории нечетких множеств, который был разработан Л. Заде в 1965 г. [110]. Основная идея этой теории состоит в следующем. Если в теории четких

множеств некоторый элемент может принадлежать множеству или не принадлежать ему, то в теории нечетких множеств вводится понятие функции принадлежности, которая характеризует степень принадлежности элемента множеству. Функцию принадлежности можно приближенно трактовать как вероятность того, что данный элемент принадлежит множеству, однако такая интерпретация, хотя и является для инженеров более понятной, не является математически строгой, поскольку существующая теория нечетких множеств не оперирует понятием вероятности.

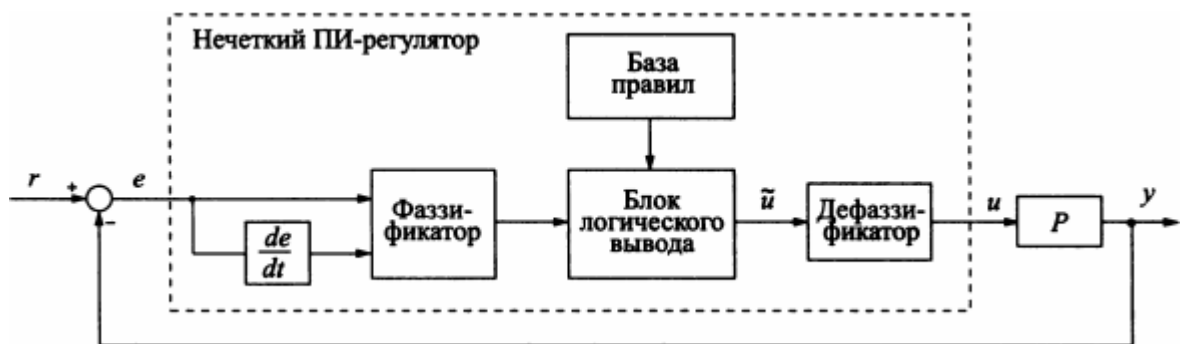


Рисунок 1.1 – Структура нечеткого ПИ регулятора

В 1974 г. Мамдани [99] показал возможность применения идей нечеткой логики для построения системы управления динамическим объектом, а годом позже вышла публикация [100], в которой описывался нечеткий ПИ регулятор и его применение для управления парогенератором. С тех пор область применения нечетких регуляторов постоянно расширяется, увеличивается разнообразие их структур и выполняемых функций.

Нечеткая логика в регуляторах используется преимущественно двумя путями: для построения самого регулятора и для организации подстройки коэффициентов регулятора, причем оба можно реализовывать в контроллере одновременно.

Одна из наиболее распространенных структур нечеткого регулятора продемонстрирована на рисунке 1.1. На вход регулятора поступает ошибка e и вычисляется ее производная по времени. Далее обе величины сначала

подвергаются операции фаззификации, затем полученные нечеткие переменные используются в блоке нечеткого логического вывода для получения управляющего воздействия на объект, которое после выполнения операции дефаззификации поступает на выход регулятора в виде управляющего воздействия u .

1.4.1 Принципы построения нечеткого регулятора

Для применения методов нечеткой логики прежде всего необходимо преобразовать обычные четкие переменные в нечеткие. Процесс такого преобразования называется фаззификацией (от английского fuzzy — нечеткий). Диапазон изменения переменной e разбивается на подмножества NL , NM , NS , Z , PS , PM , PL , в пределах каждого из которых строится функция принадлежности переменной e каждому из подмножеств.




Рисунок 1.2 – Деление области изменения переменной e на множества с функциями принадлежности треугольной формы

На рисунке 1.2 функции принадлежности имеют треугольную (наиболее распространенную) форму, хотя в общем случае они могут быть любыми, исходя из смысла решаемой задачи [61]. Количество множеств также может быть произвольным.

Для нечетких множеств существует общепринятая система обозначений: N — отрицательный (Negative); Z — нулевой (Zero); P — положительный (Positive); к этим обозначениям добавляют буквы S (малый, Small), M (средний, Medium), L (большой, Large). Например, NL — отрицательный большой; NM — отрицательный средний (Negative Medium); PL — положительный большой.

Число таких переменных (термов) может быть любым, однако с увеличением их числа существенно возрастают требования к опыту эксперта, который должен сформулировать правила для всех комбинаций входных переменных.

Если ошибка e на входе нечеткого регулятора равна e_1 (рисунок 1.2), то соответствующее значение нечеткой переменной будет равно PS со степенью принадлежности подмножеству PS , равной $\mu(e_1) = 0.82$, или равно PM со степенью принадлежности $\mu(e_1) = 0.18$. Степень принадлежности ошибки e_1 другим множествам (Z , PL , NS и др.) равна нулю. Таким образом, ошибка e_1 оказалась преобразованной в нечеткие переменные.

Для выполнения функции регулирования над нечеткими переменными должны быть выполнены операции, построенные на основании высказываний оператора, сформулированных в виде нечетких правил. Совокупность нечетких правил и нечетких переменных используется для осуществления нечеткого логического вывода, результатом которого является управляющее воздействие на объект управления.

Нечеткий вывод выполняется следующим образом. Предположим, что область изменения ошибки e разделена на множества N , Z , P , область изменения управляющего воздействия — на множества NL , NM , Z , PM , PL и что с помощью эксперта удалось сформулировать следующие правила работы регулятора [84]:

- Правило 1: если $e = N$ и $de/dt = P$, то $u = Z$;
- Правило 2: если $e = N$ и $de/dt = Z$, то $u = NM$;
- Правило 3: если $e = N$ и $de/dt = N$, то $u = NL$;
- Правило 4: если $e = N$ и $de/dt = P$, то $u = PM$;
- Правило 5: если $e = N$ и $de/dt = Z$, то $u = Z$;
- Правило 6: если $e = N$ и $de/dt = N$, то $u = NM$;
- Правило 7: если $e = N$ и $de/dt = P$, то $u = PL$;
- Правило 8: если $e = N$ и $de/dt = Z$, то $u = PM$;
- Правило 9: если $e = N$ и $de/dt = N$, то $u = Z$;

Используя правила, можно получить значение управляющей переменной и на выходе нечеткого регулятора. Для этого нужно найти функцию принадлежности переменной u множеству, образованному в результате выполнения операций вывода над множествами, входящими в систему правил.

Операция «И» в правилах соответствует пересечению множеств, а результат применения всех правил соответствует операции объединения множеств. Функция принадлежности для пересечения двух множеств, например N и P (см. правило 1), находится как

$$\mu_{e \cap de/dt} = \min(\mu_e, \mu_{de/dt}),$$

т.е. каждое значение функции принадлежности пересечения множеств равно наименьшему значению из двух, стоящих в круглых скобках.

Функция принадлежности для объединения тех же множеств имеет вид:

$$\mu_{e \cup de/dt} = \max(\mu_e, \mu_{de/dt}).$$

Функции принадлежности, полученные при пересечении или объединении множеств, могут быть определены различными способами, в зависимости от решаемой задачи. В этом смысле сама теория нечетких множеств тоже является нечеткой. Используют, в частности, более понятную операцию нахождения функций принадлежности в случае пересечения и объединения множеств, имеющую аналогию с правилами умножения и сложения вероятностей:

$$\mu_{e \cap de/dt} = \mu_e \cdot \mu_{de/dt};$$

$$\mu_{e \cup de/dt} = \mu_e + \mu_{de/dt} - \mu_e \cdot \mu_{de/dt}.$$

Однако применение первых двух способов нахождения функции принадлежности обычно более предпочтительно, так как при этом сохраняется большинство правил, разработанных для обычных множеств [70].

Функции принадлежности для каждого из множеств NL , NM , Z , PM , PL , входящих в нечеткую переменную u в правилах, полученная получаются в виде:

$$\mu_{uI}(\tilde{u}) = \min\left\{\mu_{uI}(\tilde{u}), \min(\mu_{eI}(e), \mu_{de/dt I}(de/dt))\right\},$$

$$\mu_{п2}(\tilde{u}) = \min\left\{\mu_{u2}(\tilde{u}), \min(\mu_{e2}(e), \mu_{de/dt 2}(de/dt))\right\}, \dots$$

$$\mu_{п9}(\tilde{u}) = \min\left\{\mu_{u9}(\tilde{u}), \min(\mu_{e9}(e), \mu_{de/dt 9}(de/dt))\right\}.$$

Здесь каждое из девяти уравнений соответствует одному из правил. Результирующая функция принадлежности управляющего воздействия u , полученная после применения всех девяти правил, находится как объединение функций принадлежности всех правил:

$$\mu(\tilde{u}) = \max(\mu_{п1}(\tilde{u}), \mu_{п2}(\tilde{u}), \dots, \mu_{п9}(\tilde{u})).$$

После получения результирующей функции принадлежности управляющего воздействия значение управляющего воздействия определяется как:

$$u = \frac{\int_{u_{min}}^{u_{max}} \tilde{u} \cdot \mu(\tilde{u}) \cdot d\tilde{u}}{\int_{u_{min}}^{u_{max}} \mu(\tilde{u}) \cdot d\tilde{u}}.$$

Рассмотренный способ дефаззификации является наиболее распространенным, но не единственным. Для построения нечетких регуляторов обычно используют П, ПИ и ПИД законы регулирования. Реализация нечеткого ПИД регулятора вызывает проблемы, поскольку он должен иметь трехмерную таблицу правил в соответствии с тремя слагаемыми в уравнении ПИД регулятора, которую чрезвычайно сложно заполнить, пользуясь ответами эксперта.

Окончательная настройка нечеткого регулятора или настройка, близкая к оптимальной, до сих пор остается трудной задачей. Для этого используются обучающие алгоритмы и генетические поисковые методы, требующие больших вычислительных ресурсов и времени.

1.4.2 Принципы автоподстройки реализуемого регулятора

Настройка регулятора, выполненная методами, изложенными в предыдущем параграфе может быть улучшена с помощью дальнейшей

подстройки. Подстройка может быть выполнена оператором на основании правил или автоматически, с помощью блока нечеткой логики (рисунок 1.3). Блок нечеткой логики (фаззи-блок) использует базу правил подстройки и методы нечеткого вывода. Фаззи-подстройка позволяет уменьшить перерегулирование, сократить время переходного процесса и повысить робастность ПИ регулятора.




Рисунок 1.3 – Структура ПИ регулятора с блоком автонастройки на основе нечеткой логики

Процесс автонастройки регулятора с помощью блока нечеткой логики начинается с поиска начальных приближений коэффициентов регулятора k_p, T_u . Далее формулируется критериальная функция, необходимая для поиска оптимальных значений параметров настройки методами оптимизации.

Процесс настройки регулятора состоит из нескольких этапов: выбираются диапазоны входных и выходных сигналов блока автонастройки, форма функций принадлежности искомым параметрам, правила нечеткого вывода, механизм логического вывода, метод дефаззификации и диапазоны масштабных множителей, необходимых для пересчета четких переменных в нечеткие.

Поиск параметров регулятора выполняется методами оптимизации. Для этого выбирается целевая функция как интеграл от суммы квадратов ошибки регулирования и времени установления. В критерий минимизации иногда добавляют скорость нарастания выходной переменной объекта.

В качестве искомым параметров выбирают положение максимумов функций принадлежности и масштабные коэффициенты на входе и выходе

фаззи-блока. К задаче оптимизации добавляют ограничения на диапазон изменения позиций функций принадлежности. Оптимизация критериальной функции может быть выполнена, например, с помощью генетических алгоритмов [16].

1.5 Искусственные нейронные сети

Нейроуправление динамическими объектами является новым перспективным направлением, находящимся на стыке таких дисциплин, как автоматическое управление, искусственный интеллект, нейрофизиология. Нейронные сети обладают рядом уникальных свойств, которые делают их мощным инструментом для создания систем управления: способностью к обучению на примерах и обобщению данных, способностью адаптироваться к изменению свойств объекта управления и внешней среды, пригодностью для синтеза нелинейных регуляторов, высокой устойчивостью к повреждениям своих элементов в силу изначально заложенного в нейросетевую архитектуру параллелизма. В настоящее время в литературе описаны многочисленные примеры практического применения нейронных сетей для решения задач управления теплоэнергетическими процессами: АСР температуры электропечи [89], АСР турбогенератора [107], АСР температуры перегретого пара [30], управление сервоприводом [95,96] и т.д.

Идея применения нейронных сетей для управления динамическими объектами впервые была высказана У. Видроу в 1964 г. [108], однако, интенсивные исследования данного направления развернулись лишь в конце 80-х годов прошлого века. Один из первых обзоров в области нейроуправления упоминает 5 методов обучения нейросети для непосредственного управления объектом. С тех пор количество методов нейроуправления многократно увеличилось, появились новые решения на основе многомодульного подхода и приближенного динамического программирования.

Сформировались два основных направления в применении нейронных сетей внутри синтезируемых регуляторов: прямые методы, основанные на непо-

средственном управлении объектом с помощью нейронных сетей, и не прямые методы, когда нейронные сети используются для выполнения вспомогательных функций управления, таких как фильтрация шума или идентификация динамического объекта. В зависимости от числа нейронных сетей, составляющих нейроконтроллер, системы нейроуправления могут быть одномодульными или многомодульными. Схемы нейроуправления, которые применяются совместно с традиционными контроллерами, называются гибридными [72].

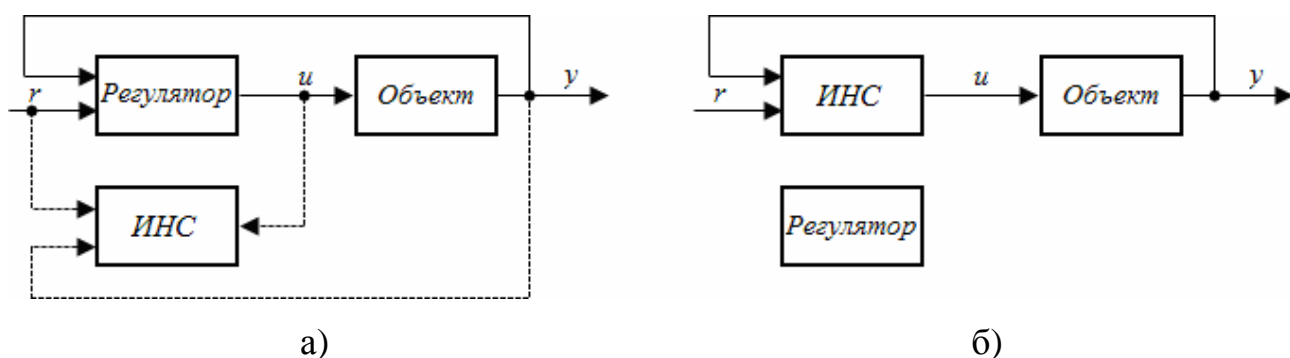
1.5.1 Подражающее нейроуправление

Название «подражающее нейроуправление» (Neurocontrol learning based on mimic, Controller Modeling, Supervised Learning Using an Existing Controller) [93, 101, 104, 108] охватывает системы управления, в которых нейроконтроллер обучается на примерах динамики обычного регулятора по обратной связи, построенного, например, на основе стандартного ПИД алгоритма. Схема подражающего нейроуправления продемонстрирована на рисунке 1.4.

После обучения нейронная сеть в точности воспроизводит функции исходного регулятора. Обучающая выборка для нейронной сети формируется следующим образом. Обычный регулятор по обратной связи управляет объектом управления в штатном режиме. Значения величин на входе и выходе регулятора протоколируются. На основе протокола формируется обучающая выборка для нейросети $U = \{P_i, T_i\}_{i=1}^M$, содержащая M пар значений входа P_i и ожидаемых реакций T_i нейросети:

$$P_i = [r(i+1), S(i)]^T,$$

$$T_i = u(i).$$



а) режим обучения нейронной сети; б) режим управления

Рисунок 1.4 – Схема подражающего нейроуправления

После обучения нейронная сеть подключается вместо исходного регулятора. Основным недостатком этого метода является необходимость в предварительно настроенном исходном регуляторе, что не всегда представляется возможным. Кроме того, полученный путем обучения нейроконтроллер в принципе не может обеспечить лучшее качество управления, чем копируемый регулятор. Поэтому, в настоящее время подражающее нейроуправление применяют, в основном, для первичного обучения нейронной сети с использованием других методов для последующего корректирующего обучения нейроконтроллера.

1.5.2 Инверсное нейроуправление


При инверсном нейроуправлении формирование инверсной модели объекта управления осуществляется путем обучения нейронной сети. Известно несколько разновидностей такого нейроуправления.

Обобщенное инверсное нейроуправление (Generalized Inverse Neurocontrol, Direct Inverse Neurocontrol) [43, 89, 102] предусматривает обучение сети в режиме офф-лайн, на основе записанных траекторий поведения динамического объекта. Для получения таких траекторий, на объект управления в качестве управляющего сигнала подают некоторый случайный процесс. Значения управляющих сигналов и ответных реакций объекта протоколируют и на этой основе формируют обучающую выборку $U = \{P_i, T_i\}_{i=1}^M$:

$$P_i = [y(i), S(i-1)]^T,$$

$$T_i = u(i).$$

В ходе обучения, нейронная сеть должна уловить и запомнить зависимость значений управляющего сигнала $u(k-1)$ от последующего значения реакции объекта управления $y(k)$, находящегося перед этим в состоянии $S(k-1)$.



а) режим обучения инверсного нейрорегулятора; б) режим управления объектом

Рисунок 1.5 – Схема обобщенного инверсного нейрорегулирования

При управлении объектом, инверсный нейрорегулятор подключается как регулятор, причем возможны два способа подключения: замкнутый и разомкнутый. При замкнутом подключении, схема которого показана на рисунке 1.5,а на вход нейроконтроллера подаются текущие значения уставки и вектора состояния объекта управления, поступающего по цепи обратной связи:

$$x(k) = [r(k+1), S(k)]^T.$$

При разомкнутом подключении на вход нейроконтроллера поступают только значения уставки с задержками:

$$x(k) = [r(k+1), r(k) \dots r(k-N+1)]^T.$$

При этом предполагается, что сформированная при обучении инверсная модель объекта управления является адекватной, следовательно, сигнал управления, выдаваемый нейронной сетью, обеспечит переход объекта в положение, заданное уставкой. Разомкнутая система нейрорегулирования обладает высоким быстродействием, поскольку на вход нейроконтроллера не поступает значение текущего состояния объекта управления, обработка которого требует значительных ресурсов. Однако из-за отсутствия обратной связи качество такого управления оказывается низким [104].

Достоинством обобщенного инверсного нейроуправления является обучение нейроконтроллера в режиме офф-лайн и отсутствие необходимости в точной математической модели объекта управления. К недостаткам следует отнести сложность формирования обучающей выборки из-за необходимости тщательного подбора идентифицирующего случайного процесса, подаваемого на вход системы, а также низкое качество работы в тех случаях, когда инверсия объекта управления оказывается неоднозначной функцией. Неоднозначность приводит к наличию противоречий в обучающей выборке, заводящих в тупик процесс обучения нейронной сети.

1.5.3 Гибридное нейроуправление

Гибридными называют системы нейроуправления, в которых нейронные сети работают совместно со стандартными регуляторами.

Гибридное нейроуправление (NNPID Autotuning, Neuromorphic PID Selftuning) [32, 85, 88, 105] позволяет осуществлять самонастройку регулятора в режиме он-лайн с использованием нейронных сетей.

Управление с использованием ПИД регулятора основано на минимизации ошибки обратной связи. Вырабатываемый контроллером сигнал управления представляет взвешенную сумму пропорциональной, интегральной и дифференциальной частей:

$$u(t) = k_p \cdot e(t) + k_u \cdot \int_0^t e(\tau) d\tau + k_d \cdot \frac{de(t)}{dt}$$

Настроечные параметры реализуемого регулятора могут быть рассчитаны вручную, по правилу Ziegler-Nichols [111], правилу Cohen-Coon [86] или другими методами [15], либо с использованием нейронной сети, как показано на рисунке 1.6.




Рисунок 1.6 – Схема гибридного нейруправления

Обученная система нейруправления действует следующим образом. На такте k нейронная сеть получает уставку $r(k+1)$ и генерирует настроечные параметры ПИД регулятора, которые поступают непосредственно на регулятор вместе со значением текущей ошибки обратной связи $e(k)$. Обучение нейросети происходит в режиме реального времени по ошибке обратной связи, методом наискорейшего спуска:

$$\Delta w(k) = -\alpha e(k) \cdot \frac{\partial y(k+1)}{\partial u(k)} \cdot \frac{\partial u(k)}{\partial K(k)} \cdot \frac{\partial K(k)}{\partial w(k)}$$

Здесь $K(k) = [k_p(k) \ k_u(k) \ k_d(k)]^T$ вектор выходов нейронной сети, поступающий на регулятор.

$$\frac{\partial u(k)}{\partial K_i} = \begin{cases} e(k) - e(k-1) & \text{при } i=1 \\ e(k) & \text{при } i=2 \\ e(k) - 2e(k-1) + e(k-2) & \text{при } i=3 \end{cases}$$

Градиенты вычисляют методом обратного распространения ошибки. Якобиан находится аналитически, на основе математической модели объекта управления. Плюсами использования этого подхода является упрощение эксплуатации вследствие устранения процедуры настройки ПИД регулятора вручную. Кроме того, в случае применения нейронной сети с нелинейными активационными функциями, применяемый регулятор фактически превращается в нелинейный, что потенциально обеспечивает более высокое качество управления нелинейными динамическими объектами. Обратная сторона подобной настройки представляет собой сложность оценки устойчивости полученного нелинейного контроллера. Также минусом является необходимость в точной математической модели объекта управления, необходимой для вычисления якобиана.

Эту трудность можно обойти, используя прямой нейроэмулятор, и, действуя по методу обратного распространения ошибки через прямой нейроэмулятор.

Методы гибридного параллельного нейроуправления (Parallel Neurocontrol, Stable Direct Adaptive Control, NARMA L2 Feedback Linearization Control, Additive Feedforward Control) [32, 89, 92] предусматривают параллельное использование нейроконтроллеров и обычных регуляторов для управления динамическими объектами. Соответствующая схема показана на рисунке 1.7. При этом ИНС и обычный регулятор получают одинаковые значения уставки.

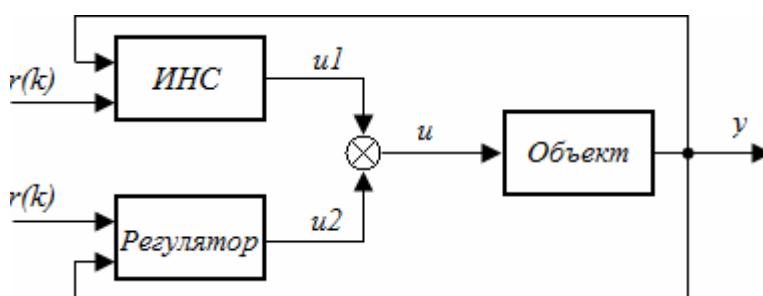


Рисунок 1.7 – Схема гибридного параллельного нейроуправления

Возможны следующие варианты совместного подключения обычного регулятора и нейроконтроллера:

1) к объекту управления подключается обычный регулятор, после чего нейроконтроллер обучается управлять уже замкнутой АСР. После обучения нейроконтроллер подключается к системе, а управляющие сигналы нейроконтроллера и регулятора суммируются;

2) нейроконтроллер учится управлять объектом управления, после обучения начинает функционировать в штатном режиме. Далее, для управления замкнутой нейроконтроллером системой, настраивается обычный регулятор. После настройки обычного регулятора, он подключается к системе, управляющие сигналы нейроконтроллера и регулятора суммируются;

3) области действия обычного регулятора и нейроконтроллера разграничиваются. Например, в пространстве состояний объекта управления для нейроконтроллера выделяется отдельная область LS:

$$LS = \begin{pmatrix} (y_1 - d_1; y_1 + d_1) \\ \dots \\ (y_n - d_n; y_n + d_n) \end{pmatrix}.$$

При этом, обычный контроллер рассчитывается на управление объектом вне этой области пространства состояния. При параллельной работе обоих контроллеров, управляющий сигнал поступает на объект либо от нейроконтроллера, если текущее состояние системы находится в пределах области LS, либо, в противном случае, от обычного регулятора.

Гибридное параллельное нейроуправление представляет компромиссное решение для внедрения нейроуправления в промышленность и перехода от обычных регуляторов к нейросетевым.

За последние 20 лет нейроуправление получило значительное развитие. Как было обозначено в одном из первых обзоров по тематике нейроуправления [93] в качестве перспективного направления исследований, доминирующая доля внимания была уделена задачам разработки нейросистем для управления нелинейными динамическими объектами, получено множество примеров успешно работающих систем этого типа.

Вместе с тем, остается ряд нерешенных проблем, мешающих широкому применению систем нейроуправления в промышленных АСУ ТП:

1. Все еще отсутствует универсальная процедура анализа устойчивости нелинейных нейроконтроллеров. Были предложены лишь частные решения для отдельных видов нейроконтроллеров при известной математической модели объекта управления.

2. Конструкция почти всех схем нейроуправления выглядит слишком усложненной из-за наличия нескольких нейросетей и нетривиальной последовательности процедур их обучения. Перспективным направлением исследований является получение унифицированного алгоритма обучения единой управляющей нейросети.

3. Для дальнейшего развития методов нейроуправления, актуальной проблемой остается создание новых моделей динамических нейронных сетей и

способов их обучения, так как базовыми блоками построения многих методов нейроуправления являются эмпирически полученные модели прямой или обратной динамики объекта управления.

1.6 Генетические алгоритмы

Генетические алгоритмы являются мощным методом оптимизации, позволяющим найти глобальный оптимум быстрее, чем другие методы случайного поиска. Существенным их достоинством является отсутствие проблем со сходимостью и устойчивостью. Эти методы используются для идентификации моделей объектов управления, для поиска оптимальных параметров регулятора и оптимальных положений функций принадлежности в фаззи-регуляторах, для обучения нейронных сетей. Чаще всего генетические алгоритмы используются совместно с нейронными сетями и регуляторами с нечеткой логикой.

Генетические алгоритмы основаны на принципах естественного отбора, сформулированных Дарвиным в 1859 г. Идею генетических алгоритмов применительно к решению математических задач сформулировал Дж. Холланд в 1962 г., используя понятия генов, хромосом, скрещивания, мутации, селекции, репродукции. Основной идеей является прямое подобие принципу естественного отбора, когда выживают наиболее приспособленные особи.

Для применения генетических алгоритмов необходимо преобразовать переменные, фигурирующие в условии задачи, в генетические переменные. Такое преобразование задается схемой кодирования. Переменные могут быть представлены в двоичной форме, в форме действительных десятичных чисел или в другой форме, в зависимости от смысла решаемой задачи.

Классический генетический алгоритм состоит из следующих шагов [8, 91]:

1. Выбор исходной популяции хромосом размера N ;
2. Оценка приспособленности хромосом в популяции;
3. Проверка условия остановки алгоритма;
4. Селекция хромосом;

5. Применение генетических операторов;
6. Формирование новой популяции;
7. Переход к п. 2.

Для работы алгоритма необходимо задать нижнюю и верхнюю границы изменения искомых параметров, вероятность скрещивания, вероятность мутации, размер популяции и максимальное количество поколений.

Исходная популяция хромосом генерируется случайным образом. Приспособленность хромосом оценивается с помощью целевой функции в кодированной форме. Далее хромосомы с лучшей приспособленностью собираются в группу, в пределах которой выполняются генетические операции скрещивания или мутации. Скрещивание позволяет получить от двух родителей перспективного потомка. Оператор мутации вносит изменения в хромосомы. В случае двоичного кодирования мутация состоит в изменении случайного бита в двоичном слове.

Пример кодирования трех коэффициентов ПИД регулятора для применения в генетических алгоритмах [97] приведен на рисунке 1.8. Здесь хромосома состоит из трех параметров общей длиной 48 бит. Операция скрещивания состоит в обмене генетическим материалом между хромосомами (родителями) для того, чтобы получить новую хромосому (потомка). Существует множество различных форм операторов скрещивания. Один из них состоит в том, что в двух родительских хромосомах случайным образом выбирается некоторая позиция (рисунок 1.9), затем происходит обмен генетической информацией, расположенной справа от выбранной позиции [91].




Рисунок 1.8 – Кодирование коэффициентов регулятора для использования в генетическом алгоритме




Рисунок 1.9 – Операция скрещивания хромосом

После выполнения генетического алгоритма производится декодирование двоичного представления в инженерные величины.

Оценка приспособленности хромосом в популяции для оценки коэффициентов ПИД регулятора может быть выбрана, к примеру, как [97]

$$J = \frac{1}{\int_0^t |e(t)| dt},$$

где $e(t)$ — текущее значение ошибки регулирования, t — время.

Селекция хромосом осуществляется методом рулетки. На колесе рулетки имеются секторы, причем ширина сектора пропорциональна функции приспособленности. Поэтому чем больше значение этой функции, тем более вероятен отбор соответствующей ей хромосомы.

Несмотря на все преимущества, существует также несколько поводов и для критики генетических алгоритмов:

Генетические алгоритмы плохо масштабируемы под сложность решаемой проблемы, что часто приводит к неоправданному увеличению элементов подверженных мутации, при большой области поиска решений, что сказывается на машинном времени расчета. Сократить время поиска решения может декомпозиция задачи, но данная процедура требует тщательного изучения со стороны исследователя.

Необходимость расчета нескольких функций приспособленности для сложных задач, с последующим выбором наиболее оптимального для решаемой задачи, что является фактором, ограничивающим использование алгоритмов искусственной эволюции.

Во многих задачах генетические алгоритмы имеют тенденцию сходиться к локальному оптимуму или даже к спорным точкам, вместо глобального оптимума для данной задачи. Эту проблему можно решить использованием

иной функции цели, увеличением вероятности мутаций, или использованием методов отбора, которые поддерживают разнообразие решений в популяции.

1.7 Выводы

1. Проведен аналитический обзор различных подходов к задачам автоматизированного и адаптивного управления, представлено краткое описание наиболее распространенных на практике систем адаптивного управления. Выделены достоинства и недостатки, присущие каждой из рассматриваемых методик.
2. Методы настройки действующих систем регулирования производственных процессов должны отвечать следующим основным требованиям:
 - минимальная продолжительность и трудоемкость экспериментальных работ;
 - процесс настройки не должен сопровождаться сильными нарушениями нормального режима работы технологического оборудования;
 - получение результатов в законченном виде, без какой либо дополнительной проверки и корректировки;
 - методика настройки должна быть достаточно универсальной, т.е. пригодной для настройки АСР с различной структурой и с различными динамическими характеристиками объектов;
 - методика настройки должна обладать достаточной защищенностью от помех и ошибок эксперимента.
3. Создание адаптивных систем управления позволяет осуществить оптимизацию режимов работы объекта, обеспечить работоспособность системы управления в условиях широкого изменения динамических свойств объекта, повысить надежность системы, снизить технологические требования к изготовлению отдельных узлов и элементов системы.
4. Растущая производительность современных контроллеров позволяет совершать шаги по реализации систем адаптивного управления непосредственно в ПЛК. При построении систем автоматического управле-

ния следует обращать внимание на эффективные и инновационные методы, как идентификации, так и адаптации, но не стоит забывать, что реализуемые программы и программное обеспечение на автоматизируемом объекте должно быть также простым и удобным в эксплуатации.

5. В настоящее время нейросетевые технологии продолжают завоевывать внимание исследователей и разработчиков. За последние годы произошел существенный рост производительности персональных компьютеров, расширились возможности программной реализации искусственных нейронных сетей, появилось достаточное количество учебной литературы. Решение задачи адаптивного управления с применением ИНС как для идентификации объекта регулирования, так и для адаптивной настройки регуляторов является перспективным направлением для исследований. Особого внимания должен быть удостоен поиск простых, но в то же время надежных решений для реализации теоретических разработок на практике.

ГЛАВА 2

ОПТИМАЛЬНАЯ НАСТРОЙКА РЕГУЛЯТОРОВ

2.1 Структуры исследуемых регуляторов, показатели качества работы АСР

2.1.1 Структуры исследуемых регуляторов

Одним из основных этапов при решении задачи синтеза и анализа вновь проектируемой АСР является выбор критерия её оптимального функционирования. Структурная схема одноконтурной АСР представлена на рисунке 2.1.

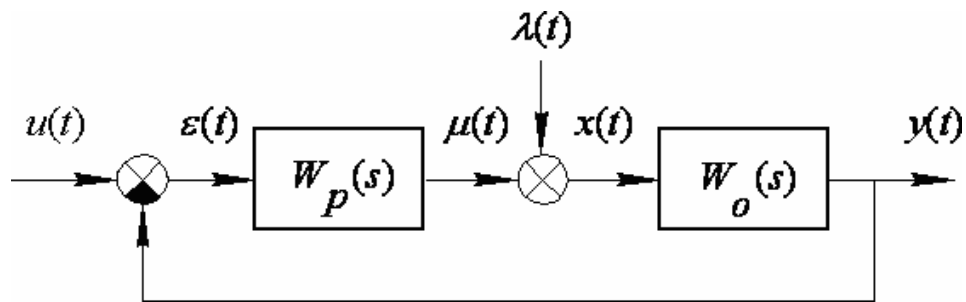


Рисунок 2.1 – Структурная схема одноконтурной АСР

Объект регулирования в большинстве промышленных АСР описывается дробно-рациональной передаточной функцией $W_o(s)$, включающей в себя звено транспортного запаздывания. В качестве регуляторов, иллюстрирующих проведенные исследования, выбраны типовой ПИ регулятор (2.1), а также идеальный (2.2) и реальный (2.4) ПИД регуляторы с соответствующими передаточными функциями.

$$W_{ПИ}(s) = k_p + \frac{k_u}{s}, \quad (2.1)$$

где k_p и $k_u = \frac{k_p}{T_u}$ – настроечные параметры ПИ регулятора (T_u – постоянная времени интегрирования).

Интерес к регуляторам, действующим по ПИД закону регулирования, в последнее время заметно вырос [81]. В первую очередь это объясняется тем, что они позволяют получить более высокое качество регулирования по сравнению с традиционно применяемыми ПИ регуляторами. Существующие аналитические методы настройки ПИД регуляторов, наряду с их неоднозначностью по используемым критериям, дают далеко не оптимальные результаты.

Передаточная функция идеального ПИД регулятора имеет вид:

$$W_{\text{ПИД ИДЕАЛ}}(s) = k_p + \frac{k_p}{T_u \cdot s} + k_p \cdot T_d \cdot s, \quad (2.2)$$

где k_p – коэффициент передачи регулятора; T_u и T_d – постоянные времени интегрирования и дифференцирования.

С учетом обозначений $k_u = \frac{k_p}{T_u}$ и $k_d = k_p \cdot T_d$ выражение (2.2) принимает вид:

$$W_{\text{ПИД ИДЕАЛ}}(s) = k_p + \frac{k_u}{s} + k_d \cdot s, \quad (2.3)$$

где k_u , k_d – настроечные параметры интегральной и дифференциальной составляющих регулятора.

Передаточная функция (2.3) является более удобной для процедур численной оптимизации, поскольку однозначно определяет каждую из составляющих регулятора через соответствующие настроечные параметры.

Из-за наличия случайных высокочастотных помех во входном сигнале регулятора дифференциальную составляющую принято реализовывать в виде реального дифференцирующего звена. На практике эта процедура осуществляется с помощью фильтров с передаточной функцией апериодического звена n -го порядка. Постоянную времени фильтра T_ϕ связывают с постоянной времени

дифференцирования T_∂ с помощью коэффициента k_ϕ . Величина коэффициента k_ϕ , а также порядок фильтра n выбираются по результатам анализа вероятностных характеристик случайной помехи, исходя из ее оптимальной фильтрации при вычислении производных [4, 20]. С учетом соотношения $T_\partial = \frac{k_\partial}{k_p}$, передаточная функция для реального ПИД регулятора может быть выражена через принятые настроечные параметры k_p , k_u , k_∂ , коэффициент k_ϕ и порядок фильтра n в виде соотношения:

$$W_{\text{ПИД РЕАЛ}}(s) = k_p + \frac{k_u}{s} + \frac{k_\partial \cdot s}{\left(\frac{k_\partial}{k_p \cdot k_\phi} \cdot s + 1 \right)^n}, \quad (2.4)$$

Передаточной функцией (2.4) описываются алгоритмы реальных ПИД регуляторов, реализуемых практически во всех отечественных и зарубежных микропроцессорных контроллерах. Величину коэффициента k_ϕ принято выбирать относительно небольшой в диапазоне от пяти до десяти, а порядок фильтра n не выше второго.

Вопросы, связанные с настройкой реальных ПИД регуляторов, изложены в работах [13, 48, 54, 65]. В работе [54] приводится аналитический метод расчета с линейным интегральным критерием оптимальности I_L и ограничением на величину частотного показателя колебательности M . Определение оптимальных настроек производится методом последовательных приближений, осуществляемых в режиме диалога на ПК. В работе [48], в отличие от известных интегральных критериев, нашедших широкое распространение в аналитических и численных методах расчета, рекомендуются экспертные критерии. С помощью процедуры многоуровневого сканирования осуществляется вывод системы регулирования на границу заданного запаса устойчивости, по результатам которого и определяется оптимальная настройка. В работе [13] для одноконтурной АСР с ПИД регулятором предложены простые эмпирические формулы, позво-

ляющие определять параметры настройки регулятора по переходной характеристике объекта регулирования. В работе [65] используются методы численной настройки реальных ПИД регуляторов с помощью эволюционного генетического алгоритма «Optim-MGA» по интегральным критериям с ограничением на величину частотного показателя запаса устойчивости. Рассматривается также возможность робастной компромиссной настройки, гарантирующей сохранение заданного запаса устойчивости при прогнозируемом характере изменения динамики объекта регулирования.

В расчетах, связанных с анализом систем регулирования, принято рассматривать две точки приложения действующих в АСР возмущений: возмущение $\lambda(t)$, поступающее в объект вместе с регулирующим воздействием $\mu(t)$, и приведенное к выходу объекта возмущение $\nu(t)$. Реакция системы в виде ошибки регулирования $\varepsilon(t)$ на возмущение $\nu(t)$ совпадает с реакцией на задающее воздействие $u(t)$ в системе управления и отличается от нее лишь знаком [22, 40]. Поскольку в системе регулирования задача ликвидации отклонений при неизменном задании $u(t)$ решается с помощью регулятора, работающего в замкнутом контуре, то возникает необходимость введения ограничений, связанных с запасом устойчивости.

2.1.2 Выбор показателя запаса устойчивости

Промышленные объекты регулирования обладают рядом особенностей и, в первую очередь, наличием транспортного запаздывания. Общепринятый метод дифференциальных уравнений с корневым показателем запаса устойчивости в виде степени колебательности m , несмотря на его широкое использование при расчете настроек, является приближенным. Предпочтительными следует считать методы, в которых запас устойчивости задается в виде частотного показателя колебательности M . Поскольку переходные процессы в АСР чаще всего имеют колебательный характер, то в графиках амплитудно-частотной характеристики замкнутого контура $A_{3c}(\omega)$ имеет место резонансный пик при резо-

нансной частоте ω_p . Отношение максимального значения $A_{zc}(\omega_p)$ к ее значению при нулевой частоте $A_{zc}(\omega_0)$ и получило название частотного показателя колебательности контура, который может быть принят в качестве меры его запаса устойчивости, т.е. можно считать, что контур имеет необходимый запас устойчивости, если его частотный показатель колебательности не превышает заранее заданного допустимого значения.

Несмотря на принятые в практике расчета АСР соотношения между корневым и частотным показателями запаса устойчивости, эти два метода дают, как правило, заметно различающиеся результаты. Расчет на основе корневого показателя запаса устойчивости не всегда гарантирует требуемую форму переходных процессов – более определенной оказывается связь между M и Ψ . Однако. Однако расчет линий $M=const$ в недалеком прошлом даже для АСР с ПИ регулятором был сопряжен с довольно громоздкими графическими построениями. Аналитический же расчет ПИ регулятора при ограничении $M \leq M_{дон}$ позволяет найти только точку $(k_u)_{max}$ [34]. В настоящее время проблема построения линий заданного запаса устойчивости потеряла свою актуальность, т.к. производительность современных ПК позволяет практически мгновенно производить подобные вычисления, как для ПИ, так и для ПИД регуляторов.

2.1.3 Интегральные критерии качества оптимальной настройки регуляторов

Объединение максимального отклонения и длительности переходного процесса наилучшим способом отображает площадь под графиком переходного процесса, которая определяется интегралом от модуля отклонения регулируемой величины I_M :

$$I_M = \int_0^{\infty} |y(t)| dt \rightarrow \min$$

Интеграл по модулю не имеет аналитической связи с настройками регулятора. Однако в численных методах расчета с использованием имитационных

моделей этот критерий, имеющий экстремум в пределах области устойчивой работы АСР, является наиболее удобным, поскольку обеспечивает наилучшую, по сравнению с другими критериями, сходимость.

Как в численных, так и в аналитических методах расчета широкое распространение получил квадратичный интегральный критерий I_k :

$$I_k = \int_0^{\infty} y^2(t) dt \rightarrow \min, \quad (2.5)$$

Возведение в квадрат позволяет устранить влияние отрицательных значений отклонения регулируемой величины. Квадратичный интегральный критерий, в отличие от предыдущего критерия, имеет аналитическую связь с настройками параметрами регулятора. Его значение может быть вычислено по формуле, включающей КЧХ замкнутой системы $W_{zc}(j\omega)$ относительно анализируемого возмущения. Поскольку $W_{zc}(j\omega)$ зависит от точки приложения возмущения, I_k также как и I_m не является инвариантным относительно возмущений, действующих по различным каналам. При возмущениях по каналу регулирующего органа выражение для I_k запишется в виде:

$$I_k = \frac{1}{\pi} \int_0^{\infty} \left| \frac{W_o(j\omega)}{1 + W_o(j\omega) \cdot W_p(j\omega)} \right|^2 \cdot \frac{1}{\omega^2} d\omega, \quad (2.6)$$

Численные процедуры поиска оптимальных настроек регулятора, отвечающих минимуму квадратичного интегрального критерия, могут быть организованы как с использованием формул 2.5, 2.6, так и непосредственно по имитационной модели.

Отсутствие инвариантности приводит к определенным неудобствам при использовании таких критериев в задачах анализа и синтеза систем регулирования. В связи с этим целесообразно иметь критерий реальной инвариантности, которому лучше всего удовлетворяет линейный интегральный критерий [49, 50], представляющий собой простое значение интеграла от отклонения регулируемой величины в переходном процессе:

$$I_{\text{л}} = \int_0^{\infty} y(t)dt \rightarrow \min$$

В отличие от I_k и $I_{\text{м}}$, линейный интегральный критерий не имеет экстремума в пространстве настроечных параметров регулятора и может использоваться лишь при введении ограничения на запас устойчивости, гарантирующего затухание собственных колебаний системы. Минимуму критерия $I_{\text{л}}$ в пространстве настроечных параметров соответствует точка $(k_p/T_u)_{\text{max}}$, находящаяся на границе области заданного запаса устойчивости, что справедливо как для ПИ, так и для ПИД регуляторов. Поскольку граница заданного запаса устойчивости определяется замкнутым контуром АСР, не зависящим от точки приложения возмущения, то такой критерий действительно отвечает требованиям реальной инвариантности. Другими словами, настройка по этому критерию остается неизменной при возмущениях, вносимых в любую точку АСР.

Наряду с неоспоримыми достоинствами этого критерия, такими как простота определения оптимальной настройки и его инвариантность относительно точки приложения действующих в системе возмущений, следует отметить и его очевидные недостатки. Этот критерий не имеет абсолютного экстремума и его использование возможно лишь при наличии условий, ограничивающих запас устойчивости. К тому же переходные процессы с настройками по этому критерию оказываются по качеству с точки зрения максимального отклонения, перерегулирования и длительности переходного процесса, заметно хуже, чем при других вышеупомянутых критериях при одинаковом ограничении на заданный запас устойчивости.

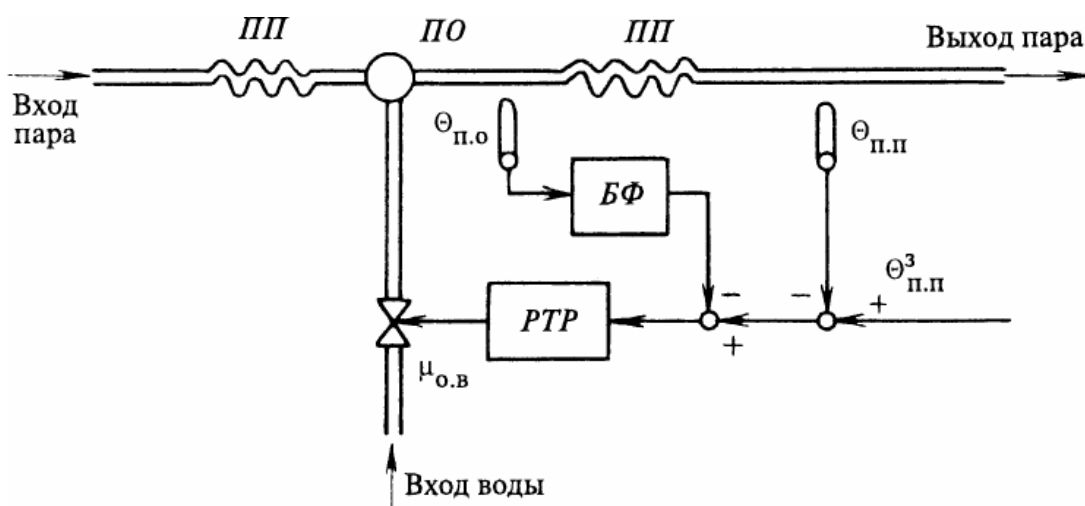
В работе проводятся расчеты на все вышеобозначенные интегральные критерии качества с целью демонстрации возможности поиска оптимальных значений настроечных параметров рассматриваемых регуляторов, а также возможности выбора того или иного критерия оптимальности в зависимости от вида помехи, присутствующей в системе регулирования, а также вида процесса ре-

гулирования, необходимого к реализации в конкретном технологическом процессе.

2.2 Численные методы расчета настроечных параметров регуляторов

2.2.1 Расчет оптимальных параметров ПИ регулятора

Для расчета оптимальных настроечных параметров регулятора необходимо получить переходный процесс объекта регулирования по каналу регулирующего органа путем проведения активного эксперимента. По полученным данным произвести параметрическую идентификацию объекта регулирования. На рисунке 2.3 показана экспериментальная переходная характеристика пароперегревателя мощного парового котла ТЭС по каналу «перемещение регулирующего органа расхода охлаждающей воды на пароохладитель» - «изменение температуры перегретого пара» в системе регулирования, рассмотренной на рисунке 2.2. Вид представленной характеристики может считаться типичным для объектов теплоэнергетических процессов с самовыравниванием.



ПО – пароохладитель,

БФ - формирующий блок, РТР – задатчик регулятора температуры

Рисунок 2.2 – Схема системы регулирования температуры перегретого пара $\Theta_{п.п.}$ за пароперегревателем ПП.




Рисунок 2.3 – Переходный процесс объекта с самовыравниванием

Передаточную функцию аппроксимирующей модели (по каналу регулирующего воздействия) для объекта регулирования можно записать в виде (2.7), переходная характеристика которого с течением времени устанавливается на некотором постоянном уровне.

$$W_O(s) = \frac{k_O \cdot \exp(-\tau_O \cdot s)}{(T_O \cdot s + 1)^n}, \quad (2.7)$$

где k_O - коэффициент усиления объекта регулирования, T_O - постоянная времени, τ_O - величина запаздывания, n – порядок объекта регулирования.

Поскольку большинство критериев, помимо линейного интегрального критерия, не удастся связать достаточно простыми аналитическими зависимостями с настроечными параметрами регулятора, то наиболее приемлемыми в этом случае остаются численные методы расчета, включая использование имитационных моделей [47, 57, 74, 76]. Для оптимизации настроечных параметров использовался эволюционный алгоритм многопараметрической многоэкстремальной оптимизации «Optim-MGA» [62].

В качестве критериев оптимальности рассматривались интегральные критерии I_L, I_k, I_M . Запас устойчивости, с целью объективного сравнения интегральных критериев, задавался в виде жесткого ограничения по частотному показателю колебательности $M=1.55$. Целевой функцией задачи оптимизации с ограничением на M являлась функция следующего вида:

$$F = \begin{cases} K \cdot \left(1 + \left| M_{зад} - A_{zc}(\omega_p) \right| \right), & \text{если } A_{zc}(\omega_p) > M_{зад} \\ K, & \text{если } A_{zc}(\omega_p) \leq M_{зад} \end{cases}$$

Для вычисления оптимальных настроечных параметров регуляторов автором были разработаны библиотеки присоединяемых программ в программном пакете MathCAD. Пример реализации одной из множества реализованных программ продемонстрирован в Приложении В. Принципиальная возможность применения библиотек присоединяемых программ продемонстрирована на рисунке 2.4., на котором жирной линией обозначены реализованные программы, тонкой линией обозначены границы этапов выбора требуемых расчетов.

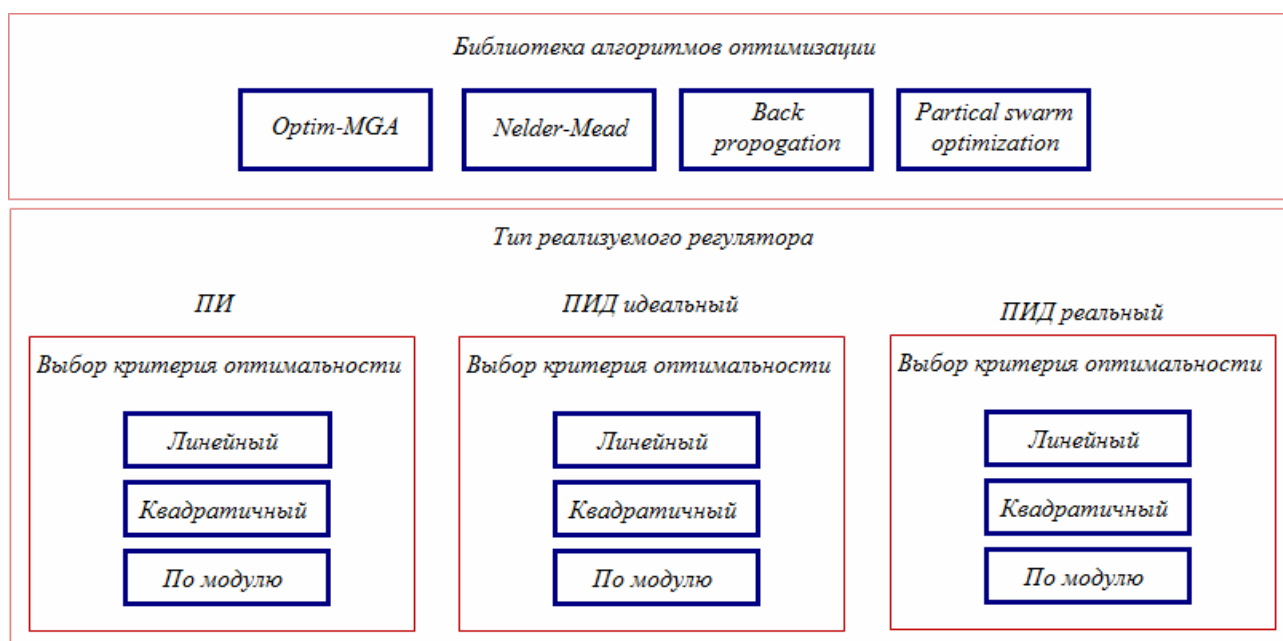


Рисунок 2.4 Реализации библиотек присоединяемых программ для расчета оптимальных настроечных параметров требуемого регулятора на выбранный критерий оптимальности

Результаты выполненных расчетов (поиск оптимальных параметров ПИ регулятора в одноконтурной системе регулирования с объектом, передаточная функция которого записывается в виде (2.7) с численными значениями параметров объекта регулирования, полученными в ходе проведения параметрической идентификации $k_O = 1.0$; $\tau_O = 2.0$ с; $T_O = 10$ с., $n = 2$.) представлены в таб-

лице 2.1. Для наглядности отображения полученных результатов для исследуемых критериев, применительно к возмущению $\lambda(t)$, были рассчитаны и построены поверхности отклика в плоскости настроечных параметров ПИ регулятора в виде линий их равного значения. На все поверхности отклика нанесена граница заданного запаса устойчивости, соответствующего показателю колебательности $M=1.55$. Полученные таким образом рисунки позволяют наглядно подтвердить оптимальность каждой точки с соответствующими настроечными параметрами.

Таблица 2.1 – Результаты поиска оптимальных настроечных параметров
ПИ регуляторов

№ точки	Критерий оптимальности	Настроечные параметры			Значения критериев оптимальности			ω_p
		k_p	T_u	k_u	I_l	$I_k \cdot 10^3$	I_m	
1	I_l	1.963	14.54	0.135	7.402	2.013	8.429	0.124
2	I_k	2.823	24.587	0.115	8.662	1.572	8.666	0.165
3	I_m	2.361	18.134	0.130	7.674	1.722	7.698	0.140

Примечания:

1. Ячейки таблицы с минимальными значениями критериев для соответствующих точек выделены темным цветом;
2. Все расчеты поиска оптимальных настроечных параметров регуляторов были выполнены на персональном компьютере в программном пакете MathCAD.

Результаты, приведенные в таблице 2.1, отражены на рисунке 2.5. В основу построения положены поверхности отклика с точками, соответствующими минимуму линейного интегрального критерия I_l (т.1), квадратичного интегрального критерия I_k (т.2) и интегрального критерия по модулю I_m (т.3). Таким образом, на рисунке 2.5,а показана поверхность отклика для критерия I_l , на рисунке 2.5,б – для критерия I_k , на рисунке 2.5,в – для критерия I_m . Из рисун-

ка 2.5 видно, что для принятых исходных данных по отношению к линейному интегральному критерию остальные интегральные критерии находятся правее и ниже на линии заданного запаса устойчивости, что соответствует более высоким значениям настроечных параметров k_p и T_u , которые и обеспечивают снижение максимального отклонения регулируемой величины, а также уменьшение ее перерегулирования.

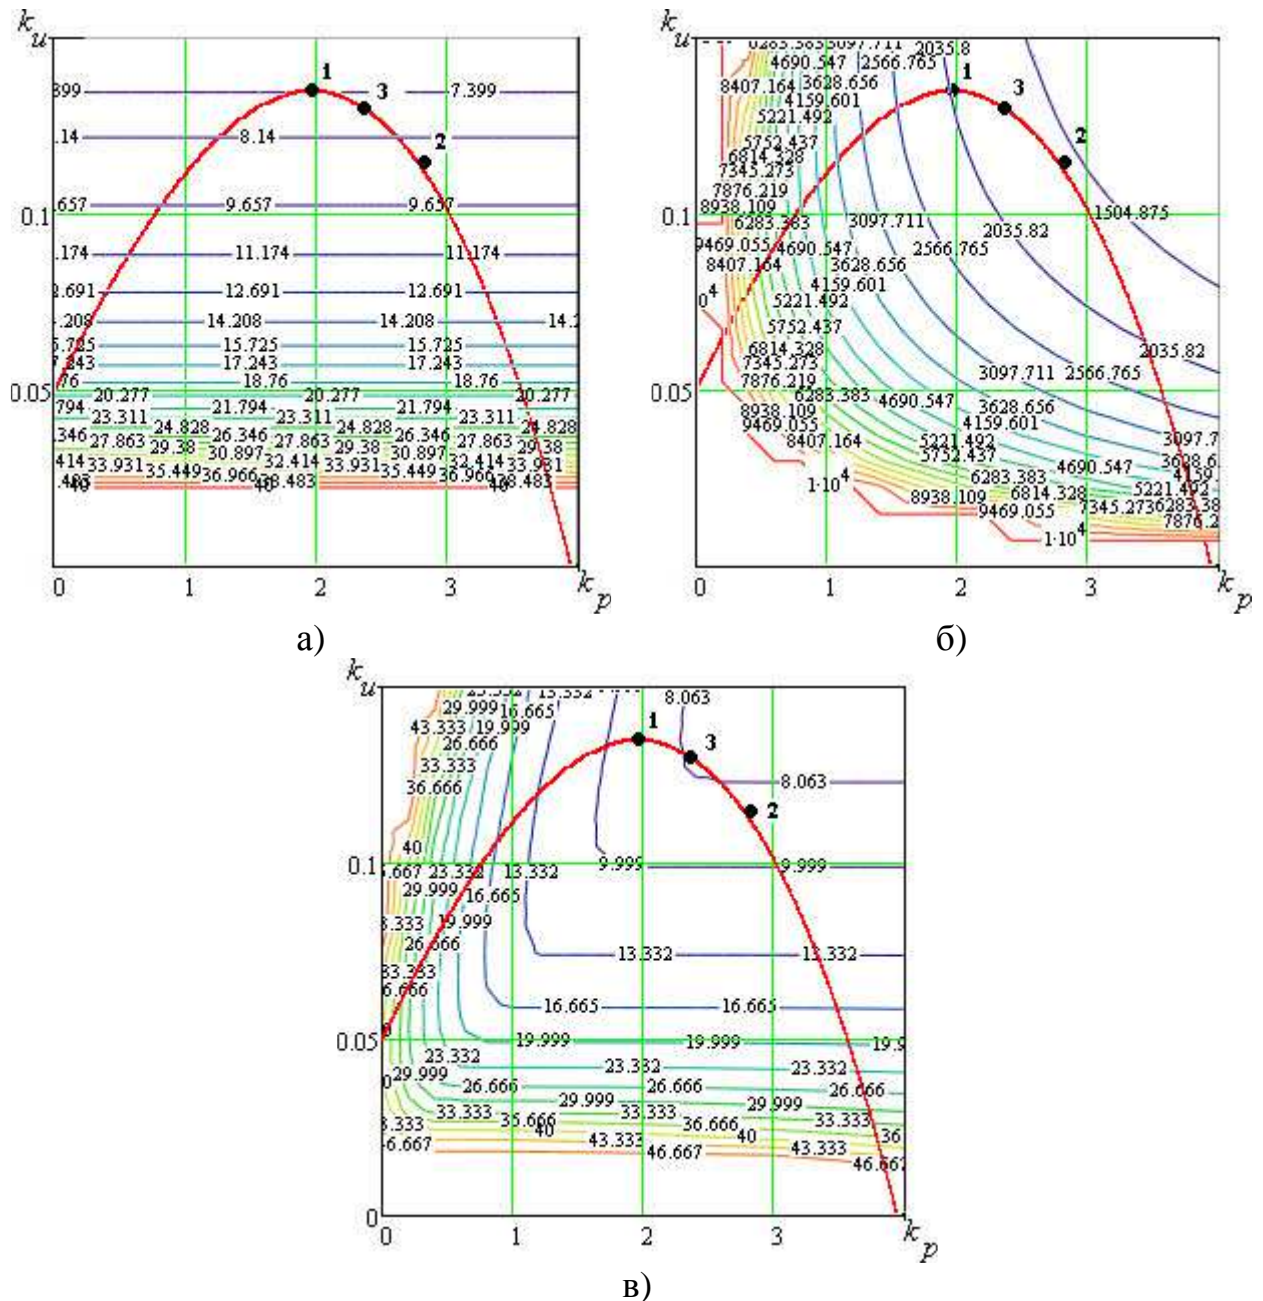




Рисунок 2.5 – Поверхности отклика с нанесенной границей заданного запаса устойчивости $M=1.55$ и точками, обеспечивающими минимум анализируемых критериев при возмущениях $\lambda(t)$


Переходные процессы для точек 1, 2 и 3 при возмущении $u(t)=1$, $\lambda(t)=1$ и соответствующие им амплитудно-частотные характеристики замкнутого контура (АЧХ) показаны на рисунке 2.6.



а)



б)



в)

1 – для критерия I_n ; 2 – для критерия I_k ; 3 – для критерия I_m .

Рисунок 2.6 – Переходные процессы при возмущении $u(t)$ (а), $\lambda(t)$ (б) и соответствующие им АЧХ замкнутого контура (в) для ПИ регулятора

2.2.2 Расчет оптимальных параметров ПИД регулятора

Запас устойчивости, также как и для ПИ регулятора, с целью объективного сравнения интегральных критериев I_l, I_m, I_k задавался в виде жесткого ограничения на частотный показатель колебательности $M=1.55$. Для оптимизации настроечных параметров использовался эволюционный алгоритм многопараметрической многоэкстремальной оптимизации «Optim-MGA» [62]. Результаты выполненных расчетов с оценкой анализируемых критериев представлены в таблице 2.2.

Таблица 2.2 – Результаты поиска оптимальных настроечных параметров ПИД регуляторов

ПИД	№ точки	Критерий оптимальности	Настроечные параметры						Значения критериев оптимальности		
			k_p	k_u	k_d	T_u	T_d	T_f	I_l	$I_k \cdot 10^3$	I_m
Идеальный	1'	I_l	8.1	1.49	44.1	5.42	5.46	-	0.67	0.067	1.38
	2'	I_k	9.0	1.40	40.3	6.40	4.51	-	0.72	0.064	1.18
	3'	I_m	9.1	1.25	37.3	7.32	4.07	-	0.80	0.067	1.13
Реальный	1''	I_l	4.7	0.68	23.1	6.94	4.98	0.62	1.48	0.244	2.87
	2''	I_k	5.2	0.61	21.1	8.41	4.25	0.53	1.63	0.227	2.47
	3''	I_m	5.4	0.53	20.3	10.28	3.73	0.47	1.88	0.232	2.27


Примечания:

1. Для реального ПИД регулятора (2.4) $n = 2$, $k_\phi = 8$;
2. Ячейки таблицы с минимальными значениями критериев для соответствующих точек выделены темным цветом;
3. Все графики на приведенных ниже рисунках для идеального и реального ПИД регуляторов для удобства визуального сравнения выполнены в одинаковых масштабах;
4. Все расчеты поиска оптимальных настроечных параметров регуляторов были выполнены на персональном компьютере в программной пакете MathCAD.

С целью наглядного отображения полученных результатов для исследуе-

мых критериев, применительно к идеальному (рисунок 2.7,а) и реальному (рисунок 2.7,б) ПИД регуляторам были реализованы программы, производящие построение линий заданного запаса устойчивости $M=1.55$ в плоскости настроечных параметров k_p , k_u при соответствующих оптимальных значениях k_D . На этих линиях показаны анализируемые точки с минимальными значениями критериев (таблица 2.2).

Точки, соответствующие оптимальным настройкам рассчитанного выше ПИ регулятора, показаны на линии $k_D=0$ (для линейного интегрального критерия I_l – точка 1, для квадратичного интегрального критерия I_k – точка 2, для интегрального критерия по модулю I_m – точка 3). Расположение точек в АСР с идеальным ПИД регулятором для тех же критериев показано под номерами 1', 2' и 3', с реальным ПИД регулятором под номерами 1'', 2'' и 3''.



а)




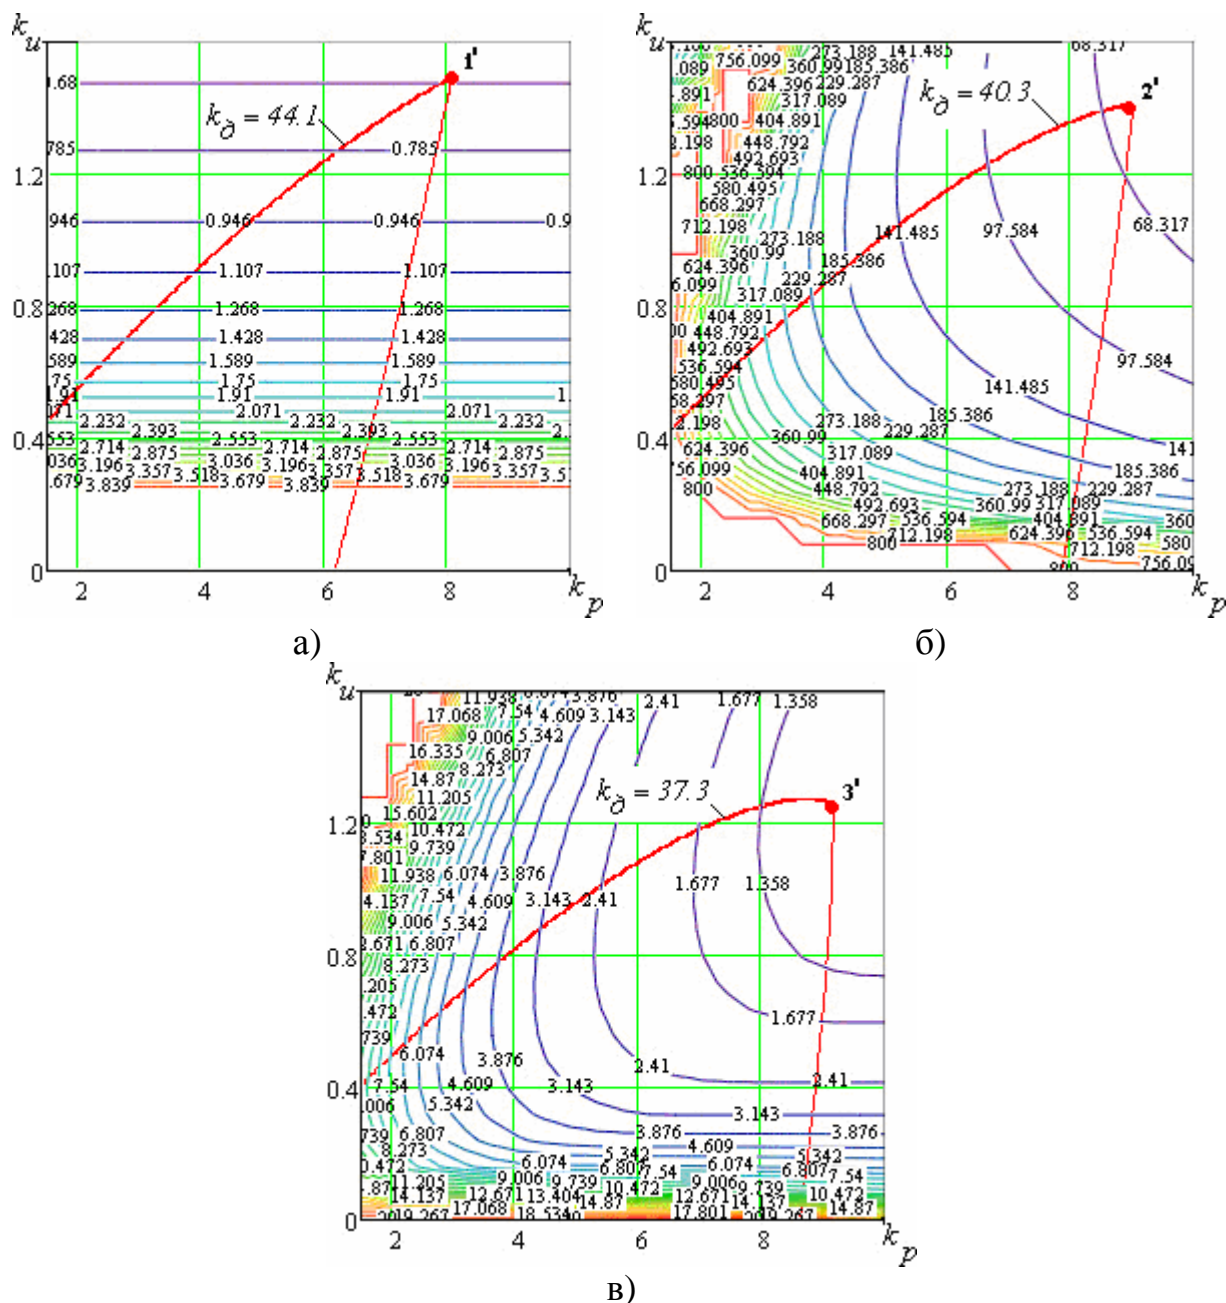
Рисунок 2.7 – Линии заданного запаса устойчивости $M=1.55$ в плоскости настроечных параметров k_p, k_u при различных значениях k_d для идеального (а) и реального (б) ПИД регуляторов

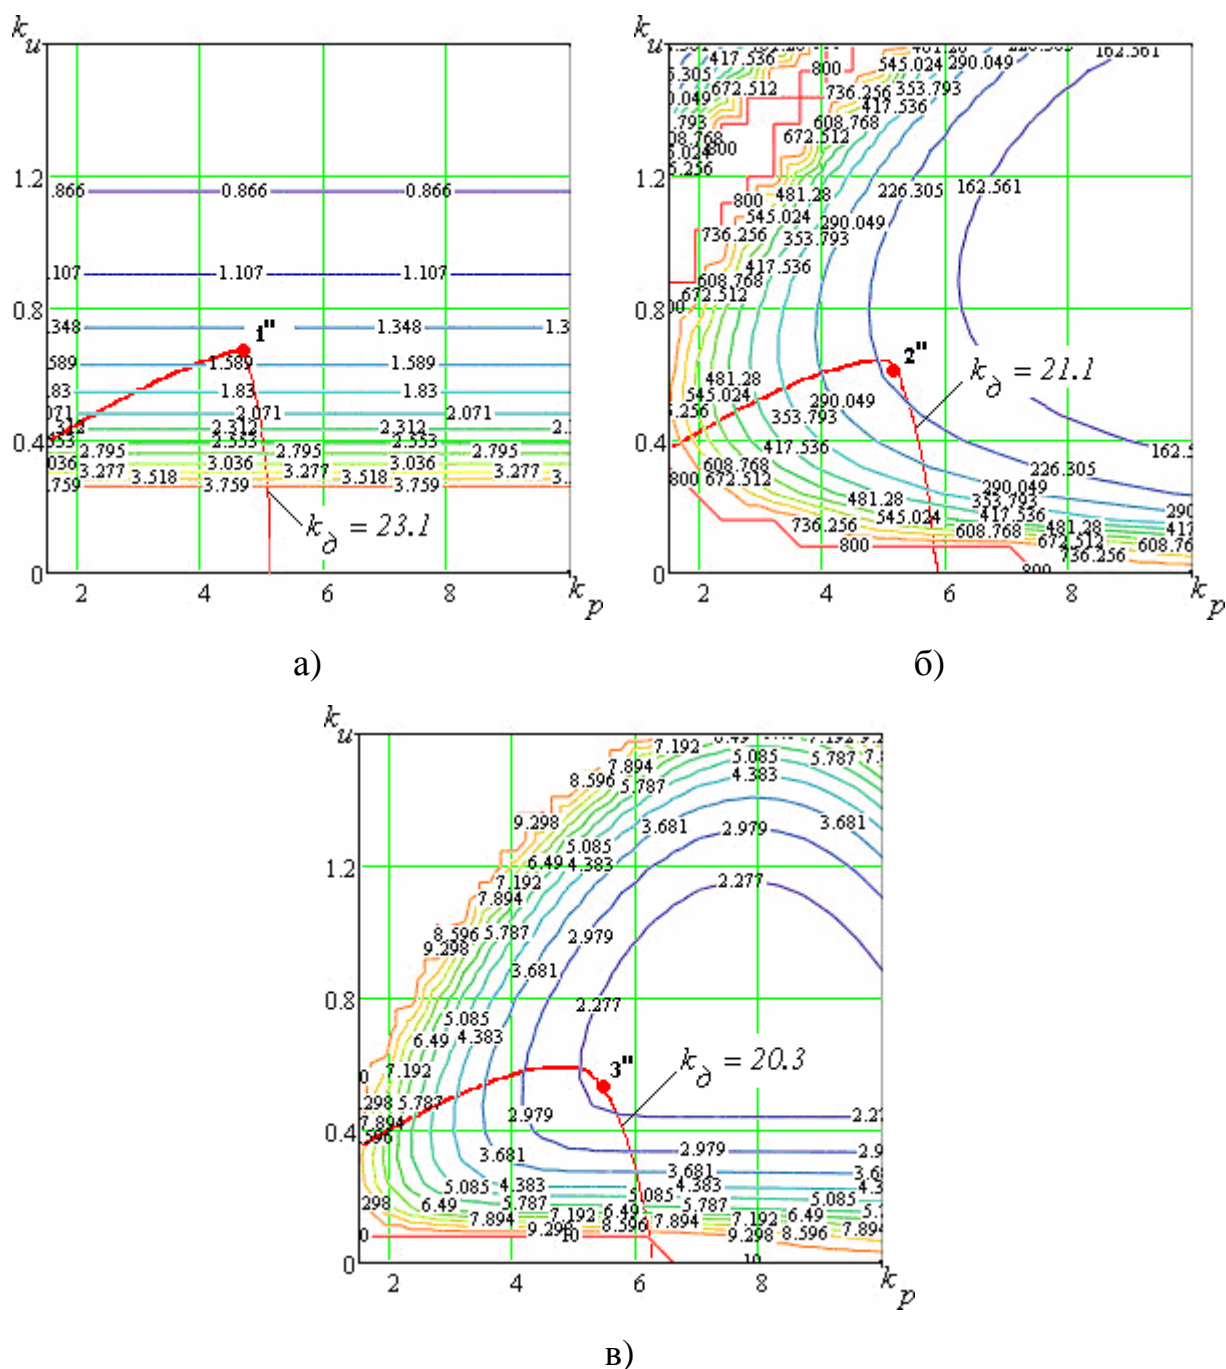
Настроечные параметры регуляторов, вычисленные на рассматриваемые критерии оптимальности, расположены достаточно близко друг к другу на плоскости параметров k_p, k_u . Анализ расположения исследуемых точек показал, что настройки по критерию I_L (1') и I_M (3') находятся на равноудаленном расстоянии от настроек по критерию I_k (2').

Для наглядного подтверждения оптимальности расположения анализируемых точек для идеального (рисунок 2.8) и реального (рисунок 2.9) ПИД регуляторов показаны поверхности отклика анализируемых критериев в плоскости настроечных параметров k_p, k_u с нанесенными линиями заданного запаса устойчивости $M=1.55$, при соответствующих оптимальных значениях k_d , а также сами точки.

Из рисунка 2.8 видно, что оптимальные точки 1' и 2' лежат на пиках соот-

ветствующих линий $M=1.55$, что подтверждается и линиями равных значений соответствующих критериев на поверхности отклика. Точка $3'$ не имеет отмеченной выше особенности и располагается правее и ниже пика линии запаса устойчивости, что также подтверждается линиями поверхности отклика.






а) критерий I_L ; б) критерий I_k ; в) критерий I_M .

Рисунок 2.9 – Поверхности отклика с нанесенной границей заданного запаса устойчивости при оптимальных k_D с оптимальными точками для реального ПИД регулятора


Относительное расположение анализируемых точек, с подтверждением их оптимальности, сохранилось и для реального ПИД регулятора (рисунок 2.9).

Настройки по критерию I_L (1'') и I_M (3'') находятся на равноудаленном расстоянии от настроек по критерию I_k (2''). Таким образом, поверхности отклика, представленные на рисунках 2.8 и 2.9 наглядно подтверждают, что настройки, найденные численным методом, как для идеального, так и для реального ПИД регулятора обеспечивают минимум принятых в расчетах критериев [66, 77].


Переходные процессы в АСР с идеальным ПИД регулятором для точек 1', 2', 3' и соответствующие им АЧХ замкнутого контура показаны на рисунке 2.10.



а)



б)




в)


1 – критерий I_l ; 2 – критерий I_k ; 3 – критерий I_m .

Рисунок 2.10 – Переходные процессы при возмущении $u(t)$ (а), $\lambda(t)$ (б) и соответствующие им АЧХ замкнутого контура (в) для идеального ПИД регулятора


Как и следовало ожидать, переходные процессы для точек 1', 2' и 3' практически совпадают, но амплитудно-частотные характеристики отличаются видом проявления резонанса: от продолжительного резонанса по критерию I_m , слабовыраженных «горбов» по критерию I_k и двух явно выраженных резонансных частот для критерия I_l .



а)



б)



в)

1 – критерий I_l ; 2 – критерий I_k ; 3 – критерий I_m .

Рисунок 2.11 – Переходные процессы при возмущении $u(t)$ (а), $\lambda(t)$ (б) и соответствующие им АЧХ замкнутого контура (в) для реального ПИД регулятора

Отмеченное выше обособленное расположение точки $3'$ для интегрального критерия I_m (правее и ниже остальных точек в плоскости настроечных параметров) соответствует более высоким значениям k_p и T_u , которые и обеспечивают заметное уменьшение площади под переходным процессом (при этом сам процесс регулирования становится близким к аperiodическому). Отмеченная тенденция для переходных процессов и АЧХ замкнутого контура сохраняется и для реального ПИД регулятора (рисунок 2.11).

2.3 Выводы

1. Перед расчетом оптимальных настроечных параметров регулятора, необходимо сформулировать цель и критерии качества регулирования. Традиционно основные качественные показатели формируются исходя из требований к форме реакции замкнутой системы на ступенчатое возмущение по каналу регулирующего органа или по каналу задания.
2. Для других передаточных функций объекта регулирования и параметров объекта, отличных от приведенных выше, численные результаты будут отличаться от полученных в проведенном исследовании, однако общая тенденция должна сохраняться [66, 67].
3. Предлагаемая методика настройки регуляторов численными методами, с помощью алгоритма многоэкстремальной оптимизации, позволит на стадии проектирования подобных систем регулирования проводить структурный анализ с выдачей рекомендаций как по алгоритмам используемых регуляторов, так и по их оптимальным настройкам.
4. Разработана библиотека присоединяемых программ, позволяющих численным методом, с помощью алгоритма оптимизации, производить расчет оптимальных настроечных параметров, как ПИ так и ПИД регуляторов на заданный частотный показатель запаса устойчивости для объектов с самовыравниванием (2.7).
5. В главе продемонстрированы возможности численных методов для поиска оптимальных настроечных параметров регуляторов при минимизации переходных процессов по интегральным критериям качества. В качестве критериев оптимальности также возможен выбор компромиссных интегральных критериев, минимального времени переходного процесса, максимального перерегулирования, количества срабатываний исполнительного механизма и т.д.).

ГЛАВА 3

СИНТЕЗ НЕЙРОСЕТЕВЫХ КОМПОНЕНТ СИСТЕМЫ АДАПТИВНОГО УПРАВЛЕНИЯ

Часть систем адаптивного управления реализует адаптацию с активной идентификацией объекта. В работе [46] предложен метод настройки систем регулирования с помощью поисковых методов глобальной оптимизации. Несмотря на свою эффективность, такой подход имеет ряд недостатков, самыми существенными из которых являются относительно большое время расчета и стохастический характер работы алгоритма оптимизации.

Первый недостаток не является сколько-нибудь существенным, что ограничивало бы внедрение глобальных методов оптимизации на практике. Это обусловлено тем, что скорость изменения характеристик объекта регулирования, как правило, значительно меньше скорости адаптации. Второй недостаток, связанный со стохастическим характером работы алгоритма оптимизации, является более существенным. Как показала практика, при повторных вычислениях одной и той же задачи, результат оказывается “разбросанным” в пределах заданной точности решения. Кроме того, при моделировании замкнутой системы регулирования с помощью численных методов поверхность отклика целевой функции становится более неровной по сравнению с аналитическими методами. В этом случае повышается вероятность того, что результат может оказаться в локальном экстремуме. С учетом отмеченного, в реальных адаптивных системах, реализованных с помощью программно-технических средств, желательно располагать функциональной зависимостью между настроечными параметрами регулятора и параметрами объекта регулирования.

В исследовании, в качестве передаточной функции объекта регулирования, была выбрана аппроксимирующая модель вида 2.7 со значениями $n=1\div 3$. Попытки создания регрессионных моделей первого и второго порядков для выяв-

ления зависимости не привели к решению поставленной задачи (погрешность воспроизведения настроечных параметров регуляторов могла достигать 90%), поэтому было принято решение произвести синтез нейросети на вход которой подаются параметры объекта регулирования, определенные на этапе параметрической идентификации, а на выходе ИНС воспроизводятся оптимальные настроечные параметры регулятора, обеспечивающие требуемое качество регулирования при соблюдении ограничения на заданный частотный показатель колебательности. На этапе параметрической идентификации объекта регулирования предлагается также использовать искусственную нейронную сеть.

В главе затрагиваются вопросы выбора архитектур нейросетей, производящих параметрическую идентификацию объекта регулирования и нейросетей адаптации, воспроизводящих оптимальные параметры реализуемых регуляторов, приемы формирования обучающих выборок для их обучения, а также вопросы, связанные с их практической реализацией.

Искусственная нейронная сеть представляет собой математическую модель, построенную по принципу организации и функционирования биологических нейронных сетей - сетей нервных клеток живого организма. Сеть искусственных нейронов представляет собой высокоэффективную, комплексную, нелинейную, параллельную систему обработки информации [106]. Применение аппарата нейронных сетей для решения различных задач науки и техники обусловлено большими потенциальными возможностями этих технологий [10, 11, 19, 68, 69, 90, 106]. Нейросети могут использоваться для поиска закономерностей, шаблонов данных, представленных выборкой данных, в задачах прогнозирования, кластеризации, распознавания образов, моделирования и т.д. С математической точки зрения нейронные сети относятся к классу гибких нелинейных регрессионных моделей [7, 24], обладая способностью к выявлению сложных нелинейных отношений в данных, нейросети способны организовать быстрое и эффективное восприятие и распознавание образов [9, 44, 71, 109].

3.1 Особенности синтезируемой адаптивной АСР на базе нейросетевых компонент идентификации и адаптации

3.1.1 Структура предлагаемой адаптивной АСР

Априорная динамика объекта регулирования, принятая на стадии проектного синтеза АСР, может заметно отличаться от реальной. Поэтому при вводе системы регулирования в эксплуатацию наладчик старается заглубить настроечные параметры регулятора с целью получения более глубокого запаса устойчивости, пренебрегая при этом, с одной стороны, потерями качества, а с другой стороны, возможностями математического аппарата теории автоматического управления. В простейшем случае настройки регулятора выставляются итерационно, с постепенным увеличением пропорциональной составляющей регулятора и уменьшением постоянной времени интегрирования до того момента, пока, по субъективным представлениям наладчика, переходный процесс регулирования не станет удовлетворительным. При этом дифференциальная составляющая регулятора практически исключается.

В сложившейся ситуации предлагаемая автором адаптивная АСР (рисунок 3.1) способна производить активный эксперимент в разомкнутом контуре системы регулирования с параметрической идентификацией объекта в широком диапазоне изменения его параметров с последующим воспроизведением оптимальных настроечных параметров реализуемого регулятора. Применение параметрической идентификации объекта регулирования в разомкнутом контуре безусловно снижает качество определения параметров объекта регулирования по сравнению с проведением данной процедуры в замкнутом контуре. Преимуществом предлагаемой структуры адаптивной АСР стоит считать простоту методики проведения активного эксперимента и возможность проведения как однократного возмущения, так и серии экспериментов с получением ансамбля реализаций и последующим их усреднением для получения оценки переходной характеристики объекта регулирования.

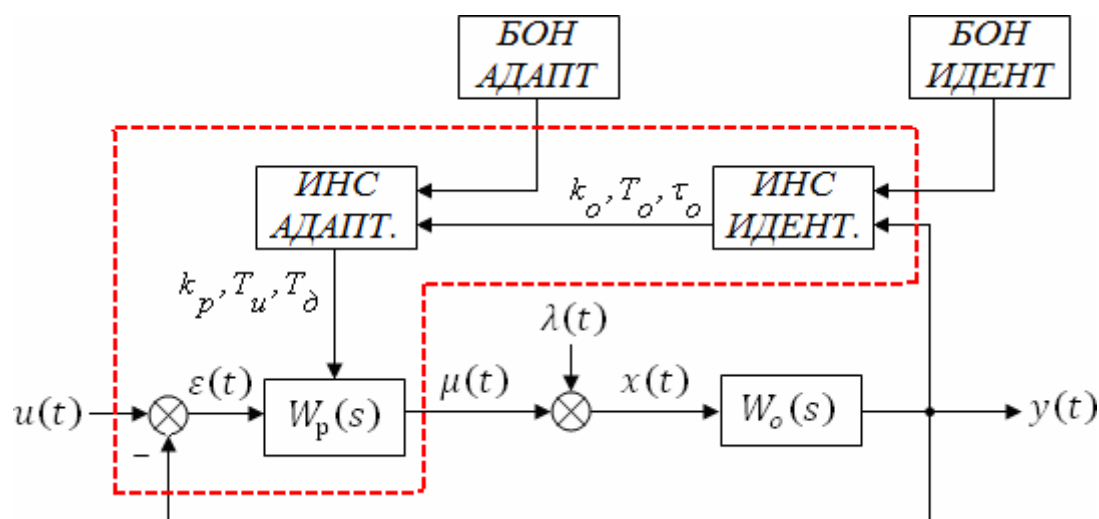


Рисунок 3.1 – Структурная схема адаптивной АСР

Предлагаемая адаптивная АСР состоит из следующих блоков:

БОН ИДЕНТ. – блок обучения нейросети идентификации;

ИНС ИДЕНТ. – искусственная нейросеть идентификации, реализующая функциональную зависимость ординат переходного процесса и его импульсной переходной характеристики с параметрами объекта регулирования выбранной модели идентификации;

БОН АДАПТ. – блок обучения нейросети адаптации;

ИНС АДАПТ. – искусственная нейросеть, реализующая функциональную зависимость, связывающую настроечные параметры реализуемого регулятора с параметрами идентифицированной модели объекта.

Часть блоков реализуется непосредственно в циклических задачах программируемого логического контроллера (на рисунке 3.1 обведено пунктирной линией). При этом блоки обучения соответствующих ИНС реализуются на персональном компьютере, при подключении которого к ПТК АСУ ТП может производиться корректировка весовых коэффициентов нейросетей, реализованных в ПЛК.

Блоки обучения нейросетей идентификации и адаптации, созданные автором, реализованы в виде пользовательских программ, которые можно условно поделить на этапы их применения. Каждый этап реализован в виде самостоятельной библиотеки программных реализаций, вызываемый при необходимости

сти того или иного расчета. Разработанные библиотеки включают в себя следующие программные реализации:

Для нейросети адаптации:

- проведение серии полных факторных экспериментов с различными коэффициентами интервалов варьирования и запись соответствующих результатов в тренировочное множество для обучения нейросети;
- дополнение тренировочного множества расчетами соответствующих оптимальных настроечных параметров регуляторов на заданный показатель запаса устойчивости с выбранным критерием оптимальности для каждого набора тренировочных данных;
- обучение нейросети созданным на предыдущих двух этапах тренировочным множеством;
- проверка обученной нейронной сети на воспроизведение тренировочного и тестового множеств.

Для нейросетей идентификации:

- проведение серии полных факторных экспериментов с различными коэффициентами интервалов варьирования, определение количества реперных точек для обучения нейросети и их представление в виде обучающего множества;
- обучение нейросети созданным на предыдущем этапе тренировочным множеством;
- проверка обученной нейронной сети на воспроизведение тренировочного и тестового множеств.

3.1.2 Процедуры идентификации и адаптации в составе адаптивной АСР

На этапе первоначального ввода системы регулирования в эксплуатацию производится выбор структуры модели объекта и осуществляется параметрическая идентификация объекта регулирования. По окончании идентификации по-

лученные коэффициенты принимаются в качестве базовых при формировании обучающих выборок для исследуемых нейросетей. Блок-схема алгоритма формирования обучающих выборок и обучения нейросетей, входящих в адаптивную АСР, приведена на рисунке 3.2.

Блок идентификации включается в работу по требованию персонала (предполагается, что перед включением режима параметрической идентификации персонал создает благоприятные условия для проведения активного эксперимента, такие как стационарность регулируемой величины, отсутствие переходных режимов во время эксперимента и т.д.), после чего происходит проведение активного эксперимента в разомкнутой АСР с нанесением ступенчатого возмущения по каналу регулирующего органа (изменение положения РО). В ходе проведения эксперимента происходит автоматическая коррекция параметров модели объекта регулирования.

Принятая на стадии идентификации математическая модель объекта будет считаться удовлетворительной, если при подаче на вход системы с действительным объектом и системы с моделью объекта одного и того же воздействия разность их выходных величин окажется достаточно малой. Критерий идентификации формируется в виде интеграла разности выходов реального объекта и его модели, взятых по модулю.

После того, как параметры для принятой структуры математической модели объекта будут определены, осуществляется следующий шаг алгоритма создания адаптивной АСР, настройки поступают в блок обучения нейросети адаптации.

Блок адаптации, включающий в себя нейронную сеть, предварительно обученную на воспроизведение оптимальных параметров реализуемых регуляторов, производит мгновенный расчет настроенных параметров и передает вычисленные параметры на входы функционального блока регулятора.

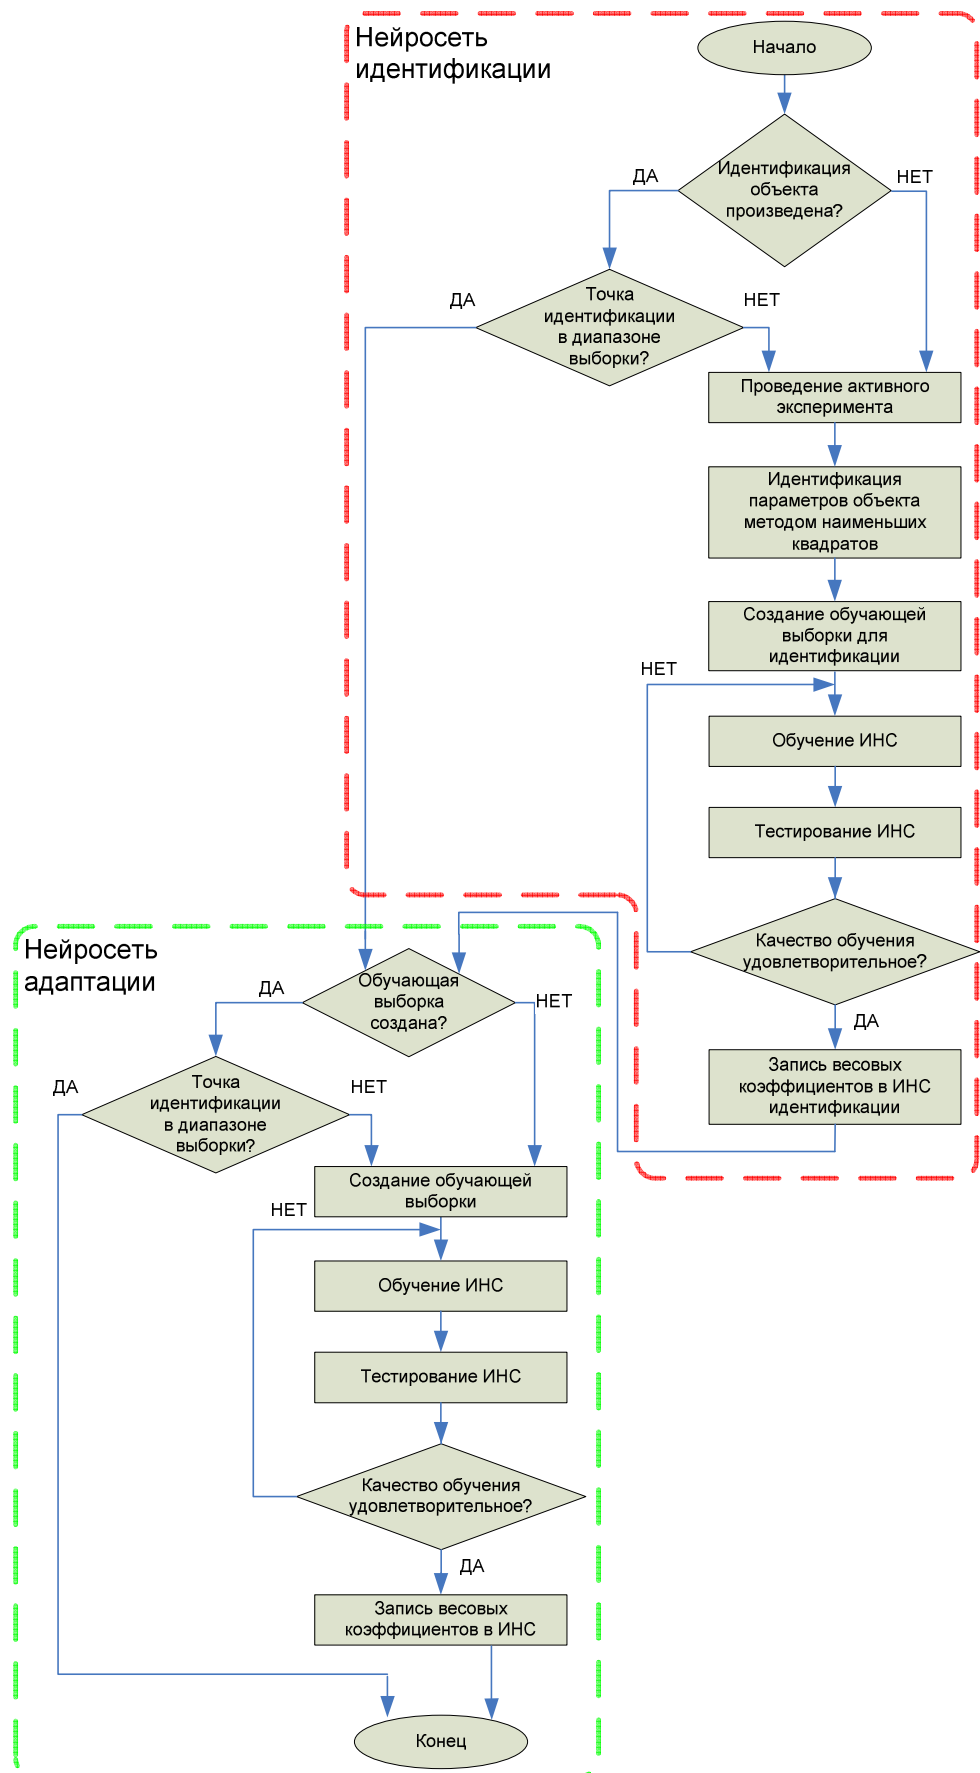


Рисунок 3.2 – Блок-схема алгоритма обучения и настройки нейросетей в составе адаптивной АСР

3.1.3 Поэтапный синтез предлагаемой адаптивной АСР

В создании адаптивной АСР можно выделить 5 основных этапов реализации:

- 1) Проведение активного эксперимента непосредственно на технологическом объекте
 - а) анализ переходного процесса объекта регулирования;
 - б) выбор аппроксимирующей модели идентификации объекта;
 - в) параметрическая идентификация объекта регулирования.
- 2) Синтез нейросети параметрической идентификации
 - а) анализ требуемого объема обучающей выборки в зависимости от возможных изменений свойств объекта регулирования;
 - б) создание тренировочного множества с применением теории планирования эксперимента;
 - в) обучение нейросети идентификации;
 - г) проверка качества обучения нейросети.
- 3) Синтез адаптивной нейросети
 - а) создание обучающей выборки с применением теории планирования эксперимента для тренировки нейросети адаптации с коэффициентами интервалов варьирования, принятых на стадии формирования обучающих выборок для нейросети идентификации;
 - б) обучение нейросети;
 - в) проверка качества обучения.
- 4) Имитационное моделирование адаптивной АСР в эмуляторе контроллера. Оценка качества воспроизведения варьируемых параметров объекта регулирования нейросетью идентификации и воспроизведение соответствующих оптимальных настроечных параметров реализуемого регулятора нейросетью адаптации.
- 5) Реализация адаптивной АСР в программируемом логическом контроллере на реальном объекте
 - а) проведение активного эксперимента с помощью реализованных ком-

- понент нейросетевой идентификации и адаптации;
- б) выбор критерия оптимальности и частотного показателя колебательности для текущего состояния объекта регулирования;
- в) оценка качества регулирования настроенной АСР.

Для вычисления оптимальных синаптических весов синтезируемых нейросетей автором были разработаны библиотеки присоединяемых программ в программном пакете MathCAD. Пример реализации одной из множества реализованных программ продемонстрирован в Приложении Д. Принципиальная возможность применения библиотек присоединяемых программ продемонстрирована на рисунке 3.3, на котором жирной линией обозначены реализованные программы, тонкой линией обозначены границы этапов выбора требуемых расчетов.

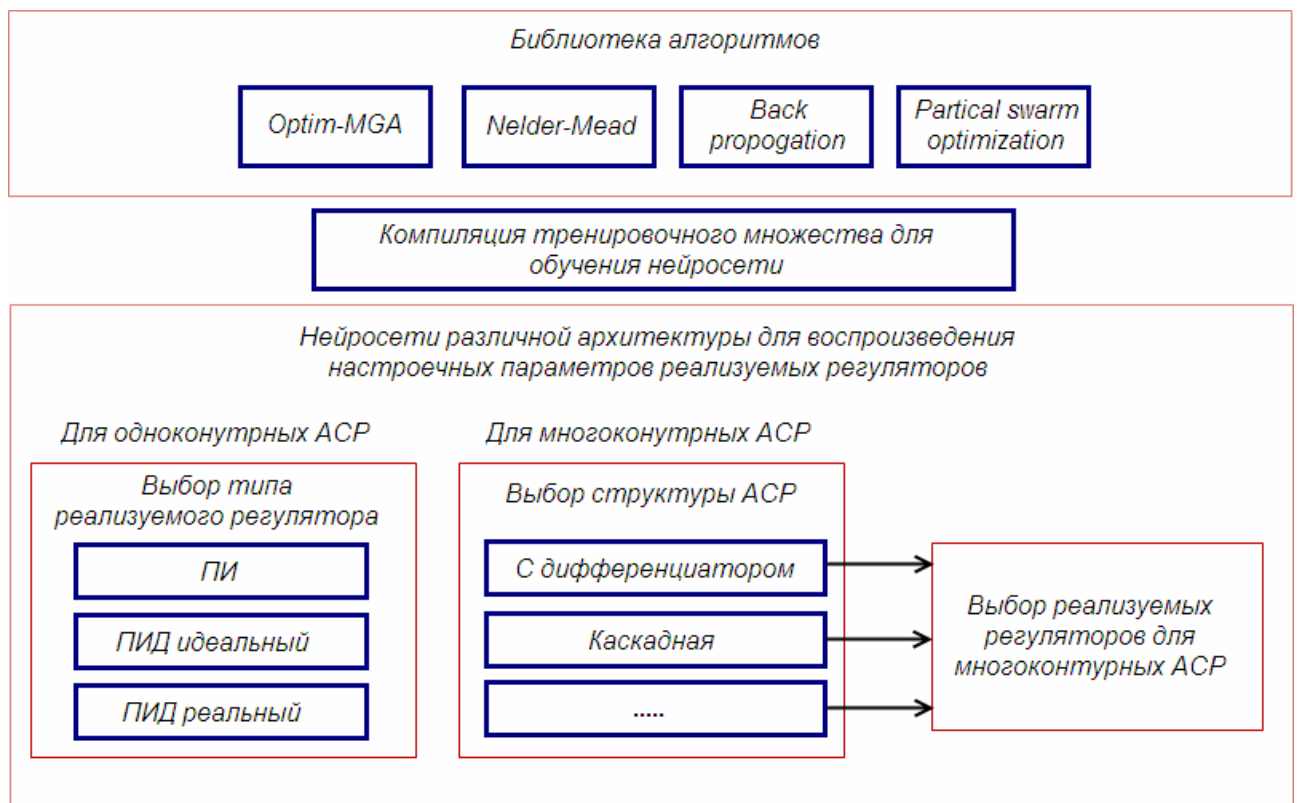


Рисунок 3.3 – Реализации библиотек присоединяемых программ для расчета синаптических весов синтезируемых нейросетей для воспроизведения оптимальных настроечных параметров реализуемых регуляторов

3.2 Синтез нейросети параметрической идентификации объекта регулирования

Реакцией системы регулирования на единичное ступенчатое возмущение является её переходная характеристика. Для получения переходной характеристики необходимо установить равновесный режим работы исследуемой системы, после чего нанести ступенчатое возмущение и зарегистрировать график вызванного таким воздействием изменения выходной величины.

После получения переходной характеристики объекта управления необходимо идентифицировать его параметры для расчета оптимальных параметров настройки регулятора. Некоторые существующие методы настройки регуляторов предлагают идентификацию объекта инерционным звеном первого порядка [21, 83], иные ссылаются на более сложные структуры [23, 46, 82]. Следует отметить, что производить выбор модели идентификации требуется непосредственно после проведения активного эксперимента, в зависимости от динамики объекта регулирования.

Исследования показывают, что в большинстве случаев наиболее приемлемой для объектов с самовыравниванием [64] оказывается аппроксимирующая модель в виде двух последовательно соединенных апериодических звеньев и звена транспортного запаздывания. Такая относительно загрубленная аппроксимация позволяет снизить чувствительность АСР по сравнению с настройками, полученными по моделям более высокого порядка.

Основными предпосылками для реализации нейросети параметрической идентификации объекта регулирования непосредственно в ПЛК послужили:

- а) постоянная необходимость наличия персонального компьютера, позволяющего производить подключение к ПЛК;
- б) необходимость проведения ряда процедур для получения параметров объекта регулирования (использование специализированного ПО или построение касательных и отрезков вручную по полученным реализациям).

Следует отметить, что процедура проведения активного эксперимента для обучения нейросети и процедура идентификации параметров объекта регулирования обученной нейросетью имеют принципиальные различия. В первом случае все действия проводятся с использованием персонального компьютера (происходит анализ объекта регулирования, определяется вид аппроксимирующей модели, анализируется время переходного процесса, определяется шаг дискретности данных, поступающих на вход ИНС, выбирается количество нейронов во входном и скрытом слоях нейросети, происходит обучение ИНС), во втором случае наличие ПК не требуется, т.к. все действия по идентификации происходят обученной нейросетью, реализованной в виде пользовательского функционального блока в ПЛК.

Для синтеза нейросети, способную решать поставленную задачу, необходимо:

- определить количество и объем данных, поступающих на входы нейросети;
- определить количество данных, рассчитываемых нейросетью (зависит от вида выбранной передаточной функции объекта регулирования);
- выбрать архитектуру сети;
- обучить нейросеть.

В рассматриваемом синтезе ИНС происходит обучение с учителем, которое подразумевает настройку параметров нейронной сети таким образом, чтобы отклик сети при заданном внешнем воздействии как можно меньше отличался от желаемого отклика.

3.2.1 Формирование тренировочного множества для обучения нейросети

Параметры объекта регулирования k_o, T_o, τ_o , полученные на этапе параметрической идентификации, представляются центром проведения полного факторного эксперимента. Планирование эксперимента производится в трех-

мерной системе координат на двух уровнях, обеспечивающих ортогональность матрицы планирования. Автором предлагается в зависимости от способности объекта изменять внутренние свойства расширять или сужать интервалы варьирования Δx_i с помощью специально введенного коэффициента k :

$$\Delta x_i = x_{i0} \cdot k,$$

$$x_{iH} = x_{i0} - \Delta x_i,$$

$$x_{iB} = x_{i0} + \Delta x_i,$$

где x_{i0} – базовая точка, k – коэффициент интервала варьирования, Δx_i – интервал варьирования, x_{iH} и x_{iB} нижние и верхние уровни факторов.

После анализа переходного процесса можно с определенной вероятностью полагать, что искомые параметры объекта регулирования могут претерпевать изменения в определенной степени. Исходя из априорных знаний о теплоэнергетических объектах, можно предполагать, что изменение параметров k_o, T_o, τ_o более чем на 50% от полученных при проведении активного эксперимента маловероятно, поэтому закладывать чрезмерную избыточность при обучении нейросети не представляется необходимым.

В случае если возможно значительное изменение внутренних свойств объекта регулирования возможно проведение не одного, а серии полных факторных экспериментов, в каждом из которых коэффициент интервала варьирования следует принимать отличным от предыдущего (0.1, 0.25 и 0.5, например). Автором в проведенных исследованиях демонстрируется принципиальная возможность обучения нейросетей на большие диапазоны обучающих данных. Таким образом, количество наборов данных Z для обучения ИНС можно рассчитать по формуле:

$$Z = 2^x \cdot F,$$

где x – количество варьируемых параметров объекта регулирования, F – количество факторных экспериментов с различными коэффициентами интервалов варьирования, участвующих в формировании обучающей выборки.

Все полученные реализации переходных процессов и соответствующих им импульсных переходных характеристик (рисунок 3.4) обрабатываются на следующем этапе формирования обучающей выборки.

3.2.2 Определение достаточного количества обучающих данных для воспроизведения параметров объекта регулирования

Для параметрической идентификации объекта регулирования нет необходимости подавать на вход нейросети все значения переменной переходного процесса – это может привести к неоправданному увеличению времени расчета оптимальных синаптических весов нейросети, а также зависимости воспроизводимых параметров от помех и случайных возмущений, поступающих на объект во время проведения активного эксперимента. Малое же количество значений переменной может неправильно сформировать синаптические веса нейросети, которая, в свою очередь, не сможет должным образом распознать необходимую зависимость воспроизведения параметров объекта регулирования от значений ординат промежуточных точек переходного процесса и импульсной переходной характеристики объекта регулирования (условимся далее называть точки для обучения нейросети реперными).

Количество реперных точек, входящих в обучающую выборку, для воспроизведения каждого параметра объекта регулирования должно определяется видом переходного процесса. Процедура определения достаточного количества реперных точек для обучения нейросети носит итерационный характер (рисунок 3.5). Как показали исследования, проведенные автором, для передаточной функции вида (2.7) с различными $n=1-3$, с типичным для теплоэнергетических объектов видом переходного процесса, достаточным является использование 11, стоящих через равные промежутки времени, реперных точек переходного процесса и импульсной переходной характеристики.




Рисунок 3.4 – Проведение ПФЭ и построение графиков переходных процессов и соответствующих им импульсных переходных характеристик для коэффициента интервала варьирования $k=0.5$

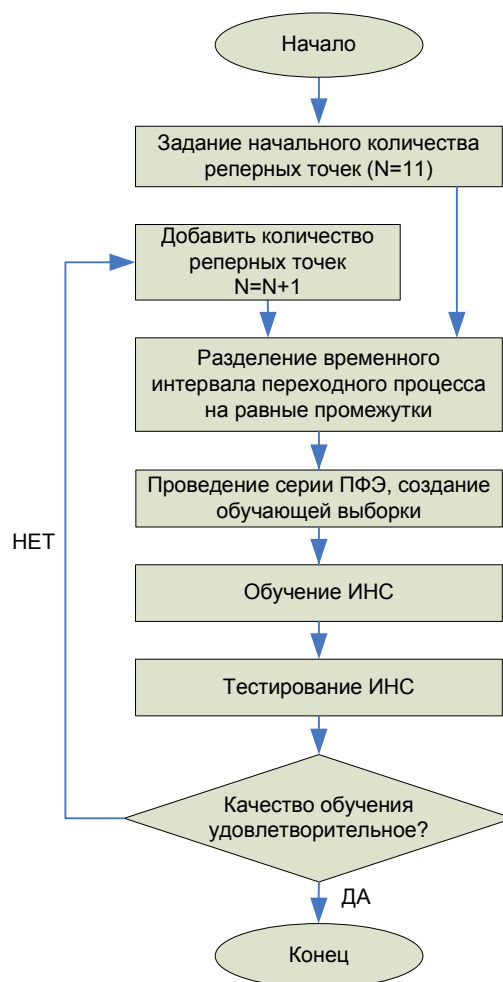


Рисунок 3.5 – Блок-схема алгоритма выбора количества реперных точек для параметрической идентификации объекта регулирования

Для определения интервалов расположения реперных точек на переходных процессах и импульсных переходных характеристиках необходимо выбрать ПФЭ с максимальным коэффициентом интервала варьирования $k=\max$, выбрать переходный процесс с минимальным значением коэффициента усиления объекта регулирования $k_o=\min$ и максимальным значением постоянной времени $T_o=\max$ (на рисунке 3.6 показан толстой линией). Для данного переходного процесса построить касательную и определить абсциссу точки пересечения касательной с установившимся значением переходного процесса. Полученное значение округлить до целого числа, кратного 10. Нанести 11 реперных точек через 10 равных промежутков времени на каждый переходный процесс и каж-

дую импульсную характеристику всех реализованных в тренировочном множестве значений параметров объектов регулирования (рисунок 3.7).




Рисунок 3.6 – Пояснение к определению интервала расположения реперных точек для определения постоянной времени объекта регулирования

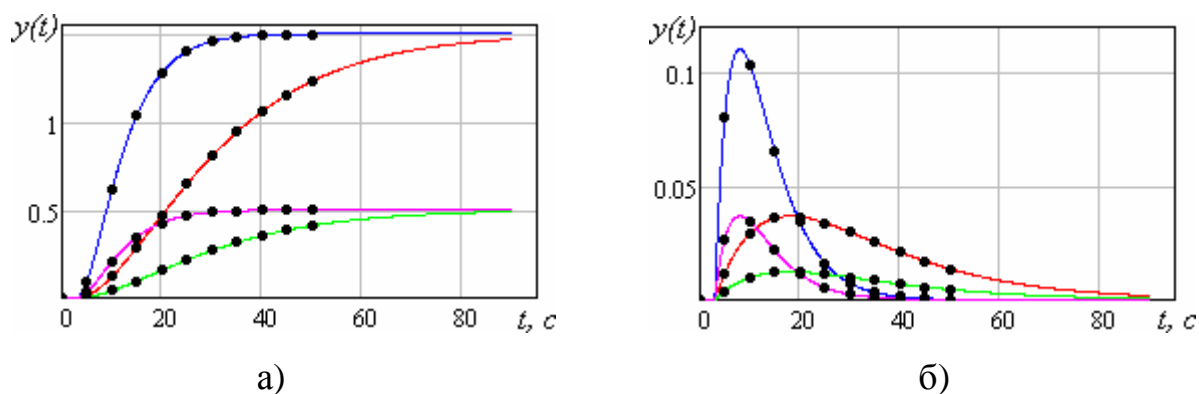


Рисунок 3.7 – Переходные процессы (а) и соответствующие им импульсные переходные характеристики (б) с нанесением реперных точек через равные промежутки времени для определения постоянной времени объекта регулирования

Как видно из рисунка 3.6 для определения постоянной времени объекта регулирования требуется располагать информацией практически всей реализации переходного процесса, для определения запаздывания, напротив, наибольшую

ценность представляет начало полученной реализации. Таким образом, для определения величины τ_0 необходимо также определить количество реперных точек по полученным ансамблям переходных процессов.

Исследования, проведенные автором, для объектов с различной динамикой переходных процессов, позволяют производить обучение нейросети на воспроизведение τ_0 должным образом с количеством реперных точек равному трехкратному округленному до целого значения величины запаздывания.

Для определения запаздывания процедуру выбора количества реперных точек можно считать аналогичной, за тем исключением, что нет необходимости строить касательные к графику переходного процесса. Величину запаздывания, полученную в ходе идентификации необходимо округлить до целого числа и умножить на 3, получив, таким образом, количество реперных точек, необходимое для идентификации обозначенного параметра с момента начала проведения эксперимента (рисунок 3.8). Значение временного интервала для расположения реперных точек принимается равным 1 с., как наиболее часто используемое время в качестве частоты дискретизации записи трендов в журнал архивных данных.




Рисунок 3.8 – Переходные процессы (а) и соответствующие им импульсные переходные характеристики (б) с нанесением реперных точек через равные промежутки времени для определения запаздывания объекта регулирования

Таким образом, значения ординат, нанесенных на графики реперных точек, для определения постоянной времени объекта регулирования и величины запаздывания будут представлять собой набор тренировочных данных для обучения нейросети.

Обучающая выборка, состоящая из одного полного факторного эксперимента с варьированием всех параметров идентифицируемой модели, продемонстрирована в таблице 3.1. В левой части таблицы представлены параметры объектов регулирования, по которым по известной передаточной функции объекта регулирования происходит построение переходных процессов и импульсных переходных характеристик. В правой части таблицы указаны ординаты реперных точек соответствующих графиков. Количество данных для обучения нейросети определяется по формуле:

$$n = (n_T + n_\tau) \cdot Z,$$

где n_T – количество равностоящих точек переходного процесса для определения постоянной времени T_O , n_τ – количество равностоящих точек переходного процесса для определения запаздывания τ_O , Z – количество наборов данных для обучения ИНС.

Таблица 3.1 – Обучающая выборка для тренировки нейросети идентификации

Параметр, воспроизводимый ИНС	№	Точки обучения ИНС (П – переходный процесс, Д – производная)							
		1		2		...		8	
		П	Д	П	Д	П	Д
T_O	1	yI_1	$yI_{\text{диф } 1}$	yI_2	$yI_{\text{диф } 2}$	yI_8	$yI_{\text{диф } 8}$
	2	$y2_1$	$y2_{\text{диф } 1}$	$y2_2$	$y2_{\text{диф } 2}$	$y2_8$	$y2_{\text{диф } 8}$

	n	yn_1	$yn_{\text{диф } 1}$	yn_2	$yn_{\text{диф } 2}$	yn_8	$yn_{\text{диф } 8}$
τ_O	1	$\tau a u I_1$	$\tau a u I_{\text{диф } 1}$	$\tau a u I_2$	$\tau a u I_{\text{диф } 2}$	$\tau a u I_8$	$\tau a u I_{\text{диф } 8}$
	2	$\tau a u 2_1$	$\tau a u 2_{\text{диф } 1}$	$\tau a u 2_2$	$\tau a u 2_{\text{диф } 2}$	$\tau a u 2_8$	$\tau a u 2_{\text{диф } 8}$

	n	$\tau a u n_1$	$\tau a u n_{\text{диф } 1}$	$\tau a u n_2$	$\tau a u n_{\text{диф } 2}$	$\tau a u n_8$	$\tau a u n_{\text{диф } 8}$

При составлении обучающей выборки следует помнить, что значения реперных точек каждого переходного процесса являются группами чисел в различных диапазонах значений, поэтому для качественного обучения нейросети необходимо производить нормирование каждой группы ординат реперных точек в заданном диапазоне (для рассматриваемой нейросети был выбран диапазон $[0,1]$). Данный подход позволяет свести к минимуму влияние больших чисел на функцию цели обучения нейросети, а также повысить точность её обучения. Нормирование каждой группы параметров производится согласно формуле:

$$y^{норм} = \frac{\max\{y\} - y_i}{\min\{y\} - \max\{y\}} + 1, \quad (3.1)$$

где y_i – текущее значение ординаты реперной точки, $\{y\}$ – вектор значений ординат реперных точек.

3.2.3 Выбор архитектуры и обучение нейросети

Исходя из предполагаемой сложности решаемой задачи, автором производились попытки синтезировать нейросети с сигмоидальными и тангенциальными активационными функциями нейронов, варьировалось количество внутренних слоёв нейросети, увеличивался объем обучающей выборки, но все попытки синтеза не приводили к решению поставленной задачи, т.к. изначально на входы ИНС поступала только информация переходного процесса. Проанализировав ситуацию было принято решение в качестве дополнительной информации о переходном процессе получить скорость его изменения и подавать, таким образом, на входы ИНС не только данные переходного процессов, но и его производную первого порядка. Удалось синтезировать нейросеть, воспроизводящую тренировочные и тестовые множества. Одним из этапов синтеза нейросети стало упрощение её структуры, сохраняя при этом высокое качество обучения ИНС и возможность аппроксимировать ранее неизвестные для нейросети результаты. Таким образом, в ходе исследований была синтезирована неполно-

связная (слоистая), прямонаправленная двухслойная нейронная сеть с линейными активационными функциями нейронов (рисунок 3.9).

На входы нейросети поступают значения ординат реперных точек, определенных на стадии формирования обучающей выборки.




Рисунок 3.9 – Структура нейросети идентификации параметров объекта регулирования

Общая структура нейросети имеет следующий вид:

$$\text{NN IN-H-OUT}, \quad (3.2)$$

где NN – neural network (нейронная сеть), IN (input) – количество входных нейронов, H (hidden) – количество нейронов в скрытом слое, OUT (output) – идентифицируемые параметры объекта регулирования.

Количество нейронов во входном слое ИНС равно количеству данных для обучения нейросети.

$$IN = n$$

Количество нейронов в скрытом слое равно половине нейронов входного слоя, т.к. на нейрон скрытого слоя поступает информация ординат реперных точек в текущий момент времени от переходного процесса и импульсной переходной характеристики.

Количество выходов нейросети идентификации определяется видом применяемой передаточной функции объекта регулирования. Для объекта (2.7) параметрами идентификации являются τ_o , T_o . В свою очередь определение коэффициента усиления на практике, при проведении активного эксперимента в разомкнутой АСР, не вызывает трудностей, поэтому целесообразно производить расчет k_o алгоритмически, не перекладывая эту задачу на нейросеть:

$$k_o = \frac{y_{уст} - y_{нач}}{x_{уст} - x_{нач}},$$

где $y_{уст}$, $y_{нач}$, $x_{уст}$, $x_{нач}$ – максимальные и минимальные значения входного и выходного сигналов объекта регулирования.

В качестве критерия обучения рассматриваемой нейросети, для каждого идентифицируемого параметра в отдельности, было определено следующее выражение:

$$S_x = \sum_{i=1}^n |x_i - x_i^{инс}|$$

где x_i – заданное значение параметра объекта регулирования, $x_i^{инс}$ – значение параметра объекта регулирования, найденного нейросетью, n – количество наборов данных, участвующих в обучении ИНС.

Стоит отметить, что задача обучения нейросети является многоэкстремальной, поэтому все классические методы оптимизации, основанные на градиенте целевой функции (в том числе известный алгоритм обратного распространения ошибки), не могут гарантировать нахождение наилучшего решения [6, 28, 45, 103]. Поэтому для повышения качества аппроксимации рекомендуется использовать эволюционные алгоритмы глобальной оптимизации. Самыми известными из них являются генетические алгоритмы. Для обучения нейросети идентификации использовался эволюционный алгоритм многопараметрической многоэкстремальной оптимизации «Optim-MGA» [62]. Для каждого из искомых

параметров объекта регулирования алгоритм вычисляет группы оптимальных синаптических весов в общей структуре ИНС отдельно от остальных.

Пример обучения нейросети идентификации и её тестирование на воспроизведение тренировочного множества приведен в Приложении Г.

3.3 Синтез адаптивной нейросети для аппроксимации функционала настроечных параметров регуляторов

Для аппроксимации функционала настроечных параметров регулятора в возможной области варьирования параметров объекта регулирования было принято решение синтезировать и обучить искусственную нейронную сеть, воспроизводящую функциональную зависимость следующего вида:

$$(k_p, T_u, T_o) = f(k_o, T_o, \tau_o)$$

Попытки синтеза нейросети для воспроизведения оптимальных настроечных параметров по примеру нейросети идентификации параметров объекта регулирования, не привели к ожидаемому результату. Линейные активационные функции не обеспечивали сходимости решения поставленной задачи (поверхности отклика функции цели оказались более сложными, нежели при идентификации), расположение синапсов не обеспечивало необходимой взаимосвязи параметров, поступающих на вход нейросети с воспроизводимыми данными.

Таблица 3.2 – Параметры базовой точки обучающей выборки

Параметры объекта регулирования			Параметры настройки ПИД регулятора		
k_o	T_o	τ_o	k_p	T_u	T_o

Без четкого построения обучающей выборки нейросеть воспроизводила параметры тренировочного множества с заданной точностью, но в множестве тестовом (параметры объектов регулирования, не входящие в обучающую выборку, но входящие в её диапазон) отклик нейросети был непредсказуем. Было принято решение ортогонализировать обучающую выборку с использованием

методов планирования эксперимента [31, 41]. Параметры объекта регулирования, полученные нейросетью идентификации во время проведения активного эксперимента представляются базовой точкой эксперимента (таблица 3.2).

Параметры k_p, T_u, T_∂ , выбранные в качестве воспроизводимых нейросетью (частный случай воспроизведения настроечных параметров идеального или реального ПИД регулятора), выбраны из соображений уменьшения влияния погрешности воспроизведения пропорциональной составляющей регулятора на коэффициенты k_u и k_∂ , которые представляют собой выражения, содержащие k_p . Автором были проведены исследования, в ходе которых в качестве воспроизводимых ИНС параметров выступали параметры k_p, k_u, k_∂ . В ходе проведения расчетов выявилась ситуация при которой происходит наложение погрешностей воспроизведения пропорциональной части регулятора на настроечные параметры $k_u = k_p / T_u$ и $k_\partial = k_p \cdot T_\partial$, что может отрицательно сказаться как на минимизации рассматриваемого критерия оптимальности качества регулирования, так и на воспроизведении должным образом заданного частотного показателя колебательности. При необходимости использования коэффициентов k_u, k_∂ всегда можно применять выражения для их вычисления с помощью настроечных параметров, вычисленных нейросетью k_p, T_u, T_∂ .

3.3.1 Создание тренировочного множества с применением полного факторного эксперимента для обучения нейросети

Создание обучающей выборки, с применением полного факторного эксперимента, проводится аналогично описанному в параграфе 3.2.1. В данном случае претерпевает изменения только формат обучающей выборки. В качестве данных для обучения нейросети адаптации используются данные объектов регулирования и, соответствующие каждому набору данных, оптимальные настроечные параметры регулятора.

При проведении одного ПФЭ путем последовательного перебора всех возможных сочетаний уровней варьирования составляется полная матрица планирования, состоящая из 8 входных (параметры объекта регулирования) и 8 выходных наборов (настроенные параметры соответствующего регулятора) значений для обучения ИНС.

Как отмечалось ранее, диапазон изменения параметров теплоэнергетических объектов может быть различным, поэтому для создания обучающей выборки возможно проведение не одного, а серии ПФЭ, в каждом из которых коэффициент интервала варьирования следует принимать отличным от предыдущего. Значения коэффициентов следует принимать равным коэффициентам, участвующим в создании обучающей выборки для нейросети идентификации (ранее были выбраны значения коэффициентов 0.1, 0.25 и 0.5). Таким образом, количество наборов данных Z для обучения ИНС можно рассчитать следующим образом:

$$Z = 2^x \cdot F \cdot M$$

где x – количество варьируемых параметров объекта регулирования, F – количество проводимых полных факторных экспериментов с различными коэффициентами интервалов варьирования, M – количество заданных частотных показателей колебательности.

Таблица 3.3 – Обучающая выборка для тренировки нейросети адаптации

№ точки	Параметры объекта регулирования			Параметры настройки ПИД регулятора		
	k_o	T_o	τ_o	k_p	T_i	T_d
1	k_o^{min}	T_o^{min}	τ_o^{min}	k_p^1	T_i^1	T_d^1
2	k_o^{max}	T_o^{min}	τ_o^{min}	k_p^2	T_i^2	T_d^2
3	k_o^{min}	T_o^{max}	τ_o^{min}	k_p^3	T_i^3	T_d^3
4	k_o^{max}	T_o^{max}	τ_o^{min}	k_p^4	T_i^4	T_d^4
5	k_o^{min}	T_o^{min}	τ_o^{max}	k_p^5	T_i^5	T_d^5
6	k_o^{max}	T_o^{min}	τ_o^{max}	k_p^6	T_i^6	T_d^6
7	k_o^{min}	T_o^{max}	τ_o^{max}	k_p^7	T_i^7	T_d^7
8	k_o^{max}	T_o^{max}	τ_o^{max}	k_p^8	T_i^8	T_d^8

Обучающая выборка, состоящая из одного полного факторного эксперимента и одного заданного частотного показателя колебательности для воспроизведения настроечных параметров идеального ПИД регулятора, в общем виде представлена в таблице 3.3.

При обучении нейросетей следует помнить, что настроечные параметры регулятора $\{k_p, T_u, T_d\}$ являются группами чисел в различных диапазонах значений, поэтому для качественного обучения нейросети необходимо произвести нормирование каждой группы параметров в диапазоне действия выбранной активационной функции. Данный метод позволяет свести к минимуму влияние больших чисел на функцию цели обучения нейросети и повысить точность её обучения. Нормирование каждой группы параметров производится согласно формуле:

$$x^{норм} = \frac{(min-max) \cdot (x_i - max\{x\})}{min\{x\} - max\{x\}} + max$$


где x_i – текущее значение параметра регулятора, $\{x\}$ – вектор значений нормируемого параметра регулятора.


3.3.2 Выбор класса и структуры нейросети, обучение ИНС

Имея в наличии все достаточные предпосылки для использования ИНС (связь между входными и выходными значениями, пренебрежительно малые помехи в обучающей выборке, достаточность выборки для обучения), был произведен выбор структур нейросетей. Для рассматриваемых регуляторов (ПИ, идеальный и реальный ПИД регуляторы), удовлетворяющим по качеству воспроизведения обучающих выборок, опытным путем были выбраны полностью связанные, прямонаправленные двухслойные нейронные сети с сигмоидальными активационными функциями нейронов (рисунки 3.10, 3.11). Количество нейронов входного слоя нейросетей продиктовано выбором вида аппроксимирующей функции объекта регулирования (2.7), количество нейронов внутреннего слоя для воспроизведения каждого настроечного параметра регулятора определялось в результате проведения серии экспериментов с минимизацией воспро-

изведения нейросетью как тренировочного, так и тестового множеств. Количество выходных нейронов определяется исходя из типа устанавливаемого регулятора. Общая архитектура нейросетей определяется формулой 3.2.

Каждая нейросеть должна соответствовать уровню сложности решаемой задачи. Количество нейронов в скрытом слое нейросети для воспроизведения каждого настроечного параметра регулятора позволяет с высокой точностью воспроизводить данные как в тренировочном, так в тестовых множествах, не входящих в обучающую выборку, но располагающихся в объеме тренировочных данных. Использование скрытых слоёв позволяет ИНС осуществлять нелинейные преобразования вход-выход любой сложности или извлекать из выходных данных статистические показатели высоких порядков. Однако усложнение структуры ИНС, такие как: увеличение количества нейронов в скрытом слое, создание дополнительных внутренних слоев нейросети, значительно увеличивают машинное время расчёта весовых коэффициентов, при этом качественного уменьшения ошибки прогноза на обучающем множестве не происходит. Исследования, проведенные автором, показывают, что выбор иных активационных функций, в отличие от предложенного, увеличивает погрешность обучения нейросетей. Необходимо отметить, что высоким качеством тренировки нейросети стоит считать приобретенную ею способность точно воспроизводить оптимальные настроечные параметры регулятора во всем объеме параметров объектов регулирования, участвующих в обучении нейросети.







б)

а) ПИ регулятора (NN 3-6-2); б) ПИД регулятора (NN 3-12-3).

Рисунок 3.10 – Нейросети воспроизведения настроечных параметров регуляторов с фиксированным частотным показателем запаса устойчивости



а)



а) ПИ регулятора (NN 4-8-2); б) ПИД регулятора (NN 4-15-3).

Рисунок 3.11 – Нейросети воспроизведения настроечных параметров регуляторов с возможностью изменения частотного показателя запаса устойчивости

Критерием настройки ИНС адаптации для всех рассматриваемых примеров был выбран минимум среднемодульного отклонения анализируемой величины:

$$S_x = \frac{1}{n} \sum_{i=1}^n \frac{|x_i^{mga} - x_i^{unc}|}{x_i^{mga}} \cdot 100\% \quad (3.3)$$

где x_i^{mga} , x_i^{unc} – настроечные параметры регулятора, рассчитанные с помощью алгоритма «Optim-MGA» и искусственной нейронной сети, соответственно, n – количество точек обучающей выборки.

Каждая идея создания и применения нейросетей требует тщательной проверки на состоятельность со стороны исследователя. Возможные непредвиденные отказы сети, ложные срабатывания, сбои могут привести к негативным последствиям, именно поэтому должна проводиться кропотливая работа по обучению, оптимизации и тестированию нейросетей с обязательной оптимизацией полученных результатов. Стоит отметить, что для промышленной эксплуатации нейросетевых технологий требуется как безотказное, надежное и выверенное программное обеспечение, так и простота обслуживания сети, удобство её эксплуатации.

Синтез нейросетей с помощью специализированного программного обеспечения возможен только в том случае, если ПО предоставляет современные алгоритмы оптимизации или возможность самостоятельной реализации необходимых алгоритмов в виде компонент системы, а также в случае уверенности правильного выбора архитектуры нейронной сети.

Все исследования, связанные с созданием и обучением нейросетей производились численными методами в программном пакете MathCAD, в качестве алгоритма оптимизации использовалась пользовательская версия эволюционного алгоритма многопараметрической многоэкстремальной оптимизации «Optim-MGA». Пример реализации нейросети адаптивной подстройки параметров реализуемого регулятора приведен в Приложении Д.

3.4 Выводы

1. Показаны предпосылки для применения аппарата теории искусственных нейронных сетей для аппроксимации функционала настроечных параметров регулятора.
2. Предложена методика проведения серии полных факторных экспериментов по созданию обучающих выборок для обучения нейросетей идентификации и адаптации.
3. Предложены структуры синтезированных нейросетей параметрической идентификации для объектов с самовыравниванием в разомкнутом конту-

ре АСР. Предложена методика создания тренировочных множеств для обучения нейросети.

4. Продемонстрирован возможный синтез искусственных нейронных сетей с различными архитектурами для аппроксимации функционала настроечных параметров ПИ и ПИД регуляторов с заданным частотным показателем колебательности ($M=const$) или возможностью его изменения в заранее заданном диапазоне ($M=var$).
5. Разработана библиотека присоединяемых программ, позволяющих численным методом, с помощью выбранного алгоритма оптимизации, производить тренировку искусственных нейронных сетей для параметрической идентификации теплоэнергетических объектов и тренировку нейросетей для автоматической коррекции настроечных параметров типовых регуляторов.

ГЛАВА 4

ОБУЧЕНИЕ ИСКУССТВЕННЫХ НЕЙРОННЫХ СЕТЕЙ ИДЕНТИФИКАЦИИ И АДАПТАЦИИ

4.1 Обучение нейросети параметрической идентификации объекта регулирования

4.1.1 Проведение активного эксперимента для создания тренировочного множества для обучения нейросети

После проведения активного эксперимента на объекте регулирования необходимо определиться с передаточной функцией модели аппроксимации и идентифицировать параметры объекта регулирования по полученной переходной характеристике. Полученные параметры принять за базовую точку в пространстве параметров объекта регулирования и провести серию полных факторных экспериментов.

В примере, приведенном на рисунке 2.3, базовой точкой следует считать параметры идентифицируемой модели (2.7) со следующими числовыми значениями $k_O = 1.0$; $\tau_O = 2.0$ с; $T_O = 10$ с., $n = 2$. Пример составления полной матрицы планирования для коэффициентов интервалов варьирования $k = 0.1, 0.25, 0.5$ приведен в таблице 4.1.

Производя построчную выборку параметров объектов регулирования из таблицы 4.1 необходимо построить графики переходных процессов с соответствующими импульсными переходными характеристиками.

Выбрав максимальный коэффициент интервала варьирования $k = 0.5$, при $k_O = 0.5$ и $T_O = 15$ с. произведем построение касательной к графику переходного процесса.

Таблица 4.1 – Параметры объектов регулирования, полученные в ходе проведения серии полных факторных экспериментов

№ точки	Коэффициент интервала варьирования	Параметры объектов регулирования		
		k_o	T_o	τ_o
1	0.1	1.1	11	2.2
2		1.1	11	1.8
3		1.1	9	2.2
4		1.1	9	1.8
5		0.9	11	2.2
6		0.9	11	1.8
7		0.9	9	2.2
8		0.9	9	1.8
9	0.25	1.25	12.5	2.5
10		1.25	12.5	1.5
11		1.25	7.5	2.5
12		1.25	7.5	1.5
13		0.75	12.5	2.5
14		0.75	12.5	1.5
15		0.75	7.5	2.5
16		0.75	7.5	1.5
17	0.5	1.5	15	3
18		1.5	15	1
19		1.5	5	3
20		1.5	5	1
21		0.5	15	3
22		0.5	15	1
23		0.5	5	3
24		0.5	5	1

Для обозначенного переходного процесса проведем касательную и определим абсциссу точки пересечения касательной и установившегося значения переменной, как это было продемонстрировано на рисунке 3.5. Получившееся значение, равное 48, необходимо округлить до 50 и, разделив его на 10, получить временной интервал в 5 секунд для нанесения 11 реперных точек на графики переходных процессов и соответствующих им импульсных переходных характеристик для определения постоянной времени объекта регулирования (рисунок 4.1).

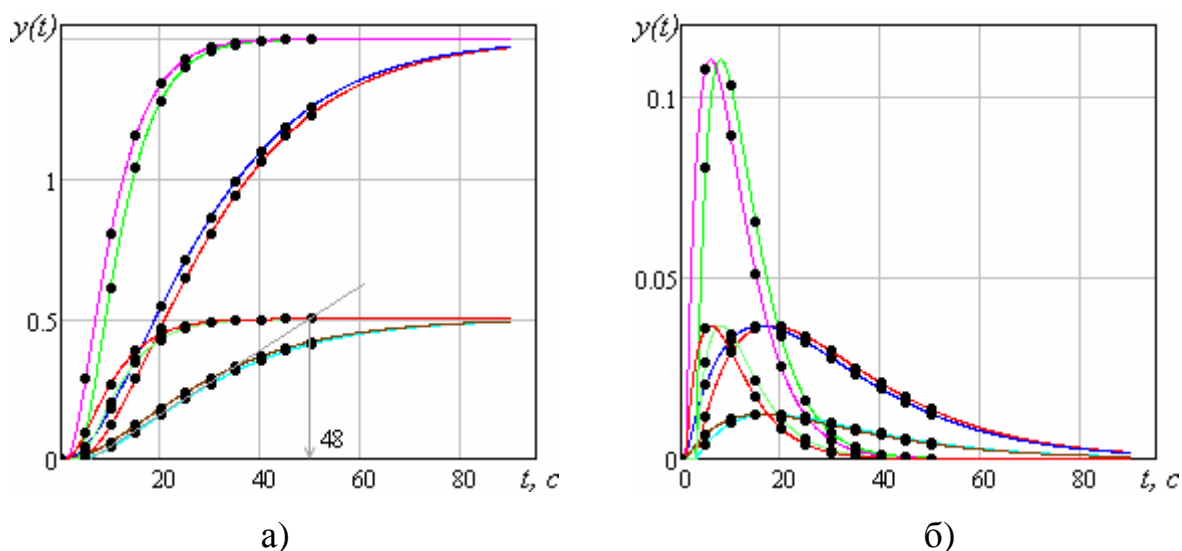


Рисунок 4.1 – Реперные точки на реализациях переходных процессов (а) и, соответствующих им, реализациях импульсных переходных характеристик (б) для определения величины постоянной времени

Для определения запаздывания выберем количество реперных точек, соответствующее трехкратному значению τ_0 с учетом момента начала проведения эксперимента, таким образом количество реперных точек для определения запаздывания составляет по 7 штук для графиков переходных процессов и импульсных переходных характеристик.




Рисунок 4.2 – Реперные точки на реализациях переходных процессов (а) и, соответствующих им, реализациях импульсных переходных характеристик (б) для определения величины запаздывания

Таблица 4.2 – Значения ординат реперных точек переходных процессов и, соответствующих им, импульсных переходных характеристик

Опреде- ляемый параметр	№ реперной точки	Значения ординат реперных точек переходных процессов (П) и соответствующих им импульс- ных переходных характеристик (Д) для объектов регулирования, взятых из ПФЭ									
		1		2		3		...		8	
		П	Д	П	Д	П	Д	П	Д
Постоянная времени	1	0	0	0	0	0	0	0	0
	2	0.012	0.012	0.045	0.02	0.092	0.08	0.096	0.036
	3	0.12	0.029	0.183	0.033	0.612	0.104	0.269	0.03
	4	0.287	0.036	0.36	0.037	1.037	0.065	0.384	0.017
	5	0.47	0.036	0.542	0.036	1.28	0.034	0.446	8.501e-3
	6	0.646	0.034	0.713	0.032	1.401	0.016	0.476	3.95e-3
	7	0.806	0.03	0.863	0.028	1.457	7.317e-3	0.49	1.756e-3
	8	0.943	0.025	0.992	0.023	1.482	3.19e-3	0.496	7.574e-4
	9	1.059	0.021	1.099	0.019	1.492	1.357e-3	0.498	3.196e-4
	10	1.153	0.017	1.186	0.016	1.497	5.667e-4	0.499	1.326e-4
	11	1.23	0.014	1.256	0.012	1.499	2.333e-4	0.5	5.434e-5
Запаздывание	1	0	0	0	0	0	0	0	0
	2	0	0	0	1.363e-9	0	0	0	1.437e-9
	3	0	0	3.189e-3	6.237e-3	0	0	8.762e-3	0.016
	4	0	1.414e-11	0.012	0.012	0	4.315e-9	0.031	0.027
	5	3.189e-3	6.237e-3	0.026	0.016	0.026	0.049	0.061	0.033
	6	0.012	0.012	0.045	0.02	0.092	0.08	0.096	0.036
	7	0.026	0.016	0.067	0.024	0.183	0.099	0.132	0.037

Полученные ординаты реперных точек необходимо представить в виде обучающей выборки (таблица 4.2).

4.1.2 Обучение нейросети параметрической идентификации

Поиск синаптических весов нейросети, как отмечалось выше, производится с помощью алгоритма многопараметрической многоэкстремальной оптимизации «Optim-MGA».

Воспроизведение нейросетью параметров как тренировочного, так и тестового множества продемонстрировано в таблице 4.3.

Таблица 4.3 – Результаты обучения нейросети параметрической идентификации

Мно- жество	Параметры объекта регулирования					Процент отклонения	
	заданного			воспроизводимого			
	k_O	T_O	τ_O	$T_{инс}$	$\tau_{инс}$	$ \% T $	$ \% \tau $
Тренировочное	1.1	11	2.2	11.16	2.2	1.5	0.2
	1.1	11	1.8	10.81	1.82	1.7	1.1
	1.1	9	2.2	9.02	2.21	0.2	0.7
	1.1	9	1.8	9.00	1.87	0.0	4.0
	0.9	11	2.2	11.13	2.2	1.2	0.2
	0.9	11	1.8	10.84	1.83	1.5	1.4
	0.9	9	2.2	8.95	2.21	0.6	0.6
	0.9	9	1.8	8.99	1.88	0.1	4.2
	1.5	15	3	15.29	3.01	2.0	0.5
	1.5	15	1	14.35	1.04	4.3	3.6
	1.5	5	3	5.06	3.01	1.2	0.3
	1.5	5	1	5.19	1.05	3.8	4.8
	0.5	15	3	15.26	3.02	1.7	0.5
	0.5	15	1	14.36	1.04	4.3	4.0
	0.5	5	3	5.05	3.00	0.9	0.1
	0.5	5	1	5.21	1.04	4.1	4.4
Тестовое	1.25	13.5	2.75	13.66	2.82	1.2	2.4
	1.25	13.5	1.25	13.11	1.29	2.9	3.3
	1.25	6.5	2.75	6.41	2.79	1.4	1.3
	1.25	6.5	1.25	6.56	1.25	1.0	0.2
	0.75	13.5	2.75	13.64	2.82	1.1	2.4
	0.75	13.5	1.25	13.13	1.29	2.7	3.4
	0.75	6.5	2.75	6.42	2.79	1.2	1.4
	0.75	6.5	1.25	6.64	1.25	2.1	0.2

Для промышленных объектов регулирования с внутренними свойствами, отличными от рассматриваемых, количество ПФЭ с различными коэффициентами интервалов варьирования, необходимых для обучения ИНС должно определяться на стадии создания тренировочных множеств, но общие тенденции, несомненно, должны сохраняться. Достаточным следует считать такое количество данных, участвующих в обучении нейросети, при котором происходит прогнозируемое обучение ИНС в области параметров объекта регулирования, необходимой для эксплуатации теплоэнергетического оборудования в различных режимах.

4.2 Обучение нейросетей адаптивной настройки реализуемых регуляторов

4.2.1 Обучение нейросетей тренировочными множествами, состоящими из одного полного факторного эксперимента

Тренировка нейросетей со структурами типа NN 3-6-2 для ПИ регулятора и NN 3-12-3 для идеального и реального ПИД регуляторов с минимизацией интегрального критерия по модулю обучающей выборкой, состоящей из одного полного факторного эксперимента с заданным коэффициентом интервала варьирования (0.1, 0.25 и 0.5) продемонстрирована в таблице 4.4.

Нейросеть с достаточной точностью воспроизводит тренировочное множество, но, при проверке воспроизведения настроечных параметров за пределами или внутри диапазона обучающей выборки, результат оказывается неудовлетворительным. Наиболее чувствительной к изменениям параметров объекта регулирования оказалась пропорциональная часть всех исследуемых регуляторов. Среднемодульная ошибка (3.3) которой при проверке ПИ регулятора может достигать 23%, для идеального ПИД регулятора 33% и 90% для реального ПИД регулятора.

Обучение нейронной сети тренировочным множеством, состоящим только из результатов одного полного факторного эксперимента, не приводит к устой-

чивым результатам тренировки адаптивных нейросетей, воспроизводящих настроечные параметры рассматриваемых регуляторов в большом диапазоне изменения параметров объекта регулирования. Данный вид обучения можно рекомендовать только при незначительных изменениях параметров объекта регулирования.

Для обучения нейросети с прогнозируемым отклонением настроечных параметров представляется возможным сгенерировать обучающую выборку, состоящую из нескольких полных факторных экспериментов, с различными коэффициентами интервалов варьирования. Условимся далее называть такую выборку расширенной [75, 78, 79].

4.2.2 Обучение нейросетей тренировочными множествами, состоящими из нескольких полных факторных экспериментов

Использование расширенных обучающих выборок при тренировке нейросетей позволяет достичь требуемых результатов в прогнозировании настроечных параметров как ПИ, так и ПИД регуляторов.

В таблице 4.5 представлены критерии настройки (3.3) обучения адаптивных нейросетей со структурами NN 3-6-2 для ПИ регулятора и NN 3-12-3 для идеального и реального ПИД регуляторов без возможности изменения частотного показателя колебательности ($M=const$), а также нейросетей с возможностью изменения последнего ($M=var$) со структурами NN 4-8-2 для ПИ регулятора и NN 4-15-3 для ПИД регуляторов.

Таблица 4.4 – Критерии тренировки нейросетей обучающими выборками, состоящими из одного полного факторного эксперимента

Коэффициент интервала варьирования		Структуры нейросетей							
		3-6-2		3-12-3					
		Тип воспроизводимого регулятора							
		ПИ		ПИД идеальный			ПИД реальный		
обучения нейросети	проверки обученной нейросети	S_{k_p}	S_{T_u}	S_{k_p}	S_{T_u}	S_{T_δ}	S_{k_p}	S_{T_u}	S_{T_δ}
0.1	0.1	0.035	0.025	0.0045	0.0056	0.0064	0.012	0.0052	0.029
	0.25	3.35	1.95	22.27	17.15	5.88	14.65	9.91	9.15
	0.5	23.32	3.99	33.49	33.14	20.13	89.86	24.26	22.57
0.25	0.1	1.22	0.861	7.11	10.52	2.75	5.04	5.98	4.2
	0.25	0.138	0.026	0.012	0.0093	0.011	0.01	0.01	0.025
	0.5	14.98	0.963	14.52	6.61	18.35	45.072	8.61	4.69
0.5	0.1	3.42	0.793	6.34	9.89	3.14	10.5	6.16	4.9
	0.25	5.87	0.423	13.17	3.17	7.62	15.41	3.85	2.26
	0.5	0.238	0.035	0.09	0.0093	0.029	0.029	0.055	0.056

Примечание: темным цветом выделены строки, в которых коэффициенты интервалов варьирования совпадают для обучения и проверки нейросети

Таблица 4.5 – Результаты тренировки нейросетей с заданным частотным показателем колебательности и возможностью его изменения

Тип регулятора	Структура нейросети	M	Критерий настройки		
			S_{k_p}	S_{T_u}	S_{T_o}
ПИ	3-6-2	const	2.98	2.73	-
	4-8-2	var	4.50	3.16	-
ПИД идеальный	3-12-3	const	3.78	4.79	2.83
	4-15-3	var	6.53	3.99	4.21
ПИД реальный	3-12-3	const	4.82	4.44	3.09
	4-15-3	var	2.74	3.74	3.54

Примечания:

- 1) Все критерии в таблице указаны для нейросетей, обученных на воспроизведение настроечных параметров регуляторов с минимизацией интегрального критерия по модулю;
- 2) Для строк $M=const$ (с заданным частотным показателем колебательности) для тренировки нейросети использовалась обучающая выборка, состоящая из 24 наборов данных;
- 3) Для строк $M=var$ (с возможностью варьирования частотного показателя колебательности) для тренировки нейросети использовалась обучающая выборка, состоящая из 72 наборов данных.
- 4) Изменение частотного показателя колебательности может производиться в интервалах значений, принятых на этапе формирования обучающих выборок. Диапазон изменений M определяется исходя из необходимой и достаточной избыточности для коррекции настроечных параметров регуляторов при настройке АСР.
- 5) Расширенные обучающие выборки и результаты обучения нейросетей с графическим представлением воспроизведения тестовых множеств продемонстрированы для интегрального критерия по модулю в Приложении А.

Как видно из таблицы 4.5 обучение нейросетей расширенными обучающими выборками позволяет определять синаптические веса ИНС таким обра-

зом, что воспроизведение настроечных параметров рассматриваемых регуляторов становится прогнозируемым во всем диапазоне обучающей выборки. Отклонение настроечных параметров в тренировочном множестве не превышает 5%, что можно считать удовлетворительным результатом.

4.2.3 Влияние количества нейронов в скрытом слое нейросети на результаты воспроизведения тренировочных множеств

Качество и скорость обучения нейросетей зависит от количества нейронов в скрытом слое ИНС. В таблице 4.6 продемонстрированы критерии обучения нейросетей (3.3) с тремя и четырьмя нейронами в скрытом слое для воспроизведения каждого настроечного параметра. В качестве обучающих выборок использовались параметры объектов регулирования и, соответствующие каждой группе параметров объекта, оптимальные параметры регуляторов, найденных на минимум линейного и квадратичного интегральных критериев, а также интегрального критерия по модулю.

Воспроизведение настроечных параметров ПИ регулятора нейросетью можно считать удовлетворительным с количеством нейронов в скрытом слое для каждого настроечного параметра равному трем. При этом обеспечивается качественное воспроизведение как тренировочных, так и тестовых множеств. При количестве нейронов для каждого параметра регулятора, равное четырем воспроизведение тренировочных множеств нейросетью не вызывает нареканий, но при проверке на тестовое множество нейросеть может воспроизводить не оптимальные параметры регулятора, что сказывается на виде переходных процессов и АЧХ замкнутого контура системы регулирования и указывает на некорректность обучения нейросети. Дальнейшее увеличение количества нейронов в скрытом слое приводит к неудовлетворительным результатам, что указывает на чрезмерное усложнение структуры искусственной нейросети для решаемой задачи.

Таблица 4.6 – Критерии качества обучения нейросетей с различными структурами

Воспроизведение параметров регулятора	Кол-во нейронов в скрытом слое нейросети для каждого параметра регулятора	Интегральный критерий настройки регуляторов для обучающей выборки	Критерии обучения нейросети		
			S_{k_p}	S_{T_u}	S_{T_∂}
ПИ	3	по модулю	2.98	2.73	-
		линейный	3.39	1.27	-
		квадратичный	2.85	3.29	-
	4	по модулю	3.55	3.01	-
		линейный	2.68	3.34	-
		квадратичный	2.11	3.19	-
Идеальный ПИД	3	по модулю	5.19	4.65	5.02
		линейный	5.33	3.02	4.88
		квадратичный	5.95	3.65	5.27
	4	по модулю	3.78	4.79	2.83
		линейный	4.10	3.42	5.52
		квадратичный	5.99	3.45	4.95
Реальный ПИД	3	по модулю	3.70	3.16	3.23
		линейный	4.30	2.85	3.72
		квадратичный	4.95	7.29	4.42
	4	по модулю	4.82	4.44	3.09
		линейный	4.79	3.71	4.18
		квадратичный	3.49	8.40	5.92

Примечание: количество наборов данных в каждой обучающей выборке для тренировки всех представленных в таблице нейросетей составляет 24 (3 полных факторных эксперимента с коэффициентами интервала варьирования 0.1, 0.25 и 0.5 с заданным частотным показателем колебательности).

Для ПИД регуляторов ситуация выглядит несколько иначе. При количестве нейронов в скрытом слое, равном трем, для каждого из искомых настроечных параметров нейросеть не находит зависимости воспроизведения. При четырех нейронах в скрытом слое ИНС обучается оптимальным образом, при котором происходит минимизация критерия оптимальности тренировки нейросети и воспроизведение тестовых множеств не вызывает нареканий. При количе-

стве нейронов в скрытом слое более пяти происходит некорректное обучение нейросети, аналогичное нейросети для воспроизведения параметров ПИ регулятора, что проявляется в кратном увеличении критерия оптимальности обучения ИНС.

Для промышленного применения возможность изменения частотного показателя колебательности (с мгновенным воспроизведением оптимальных настроечных параметров регулятора) является не столько достоинством, сколько необходимостью. Для реализации отмеченного положения необходимо учесть зависимости изменения настроечных параметров регуляторов от принимаемых значений частотного показателя колебательности и параметров объекта регулирования. В связи с чем представляется возможным создать соответствующие расширенные обучающие выборки и проверить возможность обучения нейросети для рассматриваемой задачи. В качестве примера произведен анализ нейросетей для воспроизведения настроечных параметров реального ПИД регулятора (таблица 4.7).

Таблица 4.7 – Критерии обучения нейросетей для воспроизведения оптимальных настроечных параметров реального ПИД регулятора с возможностью изменения частотного показателя колебательности

Количество нейронов в скрытом слое нейросети для каждого параметра регулятора	Структура нейросети	Критерии обучения нейросети		
		S_{k_p}	S_{T_u}	S_{T_d}
4	4-12-3	10.3	5.03	5.56
5	4-15-3	2.74	3.74	3.54
6	4-18-3	7.97	3.78	3.5

Примечания:

- 1) Количество наборов данных для обучения всех представленных в таблице нейросетей составляет 72 (3 полных факторных эксперимента с коэффициентами интервала варьирования 0.1, 0.25 и 0.5 и варьируемым частотным показателем колебательности 1.1, 1.3 и 1.55).

- 2) *Расширенная обучающая выборка и результаты обучения нейросети (с четырьмя нейронами в скрытом слое для определения каждого настроечного параметра) с графическим представлением воспроизведения тестовых множеств продемонстрированы для интегрального критерия по модулю в Приложении А.*

4.2.4 Реализация нейросети воспроизведения настроечных параметров идеального ПИД регулятора с возможностью изменения частотного показателя колебательности

Обучающая выборка, состоящая из серии полных факторных экспериментов с различными коэффициентами интервалов варьирования (0.1, 0.25 и 0.5), позволяет добиться качественного обучения нейросети (таблица 4.8), при котором воспроизведение настроечных параметров регулятора становится прогнозируемым во всем диапазоне изменения параметров объекта регулирования и частотного показателя колебательности M (диапазон определяется максимальным значением коэффициента интервала варьирования).

Таблица 4.8 – Результаты обучения нейросети, воспроизводящей настроечные параметры идеального ПИД регулятора ($M=var$)


№	Параметры объекта регулирования			M	Параметры настройки ПИД регулятора, полученные с помощью					
					MGA			ИНС		
	k_o	T_o	τ_o		k_p	T_u	T_∂	k_p	T_u	T_∂
1	1.1	11	2.2	1.1	5.53	14.33	5.81	5.36	14.48	5.84
2	1.1	11	1.8	1.1	6.82	13.49	5.63	6.75	13.73	5.61
3	1.1	9	2.2	1.1	4.54	12.48	4.84	4.40	12.65	4.85
4	1.1	9	1.8	1.1	5.59	12.01	4.62	5.35	11.97	4.63
5	0.9	11	2.2	1.1	6.80	14.53	5.71	6.90	14.52	5.83
6	0.9	11	1.8	1.1	8.31	13.55	5.61	8.80	13.75	5.61
7	0.9	9	2.2	1.1	5.57	12.59	4.79	5.51	12.69	4.84
8	0.9	9	1.8	1.1	6.81	11.95	4.64	6.81	11.99	4.63
...

Продолжение таблицы 4.8


65	1.5	15	3	1.55	6.11	10.48	6.31	6.11	10.50	5.80
66	1.5	15	1	1.55	28.68	5.6	3.49	24.31	5.14	3.86
67	1.5	5	3	1.55	1.81	7.44	2.92	2.64	7.43	2.96
68	1.5	5	1	1.55	6.11	3.86	2.04	6.57	4.71	2.42
69	0.5	15	3	1.55	18.24	11.56	6.31	17.25	10.74	5.84
70	0.5	15	1	1.55	33.02	4.68	7.08	40.05	5.13	4.16
71	0.5	5	3	1.55	5.43	7.76	2.80	5.517	7.44	2.97
72	0.5	5	1	1.55	18.06	4.39	2.01	17.60	4.63	2.50

Примечание: полная расширенная обучающая выборка и результаты обучения нейросети с графическим представлением воспроизведения тестовых множеств продемонстрированы, для интегрального критерия по модулю, в Приложении А.


На рисунках 4.5, 4.6, 4.7 представлены переходные процессы по каналам задания, регулирующего органа и амлитудно-частотные характеристики замкнутого контура АСР для визуального сравнения воспроизведения настроечных параметров идеального ПИД регулятора нейросетью (ИНС) с настроечными параметрами, полученными численными методами в различных точках тренировочного множества с помощью алгоритма «Optim-MGA» (MGA).



а)




б)




в)


Рисунок 4.5 – Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 4-15-3), воспроизводящей параметры идеального ПИД регулятора, тестовым объектом регулирования ($k_o=1.4$, $\tau_o=1.5$ с., $T_o=11.5$ с.), $M=1.55$



а)




б)




в)


Рисунок 4.6 – Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 4-15-3), воспроизводящей параметры идеального ПИД регулятора, тестовым объектом регулирования ($k_o=0.85$, $\tau_o=3.0$ с., $T_o=14$ с.), $M=1.4$



а)



б)



в)

Рисунок 4.7 – Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 4-15-3), воспроизводящей параметры идеального ПИД регулятора, тестовым объектом регулирования ($k_o=1.3$, $\tau_o=2.0$ с., $T_o=8$ с.), $M=1.3$

4.2.5 Реализация адаптивной нейросети в составе двухконтурной каскадной АСР

Среди систем управления с добавочными переменными состояния объекта регулирования наибольшее распространение получили двухконтурные каскадные АСР с корректирующим (главным) и стабилизирующим (вспомогательным) регуляторами. Отработанная методика синтеза и тренировки адаптивных нейросетей для одноконтурных систем регулирования позволяет также реализовывать типовые решения в области построения АСР для теплоэнергетической отрасли. Адаптивная АСР для каскадной системы регулирования продемонстрирована на рисунке 4.8.

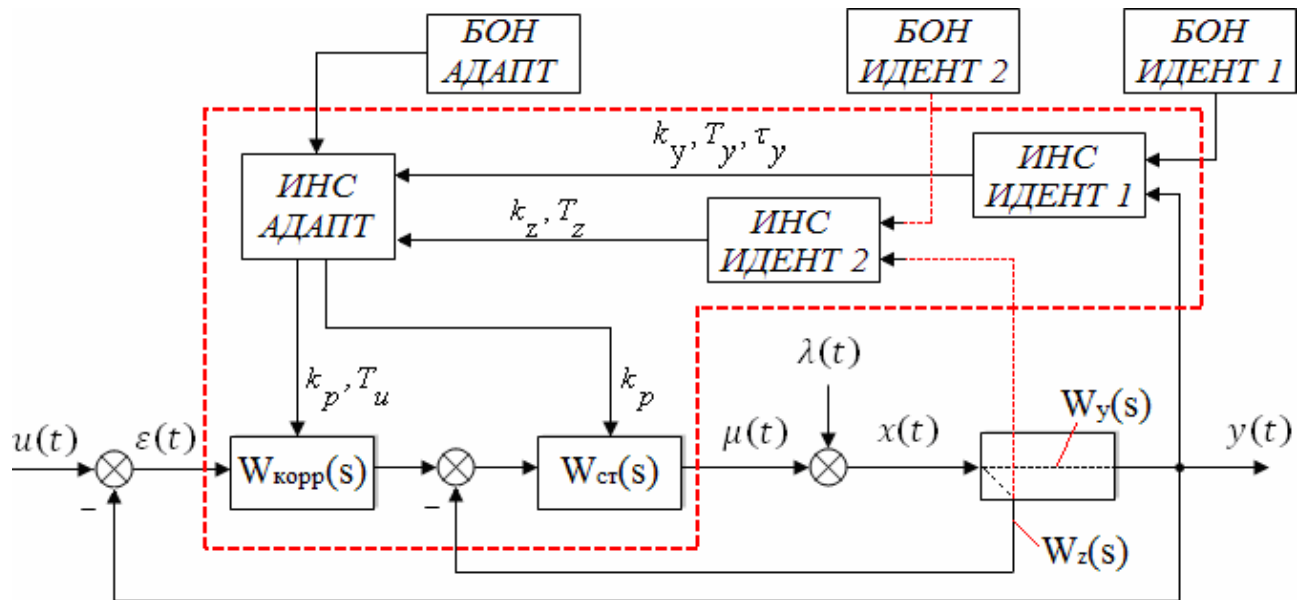


Рисунок 4.8 – Структурная схема двухконтурной каскадной адаптивной АСР

В рассматриваемом примере стабилизирующим является П регулятор, корректирующим – ПИ. Передаточные функции объекта регулирования по внутреннему (4.1) и внешнему (4.2) контурам представлены ниже:

$$W_z(s) = \frac{k_z}{(T_z + 1)}, \quad (4.1)$$

где $k_z = 0.5$; $T_z = 5$ с.

$$W_y(s) = k_y \frac{\exp(-\tau_y \cdot s)}{(T_y + 1)^3}, \quad (4.2)$$

где $k_y = 1.0$; $\tau_y = 4.0$ с.; $T_y = 10$ с.

Количество наборов данных при создании обучающей выборки из пяти свободно варьируемых параметров рассматриваемых объектов регулирования при количестве коэффициентов интервалов варьирования равное двум составляет:

$$n = 2^X \cdot F = 2^5 \cdot 2 = 64,$$

где X – количество варьируемых параметров, F – количество коэффициентов интервалов варьирования.

Обучающая выборка формировалась по принципу, аналогичному для построения одноконтурных систем регулирования, при этом для обеспечения за-

данного запаса устойчивости использовался частотный показатель колебательности, определяемый в виде максимального значения АЧХ замкнутой АСР на резонансной частоте. Для каскадной АСР требуется, чтобы этот показатель для любой точки её структуры не превышал заданного значения. Выполнение этого условия проверяется в точках, отражающих поведение главного и вспомогательного контуров. При этом, точки размыкания контуров выбираются перед входами в соответствующий регулятор.

С учетом эквивалентных объектов, выражение для КЧХ разомкнутой системы с корректирующим регулятором запишется в виде:

$$W_{pc}^y(j\omega) = W_k(j\omega) \cdot \frac{W_c(j\omega) \cdot W_y(j\omega)}{1 + W_c(j\omega) \cdot W_z(j\omega)},$$

а со стабилизирующим в виде:

$$W_{pc}^z(j\omega) = W_c(j\omega) \cdot [W_y(j\omega) \cdot W_k(j\omega) + W_z(j\omega)].$$

КЧХ замкнутых систем главного и вспомогательного контуров и соответствующие им АЧХ определяются согласно выражениям:

$$W_{3c}^y(j\omega) = \frac{W_{pc}^y(j\omega)}{1 + W_{pc}^y(j\omega)}; \quad A_{3c}^y(\omega) = |W_{3c}^y(j\omega)|;$$

$$W_{3c}^z(j\omega) = \frac{W_{pc}^z(j\omega)}{1 + W_{pc}^z(j\omega)}; \quad A_{3c}^z(\omega) = |W_{3c}^z(j\omega)|;$$

При численном методе настройки $\max A_{3c}^y(\omega)$ и $\max A_{3c}^z(\omega)$ не должны превышать заданные допустимые значения соответствующих им показателей колебательности.

Таким образом, контроль $A_{3c}^y(\omega)$ и $A_{3c}^z(\omega)$ позволяет ограничить их максимальные значения и тем самым исключить настройки, приводящие к недопустимой колебательности как в главном, так и во вспомогательном контурах каскадной АСР.

Часть набора обучающей выборки, состоящей из двух факторных экспериментов с коэффициентами интервалов варьирования 0.1, 0.25 и результаты

обучения нейросети по воспроизведению настроечных параметров корректирующего и стабилизирующего регуляторов представлены в таблице 4.9.

Критерии настройки нейросети со структурой NN 5-25-3 для пропорциональной части корректирующего регулятора $S_{k_p} = 0.16$, для пропорциональной и интегральной частей стабилизирующего регулятора $S_{k_p} = 1.99$ и $S_{T_i} = 1.96$, соответственно, позволяют говорить о возможности реализации адаптивных каскадных АСР, в основе которых положены алгоритмы нейронных сетей, в промышленной эксплуатации.

Таблица 4.9 – Результаты обучения нейросети, воспроизводящей настроечные параметры корректирующего и стабилизирующего регуляторов адаптивной каскадной АСР

№	Параметры объектов регулирования для контуров					Настроечные параметры регуляторов, найденные с помощью					
						MGA			ИНС		
	внешнего			внутреннего		корр.	стаб.		корр.	стаб.	
	k_y	T_y	τ_y	k_z	T_z	k_p	k_p	T_i	k_p	k_p	T_i
1	1.1	11	4.4	0.55	5.5	9.153	1.02	27.81	9.136	1.03	28.36
2	1.1	11	3.6	0.55	5.5	9.135	1.12	27.76	9.134	1.12	28.11
3	1.1	9	4.4	0.55	5.5	9.113	0.97	22.64	9.117	0.96	22.52
4	1.1	9	3.6	0.55	5.5	9.096	1.07	22.65	9.111	1.04	21.95
5	0.9	11	4.4	0.55	5.5	9.154	1.26	28.24	9.138	1.29	28.35
6	0.9	11	3.6	0.55	5.5	9.134	1.37	27.92	9.134	1.36	28.04
7	0.9	9	4.4	0.55	5.5	9.118	1.20	23.15	9.118	1.20	22.31
8	0.9	9	3.6	0.55	5.5	9.096	1.29	21.98	9.11	1.29	21.64
...
57	1.25	12.5	5	0.45	5.5	11.24	0.73	33.16	11.17	0.75	31.17
58	1.25	12.5	3	0.45	5.5	11.21	0.86	31.14	11.17	0.87	30.59
59	1.25	7.5	5	0.45	5.5	11.21	0.60	18.69	11.16	0.70	19.31
60	1.25	7.5	3	0.45	5.5	11.15	0.77	17.67	11.17	0.79	18.03
61	0.75	12.5	5	0.45	5.5	11.22	1.21	32.85	11.17	1.23	32.59
62	0.75	12.5	3	0.45	5.5	11.21	1.47	32.15	11.17	1.42	32.10
63	0.75	7.5	5	0.45	5.5	11.2	1.02	19.4	11.16	1.02	19.42
64	0.75	7.5	3	0.45	5.5	11.14	1.28	17.27	11.17	1.28	18.07

Примечание: весь объем расширенной обучающей выборки и результатов обучения нейросети с графическим представлением воспроизведения тестовых множеств представлен в Приложении Б.

На рисунках 4.9, 4.10, 4.11 представлены переходные процессы по каналам задания, регулирующего органа и амлитудно-частотные характеристики замкнутого контура АСР для визуального сравнения воспроизведения настроечных параметров каскадного и стабилизирующего регуляторов нейросетью (ИНС) с настроечными параметрами, полученными численными методами в различных точках тренировочного множества с помощью алгоритма «Optim-MGA» (MGA).

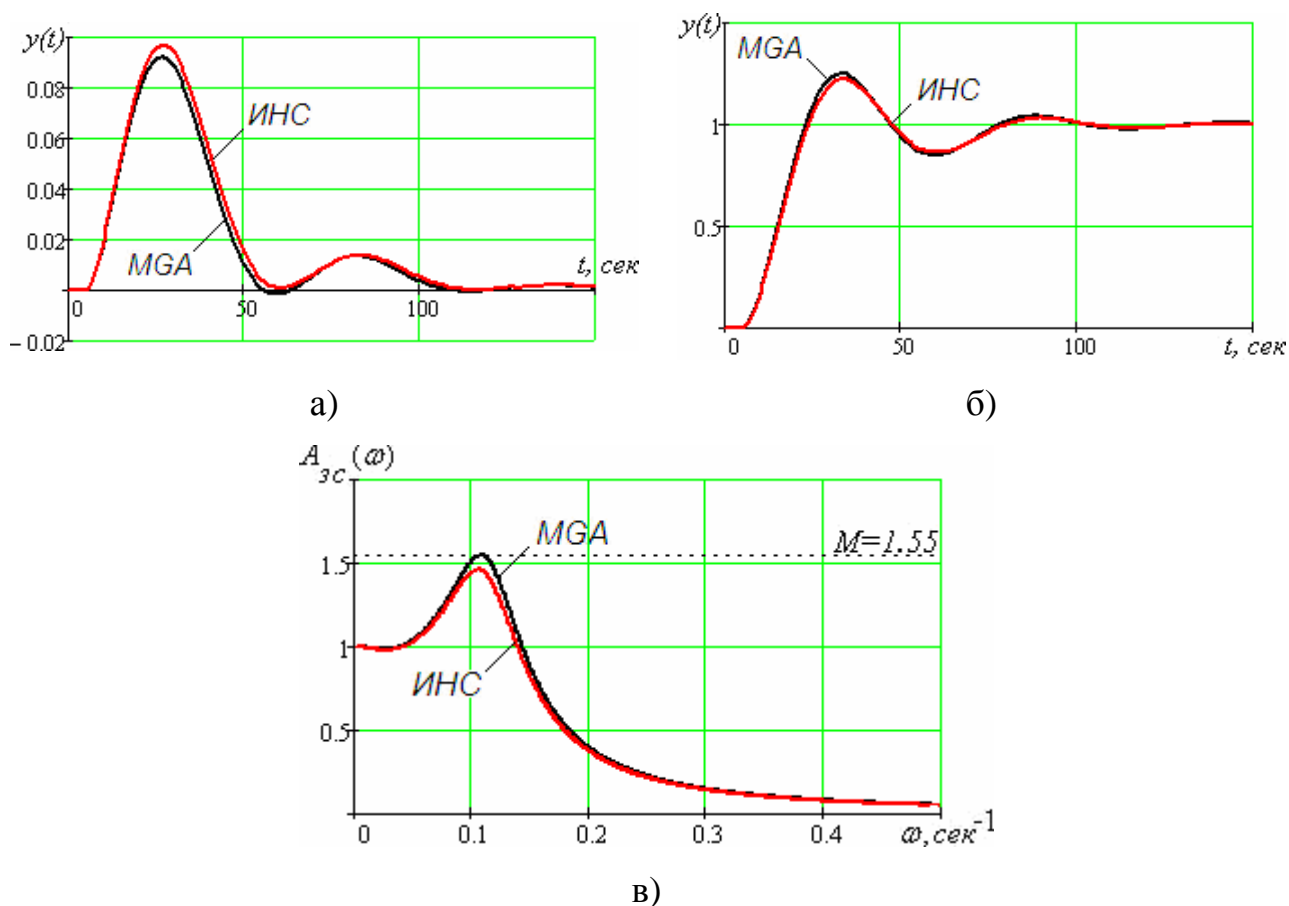





Рисунок 4.9 – Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 5-25-3), воспроизводящей параметры корректирующего и стабилизирующего регуляторов, тестовыми объектами по внутреннему и внешнему контурам ($k_z=1.17$, $\tau_z=4.0$ с., $T_z=9.0$ с., $k_y=0.52$, $T_y=5.1$ с.)



а)




б)




в)


Рисунок 4.10 – Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 5-25-3), воспроизводящей параметры корректирующего и стабилизирующего регуляторов, тестовыми объектами по внутреннему и внешнему контурам ($k_z=0.95$, $\tau_z=2.7$ с., $T_z=8.0$ с., $k_y=0.47$, $T_y=4.6$ с.)



а)



б)



в)

Рисунок 4.11 – Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 5-25-3), воспроизводящей параметры корректирующего и стабилизирующего регуляторов, тестовыми объектами по внутреннему и внешнему контурам ($k_z=0.8$, $\tau_z=5.2$ с., $T_z=12$ с., $k_y=0.54$, $T_y=5.4$ с.)

4.3 Рекомендации поэтапного синтеза нейросетей

идентификации и адаптации применительно к задачам синтеза адаптивных АСР теплоэнергетических объектов

На основании множества экспериментов по синтезу ИНС применительно к задачам идентификации и адаптивной подстройки регуляторов автором даются несколько рекомендаций для более быстрого и качественного обучения нейросетей:

1. Необходимо оценить возможность изменения параметров объекта регулирования. Исходя из полученной оценки необходимо задаться количеством полных факторных экспериментов, необходимых для создания обучающей выборки. Для каждого ПФЭ определить коэффициент интервала варьирования (коэффициенты должны быть выбраны таким образом, чтобы обученная нейросеть смогла воспроизводить настроечные параметры регулятора в диапазоне между различными ПФЭ с заданной точностью).
2. Для тренировки нейросетей требуется тщательный анализ создаваемой обучающей выборки, исключающий появление некорректных данных или взаимоисключающих событий (появление отрицательных параметров регуляторов при прочих положительных и т.д.).
3. Выбор оптимальной структуры искусственной нейронной сети, реализуемой исходя из условий решаемой задачи.
4. Нормирование обучающей выборки в заданном диапазоне.
5. Расчет синаптических весов нейросети с помощью алгоритма оптимизации должен производиться, по возможности, несколько раз с последующим выбором наилучшего результата.
6. Анализ результатов обучения нейросетей:
 - 6.1 Оценка критериев оптимальности обучения рассматриваемых нейросетей.
 - 6.2 Оценка синаптических весов нейросети. Чем меньше значения весов нейросети, тем точнее воспроизведение нейросетью как тренировочного, так и тестового

вых множеств (при значениях синаптических весов, различающихся меж собой на два порядка и более, можно отвергать полученный результат, т.к. в данном случае нейросеть, способная воспроизводить тренировочное множество, не сможет воспроизводить тестовые объекты регулирования с заданной точностью).

7. Во время тренировки нейросетей следует обращать внимание на возможность их некорректного обучения, которое не проявляется при воспроизведении параметров обучающей выборки. Отрицательный результат обучения будет выявлен только при проверке обученных нейросетей на воспроизведение тестовых множеств. В подобном случае необходимо повторить обучение нейросети.

4.4 Синтез адаптивной АСР на базе нейросетевых компонент в эмуляторе программируемого логического контроллера

Основными факторами реализации нейросетевых компонент в виде пользовательских функциональных блоков в программируемом логическом контроллере являются:

- простота использования нейросетей для параметрической идентификации объекта регулирования и адаптивной подстройки параметров реализованных регуляторов;
- время воспроизведения оптимальных настроечных параметров регуляторов в зависимости от изменившихся параметров объекта регулирования;
- включение адаптивной АСР по требованию персонала;
- возможность вмешательства персонала в работу адаптивной АСР.

Главным достоинством рассматриваемой адаптивной системы является легкость, с которой можно получить оптимальные настроечные параметры регулятора. Единожды обученная нейросеть способна воспроизводить оптимальные параметры регуляторов в широком диапазоне изменения параметров объекта регулирования (диапазон воспроизведения параметров определяется закладываемой избыточностью во время выбора коэффициентов интервала варь-

ирования для создания тренировочных множеств для обучения рассматриваемых в работе нейросетей). Сбои в обработке полученной информации и некорректная работа сети исключаются логикой реализации структуры адаптивной АСР, тщательной подготовкой обучающих выборок, оценкой всех полученных настроенных параметров на стадии создания тренировочного множества.

Этапом, предшествующим реализации адаптивной АСР в ПЛК должна стать реализация имитационной модели создаваемой системы в эмуляторе контроллера. Данная процедура позволяет должным образом проверить результаты проделанной работы и оценить корректность полученных результатов. Программная реализация адаптивной АСР в эмуляторе контроллера выполнена согласно разделу международного стандарта МЭК 61131-3 на языке программирования FBD и представлена на рисунке 4.12 в программной среде разработки Control Builder F компании «ABB» [16, 29, 35-39, 80]. Нейросетевые компоненты идентификации и адаптации выполнены в виде пользовательских функциональных блоков на языке ST. Объект регулирования (2.7) реализован в виде последовательного соединения стандартных функциональных блоков.

При реализации адаптивной АСР в ПЛК нет необходимости нагромождать контроллер избыточными экземплярами функциональных блоков, поэтому представляется необходимым объединить несколько адаптивных нейросетей (для воспроизведения параметров ПИ и ПИД регуляторов) в едином ПФБ, предоставив при этом персоналу выбор структуры реализуемого регулятора, критерия оптимальной настройки и значения частотного показателя колебательности. Предложенный вариант реализации, несомненно, повысит качество настройки АСР и позволит сократить время их оптимизации.

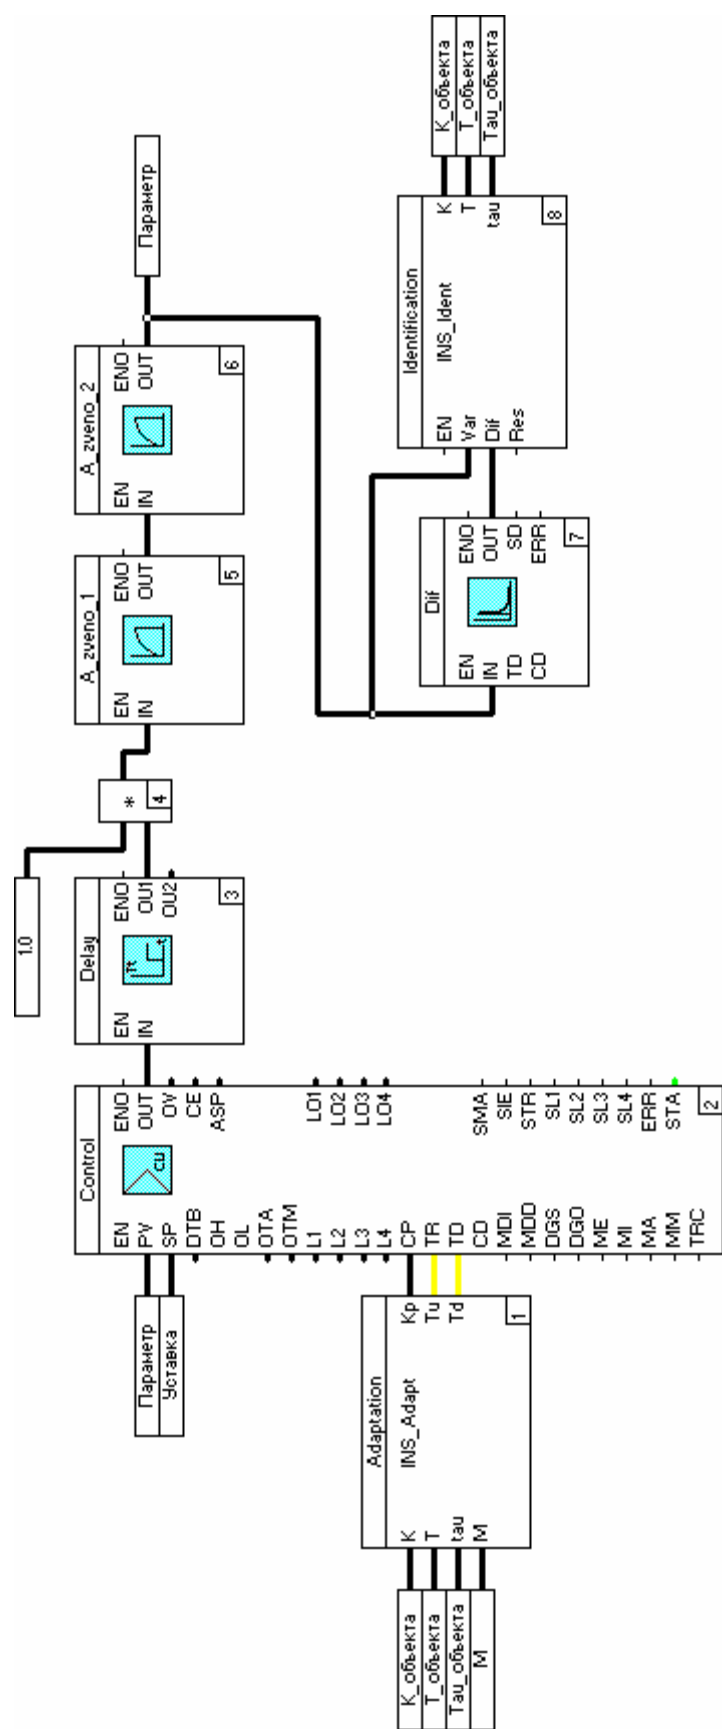


Рисунок 4.12 – Реализация нейросетевых компонент идентификации (Identification) и адаптации (Adaptation) в общей структуре адаптивной АСР в виде пользовательских функциональных блоков в эмуляторе контроллера AC800 компании «ABB» в среде программирования Control Builder F

ПФБ Identification, реализующий нейросеть параметрической идентификации параметров объекта регулирования не содержит диалоговых окон и настраивается для каждой аппроксимирующей модели объекта регулирования единовременно.

а)

б)

в)

Рисунок 4.13 – Диалоговое окно ПФБ INS_Adapt

В диалоговом окне пользовательского функционального блока INS_Adapt, представленного на рисунке 4.13, на первой вкладке реализована возможность выбора структуры реализуемого регулятора, а также запись синаптических весов обученных нейросетей. На второй вкладке (рисунок 4.13,б) записываются диапазоны обучающей выборки для нормирования данных, поступающих на входы нейросети, на третьей и последующих вкладках (рисунок 4.13, в) записываются синаптические веса обученной нейросети для каждого настроечного параметра регулятора. При выборе структуры регулирования на вход функционального блока регулятора Control поступают оптимальные настроечные параметры регулятора, соответствующие текущим параметрам объекта регулирования.

4.5 Выводы

1. Синтез нейросети параметрической идентификации, по предложенной автором методике обучения нейросетей, позволяет свести к минимуму ошибку прогноза воспроизведения как тренировочных, так и тестовых множеств нейросетью уже на первом этапе синтеза и анализа работы реализованной ИНС.
2. Обучение нейросетей обучающими выборками, состоящими из одного полного факторного эксперимента, приводит к результату, в котором с высокой точностью воспроизводится только тренировочное множество, при этом воспроизведение параметров тестового множества нельзя считать удовлетворительным при больших коэффициентах интервалов варьирования. Предлагается использовать данный вид обучения для систем, изменение параметров которых не превышает 5-10%.
3. Обучение адаптивных нейросети рекомендуется проводить с использованием обучающих выборок, состоящих из серии полных факторных экспериментов с различными коэффициентами интервалов варьирования и возможностью изменения частотного показателя колебательности. Выполнение данных рекомендаций обеспечивает постоянство заданного запаса

устойчивости системы, а также минимизацию выбранного критерия качества переходного процесса в широком диапазоне изменения параметров объекта регулирования.

4. Предлагаемая методика синтеза и обучения нейросетей позволяет внедрять нейрокомпоненты в типовые схемы автоматизированных систем управления теплоэнергетическими процессами.
5. Реализация в ПЛК нейронной сети позволяет мгновенно воспроизводить оптимальные настроечные параметры, обеспечивающие заданные критерии качества и заданный показатель колебательности АСР в процессе ее функционирования, что, безусловно, облегчает труд персонала, снижая время, требуемое для настройки и отладки конкретной АСР.

ГЛАВА 5

ПРАКТИЧЕСКАЯ РЕАЛИЗАЦИЯ АДАПТИВНОЙ АСР

5.1 Обучение нейросети параметрической идентификации объекта регулирования

После проведения ряда исследований по разработке нейросетевых компонент идентификации и адаптации возникла необходимость подтвердить полученные теоретические результаты на практике.

В качестве объекта регулирования была выбрана электрическая печь. Напряжение на нагревательном элементе изменяется воздействием исполнительного механизма МЭО на автотрансформатор. Измеряемые параметры (температура в электропечи и указатель положения регулирующего органа) подаются на аналоговые входы контроллера.

ПТК АСУ ТП электропечи состоит из контроллера ПЛК150 фирмы «ОВЕН», который связан по протоколу Modbus TCP с персональным компьютером (ОС Windows XP). Программирование микроконтроллера производится в программной среде разработки CoDeSys.

5.1.1 Подготовительный этап реализации искусственных нейросетей

Перед проведением активного эксперимента необходимо организовать запись переменной переходного процесса и указатель положения исполнительного механизма. Для проведения параметрической идентификации объекта регулирования необходимо установить постоянное напряжение на выходе трансформатора и дождаться установившегося состояния температуры электропечи.

Создать ступенчатое возмущение на входе объекта регулирования, для чего с помощью ИМ в режиме «Руч» путем включения ИМ в направлении «Больше» на время 7-8 с. (перемещение ИМ должно быть непрерывным), после чего дождаться стабилизации температуры электронагревателя. По достижении стацио-

нарного состояния открыть файл архивных данных, созданный программой Codesys, и импортировать данные в программу TunePID [63], предназначенную для настройки и оценки качества работы АСР, после чего выбрать модель аппроксимирующей передаточной функции объекта регулирования и произвести его параметрическую идентификацию. Наилучшим образом воспроизведение переходного процесса обеспечивает передаточная функция, состоящая из двух последовательно соединенных апериодических звеньев и звена транспортного запаздывания (рисунок 5.1).




Рисунок 5.1 – Параметрическая идентификация объекта регулирования в программе TunePID

Параметры идентифицируемой модели $k_o = 1.3 \text{ } ^\circ\text{C}/\%\text{УП}$; $T_o = 115.84 \text{ с}$. $\tau_o = 1.6 \text{ с}$. принимаются за базовую точку проведения серии полных факторных экспериментов для создания тренировочных выборок с целью обучения нейросети параметрической идентификации.

5.1.2 Синтез и обучение нейросети идентификации

Стоит отметить, что численное значение запаздывания для выбранной аппроксимирующей функции объекта регулирования, полученные во время параметрической идентификации, достаточно мало по сравнению со значением постоянной времени. Можно предположить, что запаздывание объекта регулирования более подвержено со временем изменению, нежели T_O . Таким образом представляется возможным создать обучающие выборки на диапазон изменения $T_O \pm 10\%$, а для τ_O выбрать 2 диапазона изменения $\pm 10\%$ и от 0 до 4 с. Результаты обучения нейросети представлены в таблице 5.1.

Произведем синтез тренировочного множества для обучения нейросети для чего необходимо рассчитать временные интервалы нанесения реперных точек на графики переходных процессов и импульсных переходных характеристик. Выберем переходный процесс с $k=0.10$, $k_O = 1.17$ °C/%УП; $T_O = 104.26$ с. и определим абсциссу точки пересечения касательной к установившемуся значению выбранного переходного процесса. Значение абсциссы точки А (рисунок 5.2) равно 394, округлив до 400 и, поделив на 10, получим значение интервала размещения реперных точек равное 40 с.

Округлив значение величины запаздывания с 1.6 до 2 и, утроив полученное значение, было зафиксировано 6 временных интервалов на которых расположились 7 реперных точек с момента начала проведения активного эксперимента.

Абсциссы реперных точек записываются в тренировочное множество для обучения нейросети идентификации аналогично Таблице 4.2. Архитектура синтезируемой нейросети NN 36-18-2. Результаты обучения ИНС с помощью алгоритма «Optim-MGA» представлены в таблице 5.1.




Рисунок 5.2 – Графики переходных процессов и импульсных переходных процессов при $k=0.1$

Таблица 5.1 – Значения параметров обучающей выборки и параметров, воспроизведенных обученной нейросетью

Параметры объекта регулирования					Процент отклонения	
обучающей выборки			воспроизведенного			
k_o	T_o	τ_o	$T_{\text{инс}}$	$\tau_{\text{инс}}$	$ \% T $	$ \% \tau $
1.43	127.4	1.76	127.34	1.76	0.05	0.11
1.43	127.4	1.44	127.24	1.45	0.13	0.76
1.43	104.3	1.76	104.24	1.75	0.05	0.45
1.43	104.3	1.44	104.18	1.44	0.11	0.14
1.17	127.4	1.76	127.33	1.76	0.06	0.17
1.17	127.4	1.44	127.28	1.45	0.09	0.76
1.17	104.3	1.76	104.16	1.75	0.14	0.51
1.17	104.3	1.44	104.24	1.44	0.06	0.14
1.43	127.4	4	127.57	4.00	0.14	0.10
1.43	127.4	0	127.11	0	0.23	0.00
1.43	104.3	4	104.04	4	0.25	0.00
1.43	104.3	0	104.20	0	0.10	0.00
1.17	127.4	4	127.63	4.00	0.18	0.10
1.17	127.4	0	127.08	0.01	0.25	0.00
1.17	104.3	4	104.11	4.00	0.19	0.03
1.17	104.3	0	104.23	0	0.07	0.00

Из таблицы 5.1 видно, что качество обучения ИНС достаточно высокое, таким образом синтезированную нейросеть параметрической идентификации с

известными синаптическими весами можно реализовать в виде пользовательского функционального блока в ПЛК. Программная реализация ИНС представлена в Приложении Е1.

5.1.3 Синтез и обучение нейросети адаптации

После синтеза нейросети идентификации необходимо произвести подобный ряд процедур и для нейросети адаптации. В качестве обучающей выборки выступает тренировочное множество для нейросети идентификации, с той лишь разницей, что вместо ординат реперных точек должны быть рассчитаны оптимальные настроечные параметры регулятора (было принято решение произвести расчет для двух значений частотного показателя колебательности 1.3, 1.55 с помощью алгоритма «Optim-MGA»). Архитектура адаптивной нейросети NN 4-8-2, результаты обучения представлены в таблице 5.2.

Таблица 5.2 – Значения настроечных параметров регуляторов в обучающей выборке и параметров, воспроизведенных обученной нейросетью

№	Параметры объекта регулирования			М	Параметры настройки ПИ регулятора, полученные с помощью			
					MGA		ИНС	
	k_o	T_o	τ_o		k_p	T_u	k_p	T_u
1	1.17	104.3	1.44	1.55	3.484	169.9	3.55	172.595
2	1.43	104.3	1.44	1.55	2.861	170.4	2.897	172.527
3	1.17	127.4	1.44	1.55	3.58	210	3.642	212.892
4	1.43	127.4	1.44	1.55	2.931	210.1	2.974	211.805
5	1.17	127.4	1.76	1.55	3.579	213	3.572	210.867
6	1.43	127.4	1.76	1.55	2.926	212.8	2.899	209.785
7	1.17	104.3	1.76	1.55	3.489	173	3.474	172.225
8	1.43	104.3	1.76	1.55	2.851	172.7	2.836	172.175
9	1.17	104.3	0	1.55	3.922	177.5	3.85	175.968
10	1.43	104.3	0	1.55	3.193	176.4	3.186	175.876
11	1.17	104.3	4	1.55	3.094	169.8	3.022	171.413
12	1.43	104.3	4	1.55	2.528	169.6	2.548	171.325
13	1.17	127.4	4	1.55	3.111	201.4	3.144	201.325
14	1.43	127.4	4	1.55	2.545	201.4	2.55	201.917

Продолжение таблицы 5.2

15	1.17	127.4	0	1.55	4.091	226.8	3.9	226.735
16	1.43	127.4	0	1.55	3.318	224.4	3.282	225.658
17	1.17	104.3	1.76	1.3	2.64	186.4	2.589	184.859
18	1.43	104.3	1.76	1.3	2.169	187.2	2.066	185.067
19	1.17	104.3	1.44	1.3	2.657	185.4	2.626	186.411
20	1.43	104.3	1.44	1.3	2.169	185	2.097	186.58
21	1.17	127.4	1.44	1.3	2.89	246.5	2.736	232.305
22	1.43	127.4	1.44	1.3	2.37	247.1	2.215	231.669
23	1.17	127.4	1.76	1.3	2.53	214.9	2.711	230.692
24	1.43	127.4	1.76	1.3	2.07	214.8	2.167	230.177
25	1.17	104.3	4	1.3	2.317	175.5	2.336	176.424
26	1.43	104.3	4	1.3	1.898	175.8	1.937	176.902
27	1.17	104.3	0	1.3	2.697	178.3	2.76	177.327
28	1.43	104.3	0	1.3	2.207	178.3	2.258	178.537
29	1.17	127.4	0	1.3	2.933	237.7	2.861	239.91
30	1.43	127.4	0	1.3	2.398	237.6	2.45	239.131
31	1.17	127.4	4	1.3	2.482	224.7	2.48	223.715
32	1.43	127.4	4	1.3	2.033	224.9	1.957	223.928

Из таблицы 5.2 видно, что качество обучения ИНС приемлемо для реализации нейросети адаптивной подстройки регулятора с известными синаптическими весами в виде пользовательского программного блока в ПЛК. Программная реализация ИНС представлена в Приложении Е2.

5.2 Реализация адаптивной АСР на базе нейросетевых компонент в ПЛК

В адаптивной АСР, представленной на рисунке 5.3, применяется один из способов реализации линейных законов регулирования на базе ИМ постоянной скорости с применением трехпозиционного релейного элемента с гистерезисом и зоной нечувствительности.

Несмотря на среду разработки, отличную от рассмотренной в параграфе 4.5, в CoDeSys также возможна реализация программ, функциональных блоков

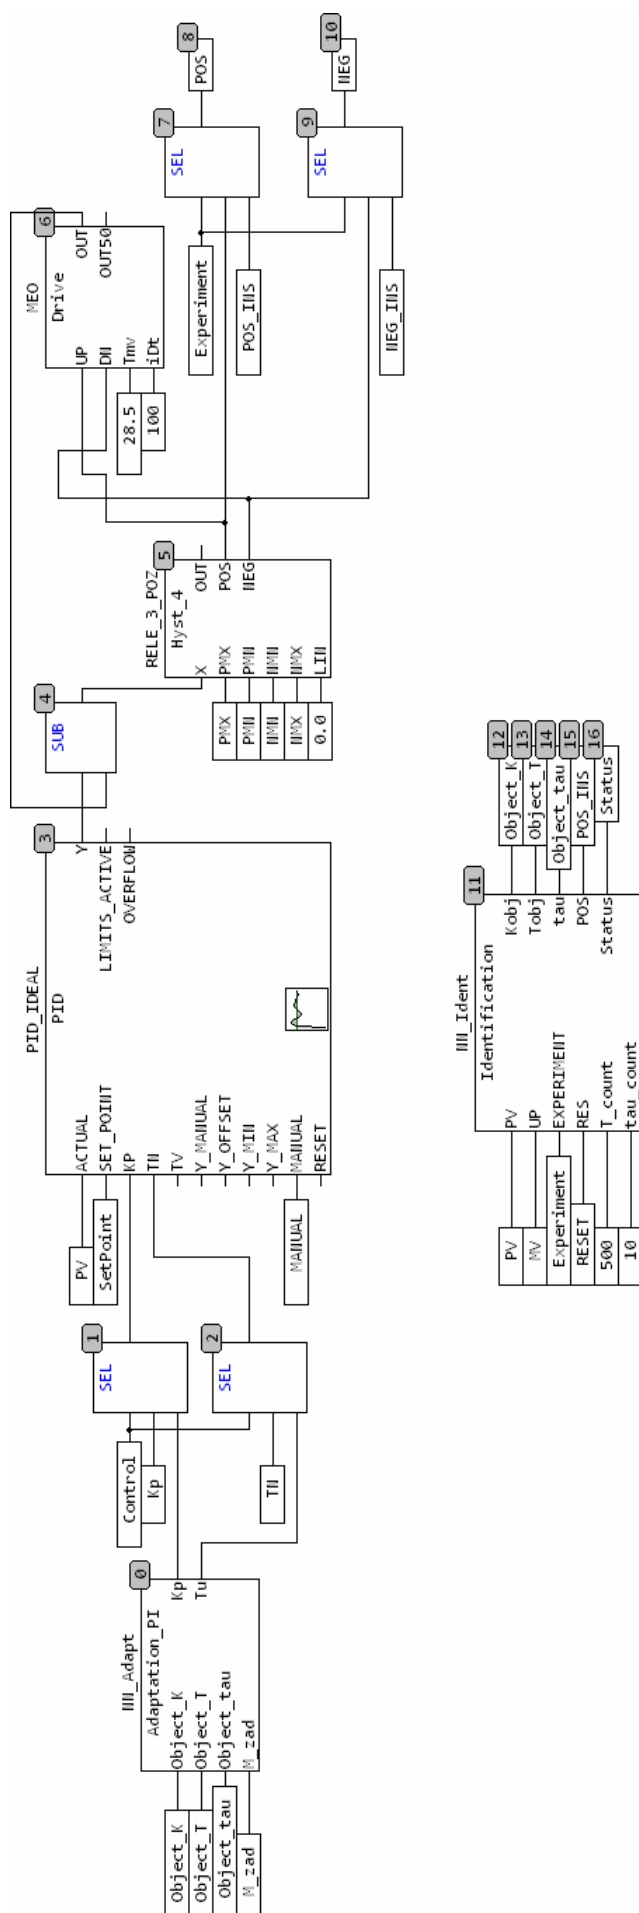


Рисунок 5.3 – Реализация адаптивной АСР на базе нейросетевых компонент в среде разработки CoDeSys

и функций также как и в Control Builder F, т.к. рассматриваемая среда разработки соответствует международному стандарту МЭК 61131-3.

Для представленной на рисунке 5.3 адаптивной АСР требуется соблюсти ряд последовательных действий для корректного проведения параметрической идентификации объекта регулирования, а также адаптивной настройки реализуемого в АСР регулятора:

- 1) Необходимо перевести регулятор в ручной режим и дождаться установившегося значения регулируемой величины во времени;
- 2) На входе функционального блока NN_Ident присвоить переменной Experiment значение TRUE, что означает начало проведения эксперимента;
 - а) С помощью блоков SEL (select) происходит переключение управляющих воздействий на исполнительный механизм с трехпозиционного реле на выходы NN_Ident;
 - б) От NN_Ident подается импульсная команда заданной длительности на ИМ в сторону «Больше»;
 - в) С момента начала подачи возмущения нейросеть NN_Ident начинает записывать значения ординат реперных точек через равные промежутки времени во внутренние массивы данных для их последующей обработки;
- 3) Окончание эксперимента наступает во время присваивания блоком NN_Ident переменной Status значения TRUE, что свидетельствует о корректности завершённой процедуры параметрической идентификации;
- 4) Полученные на предыдущем этапе параметры объекта регулирования поступают на входы функционального блока NN_Adapt;
- 5) NN_Adapt автоматически рассчитывает оптимальные параметры реализуемого регулятора на заданный пользователем частотный показатель колебательности;
- 6) Настраиваемые параметры подаются на входы регулятора;

- 7) После подачи на регулятор новых настроечных параметров присвоить переменной Experiment значение FALSE и перевести регулятор из ручного режима работы в автоматический;
- 8) Провести серию экспериментов в замкнутой системе регулирования (нанести возмущение по каналам задания и регулирующего органа) для оценки качества переходных процессов.

5.3 Проверка качества настроенной адаптивной АСР

После синтеза нейросетей и реализации их в виде пользовательских функциональных блоков в ПЛК необходимо провести ряд экспериментов для проверки качества синтезированной адаптивной АСР.

Необходимо с помощью нейросети провести активный эксперимент, во время которого реализованная ИНС будет проводить параметрическую идентификацию объекта регулирования. Реализация переходного процесса продемонстрирована на рисунке 5.4.

В ходе проведения активного эксперимента нейросеть идентификации корректирует параметры объекта регулирования и, после полного заполнения массивов данных значениями ординат реперных точек, ИНС выдает результат проведенной параметрической идентификации.

Параметры объекта регулирования, выданные ИНС в ходе проведения эксперимента $k_o=1.32$, $T_o=116.28$ с., $\tau_o=1.8$ с., находятся в диапазоне обучающей выборки, поэтому по окончании эксперимента состояние переменной State принимает значение TRUE, таким образом значения рассчитанных параметров поступают на входы нейросети адаптации, которая, в свою очередь, воспроизводит оптимальные настроечные параметры ПИ регулятора ($k_p=3,73$, $T_u=179.27$) с заданным значением показателя колебательности $M=1.55$.

После подстройки регулятора необходимо провести серию экспериментов для проверки качества регулирования, для чего необходимо с помощью пере-

менной Control переключить входы регулятора на адаптивные настроечные параметры и перевести регулятор в автоматический режим работы.




Рисунок 5.4 – Переходный процесс по каналу задания

На рисунке 5.5 представлены два переходных процесса по каналу задания и один переходный процесс по каналу регулирующего органа, полученные в ходе проведения экспериментальных исследований по настройке адаптивной АСР на базе нейросетевых компонент.




Рисунок 5.5 – Переходные процессы по каналу задания и регулирующего органа

Из графиков, представленных на рисунке 5.5 видно, что качество настрой-

ки АСР можно считать удовлетворительным. Соблюдается частотный показатель колебательности, настроечные параметры регулятора, полученные на минимум интегрального критерия по модулю, способствуют быстрому затуханию переходных процессов.

5.4 Выводы

- 1) Программная реализация адаптивной АСР на реальном объекте регулирования, рассмотренная в данной главе, позволяет удостовериться в применимости методики синтеза нейросетей для задач идентификации и адаптивной настройки регуляторов для АСР теплоэнергетических процессов.
- 2) Качество регулирования АСР на реальном объекте практически не отличается от моделируемого, что подтверждает практическую ценность проведенных исследований и позволяет говорить об оптимальной настройке регуляторов не только в исследовательских работах, но и на практике.
- 3) Предлагаемая автором методика проведения этапов идентификации и адаптивной подстройки настроечных параметров регуляторов ориентируется на высококвалифицированный персонал теплоэнергетических объектов, но, при этом, последовательность действий для оператора, необходимых для проведения экспериментов достаточно проста и лаконична.
- 4) Обучать нейросети можно тренировочным множеством, состоящим не только из полных факторных экспериментов с заданными коэффициентами интервалов варьирования, но также множеством, состоящим из ПФЭ с задаваемым пользователем диапазонами, исходя из динамики объекта регулирования и возможности изменения внутренних свойств объекта со временем. Данная возможность придает гибкость тренировочному множеству, что несомненно, лучшим образом сказывается на свойствах нейросети производить с высокой точностью параметрическую идентификацию в широких диапазонах варьирования параметров объекта регулирования.

ЗАКЛЮЧЕНИЕ

Совершенствование вычислительной техники в последнее десятилетие позволило для решения задач адаптивной настройки АСР реализовывать более сложные и эффективные алгоритмы, в том числе и искусственные нейронные сети, непосредственно в ПЛК ПТК АСУ ТП. В качестве инструмента для тренировки нейросетей, входящих в компонентную базу адаптивной АСР, служит персональный компьютер, позволяющий качественно оценивать создаваемые тренировочные множества непосредственно во время проведения активных экспериментов на объекте регулирования.

Достоинство разработанной адаптивной АСР на базе нейросетевых компонент заключается в том, что она находит применение в различных системах регулирования (одноконтурные, двухконтурные каскадные, двухконтурные с дифференциатором и т.д.). Предлагаемый подход синтеза нейросетевых компонент позволяет применять единожды обученные нейросети для периодической коррекции настроечных параметров реализуемых регуляторов.

Представленная в диссертационной работе методика построения адаптивных АСР, с применением нейросетевого моделирования, состоит из пяти основных этапов:

- 1) Проведение активного эксперимента непосредственно на технологическом объекте
 - а) анализ переходного процесса объекта регулирования;
 - б) выбор аппроксимирующей модели идентификации объекта;
 - в) параметрическая идентификация объекта регулирования.
- 2) Синтез нейросети параметрической идентификации
 - а) анализ требуемого объема обучающей выборки в зависимости от возможных изменений свойств объекта регулирования;
 - б) создание тренировочного множества с применением теории планирования эксперимента;
 - в) обучение нейросети идентификации;

- г) проверка качества обучения нейросети.
- 3) Синтез адаптивной нейросети
 - а) создание обучающей выборки с применением теории планирования эксперимента для тренировки нейросети адаптации с коэффициентами интервалов варьирования, принятых на стадии формирования обучающих выборок для нейросети идентификации;
 - б) обучение нейросети;
 - в) проверка качества обучения.
- 4) Имитационное моделирование адаптивной АСР в эмуляторе контроллера. Оценка качества воспроизведения варьируемых параметров объекта регулирования нейросетью идентификации и воспроизведение соответствующих оптимальных настроечных параметров реализуемого регулятора нейросетью адаптации.
- 5) Реализация адаптивной АСР в программируемом логическом контроллере на реальном объекте
 - а) проведение активного эксперимента с помощью реализованных компонент нейросетевой идентификации и адаптации;
 - б) выбор критерия оптимальности и частотного показателя колебательности для текущего состояния объекта регулирования;
 - в) оценка качества регулирования настроенной АСР.

Разработанная методика синтеза адаптивных АСР на базе нейросетевых компонент является универсальной и может быть распространена на различные системы регулирования тепломеханического оборудования как в теплоэнергетике, так и в других отраслях промышленности.

Внедрение разработанной методики на производстве позволит упростить процедуру периодической настройки АСР, повысить качество регулирования и сократить затраты на производство изготавливаемой продукции.

ОСНОВНЫЕ ВЫВООДЫ ПО РАБОТЕ

1. Произведен синтез искусственных нейронных сетей с различными архитектурами для аппроксимации функционала настроечных параметров ПИ и ПИД регуляторов с заданным частотным показателем колебательности ($M=const$) или возможностью его изменения в заранее заданном диапазоне ($M=var$), как для одноконтурных, так и для каскадных АСР.
2. Разработаны библиотеки присоединяемых программ, позволяющих численным методом, с помощью выбранного алгоритма оптимизации, производить как тренировку искусственных нейронных сетей (для задач идентификации и адаптивной настройки регуляторов), так и осуществлять поиск оптимальных настроечных параметров реализуемых регуляторов.
3. Программная реализация адаптивной АСР на реальном объекте, рассмотренная в диссертационном исследовании, позволяет говорить в применении методики синтеза нейросетей для задач идентификации и адаптивной настройки регуляторов для АСР теплоэнергетических процессов.
4. Необходимость создания новых программных реализаций как для настройки регуляторов, так и синтеза оптимальных по архитектуре нейронных сетей носит одноразовый характер. Единожды созданные программы могут быть применены для объектов со схожей динамикой. Таким образом, представляется возможным синтезировать библиотеку присоединяемых программ для ряда передаточных функций, типичных для использования в задачах аппроксимации теплоэнергетических объектов.

СПИСОК ЛИТЕРАТУРЫ

1. Александрова Н.Д. Расчет параметров динамической настройки регулятора (САР) температуры пара с опережающим скоростным сигналом. // Теплоэнергетика. 1965. №4.
2. Аналитические самонастраивающиеся системы автоматического управления. // Под ред. В.В. Солодовникова. – М.: Машиностроение, 1965г. – 356 с.
3. Бинь Ф.Т., Ротач В.Я., Мань Н.В. Расчет робастной настройки ПИД-регуляторов по огибающим частотных характеристик объекта. // Теплоэнергетика. 1995. №12.
4. Виленкин С.Я. Статистические методы исследования систем автоматического регулирования. – М.: Советское радио, 1967.
5. Воронов А.А. Основы теории автоматического управления. – М.: Энергоиздат. 1981. – 304 с.
6. Вороновский Г.К., Махотило К.В. Генетические алгоритмы, искусственные нейронные сети и проблемы виртуальной реальности. – Харьков: Основа, 1997.
7. Галушкин А.И. Теория нейронных сетей. Кн. 1: Учеб. Пособие для вузов / Общая ред. А.И. Галушкина. – М.: ИПРЖР, 2000. – 416 с.
8. Гладков Л.А., Курейчик В.В., Курейчик В.М. Генетические алгоритмы. – М.: Физматлит, 2006. – 320 с.
9. Головки В.А. Нейроинтеллект: Теория и применения. Книга 1 Организация и обучение нейронных сетей с прямыми и обратными связями. – Брест: БПИ, 1999. – 260 с. Книга 2 Самоорганизация, отказоустойчивость и применение нейронных сетей – Брест: БПИ, 1999. – 228 с.
10. Горбань А.Н., Россиев Д.А. Нейронные сети на персональном компьютере. – СПб.: Наука. РАН. 1996.

11. Горелик А.Л., Скрипкин В.А. Методы распознавания. – М.: Высш. шк., 1984. – 219 с.
12. Грязнов И.Е. Развитие методов автоматизированной настройки систем регулирования теплоэнергетических объектов. Дис. на соискание учен. степени кандидата техн. наук. – М.: МЭИ. 1998. – 173 с.
13. Давыдов Н.И., Идзон О.М., Симонова О.В. Определение параметров настройки ПИД-регуляторов по переходной характеристике объекта регулирования. // Теплоэнергетика. 1993. №10.
14. Давыдов Н.И., Идзон О.М., Симонова О.В. Определение параметров по переходной характеристике объекта регулирования. // Теплоэнергетика. 1993. №10.
15. Давыдов Н.И., Идзон О.М., Смирнова О.В. Определение параметров ПИД-регуляторов по переходной характеристике системы. // Теплоэнергетика. 1995. №10.
16. Денисенко В.В. Компьютерное управление технологическим процессом, экспериментом, оборудованием. – М.: Горячая линия – Телеком, 2009. – 608 с.
17. Дронов В.А. Автоматизированная настройка сложных систем регулирования теплоэнергетических объектов с применением косвенных критериев оптимальности. Дис. на соискание учен. степени кандидата техн. наук. – М.: МЭИ. 2001. – 237 с.
18. Дудников Е.Г. Основы автоматического регулирования тепловых процессов. – М.: ГЭИ. 1956.
19. Ежов А.А., Шумский С.А. Нейрокомпьютинг и его применение в экономике и бизнесе. – М.: Открытые системы. 1998. – 222 с.
20. Ицкович Э.Л. Контроль производства с помощью вычислительных машин. – М.: Энергия, 1975. – 416 с.
21. Ицкович Э.Л. Современные алгоритмы автоматического регулирования и их использование на предприятиях. // Автоматизация в промышленности. 2007 №6.

22. Ицкович Э.Л. Статистические методы при автоматизации производства. – М. Энергия, 1964.
23. Ключев А.С., Товарнов А.Г. Наладка систем автоматического регулирования котлоагрегатов. – М.: Энергия, 1970. – 280 с.
24. Кохонен Т. Ассоциативные запоминающие устройства. – М.: Мир, 1982. – 384 с.
25. Коцемир И.А. Разработка алгоритмов и технических средств автоматизированной настройки систем регулирования на базе микропроцессорной техники. Дис. на соискание учен. степени кандидата техн. наук. – М.: МЭИ. 1985. – 240 с.
26. Кузищин В.Ф., Зверьков В.П. Алгоритм расчета оптимума для итерационной процедуры автоматизированной настройки регуляторов. // Теория и практика построения и функционирования АСУ ТП. Сборник научных трудов. – М.: МЭИ. 1998.
27. Кузищин В.Ф., Зверьков В.П., Грязнов И.Е. Применение программируемых приборов Протар в системах регулирования барабанных котлов. // Теплоэнергетика. 1995. №10.
28. Махотило К.В. Разработка методик эволюционного синтеза нейросетевых компонентов систем управления. // Дис. на соискание учен. степени кандидата техн. наук. – Харьков: ХГПУ. 1998. – 182 с.
29. Минаев И.Г. Программируемые логические контроллеры. Практическое руководство для начинающего инженера. – Ставрополь: АГРУС, 2009. – 100 с.
30. Михайленко В.С., Харченко Р.Ю. Применение гибридных сетей в адаптивных системах управления теплоэнергетических объектов. // Автоматика и информационно-измерительная техника. 2012. №1.
31. Мойсюк Б.Н. Основы теории планирования эксперимента. – М.: Издательство МЭИ, 2005.
32. Омату С., Халид М., Юсоф Р. Нейроуправление и его приложения: пер. с англ. – М.: ИПРЖР, 2000. – 272 с.

33. Панько М.А. Расчет автоматических систем регулирования с дифференцированием вспомогательной регулируемой переменной. // Теплоэнергетика. 1998. №10.
34. Панько М.А. Расчет и моделирование автоматических систем регулирования в среде MathCAD. – М.: Издательство МЭИ, 2004. – 112 с.
35. Петров И.В. Отладка прикладных ПЛК программ в CoDeSys (часть 1) // Промышленные АСУ и контроллеры. 2006. №2.
36. Петров И.В. Отладка прикладных ПЛК программ в CoDeSys (часть 2) // Промышленные АСУ и контроллеры. 2006. №3.
37. Петров И.В. Отладка прикладных ПЛК программ в CoDeSys (часть 4) // Промышленные АСУ и контроллеры. 2006. №5.
38. Петров И.В. Отладка прикладных ПЛК программ в CoDeSys (часть 9) // Промышленные АСУ и контроллеры. 2007. №3.
39. Петров И.В. Программируемые контроллеры. Стандартные языки и инструменты. – М.: СОЛОН-Пресс, 2003. – 256 с.
40. Пикина Г.А., Верховский А.В. Об одном методе расчета оптимальных настроек типовых регуляторов. // Сб. научных трудов кафедры АСУТП. – М.: Издательство МЭИ, 1998.
41. Пикина Г.А., Щедеркина Т.Е., Волгин В.В. Идентификация объектов управления в теплоэнергетике. – М.: Издательский дом МЭИ, 2011. – 224 с.
42. Прикладные нечеткие системы: Пер. с япон. / К. Асаи, Д. Ватада, С. Иваи и др; под редакцией Т. Тэрано, К. Асаи, М. Сугэно. – М.: Мир, 1993 – 368 с.
43. Пупков К.А., Егупов Н.Д. Методы робастного, нейронечеткого и адаптивного управления: Учебник. М. : Изд-во МГТУ им. Н.Э. Баумана, 2001. – 744 с.
44. Репин А.И. Диагностика информационной подсистемы АСУ ТП ТЭЦ с использованием технологий искусственного интеллекта. Дис. на соискание учен. степени кандидата техн. наук. – М.: МЭИ. 2005. – 170 с.

45. Репин А.И., Сабанин В.Р., Смирнов Н.И. Автоматические системы регулирования на основе нейросетевых технологий. // Сборник трудов конференции Control 2003. – М.: Издательство МЭИ, 2003.
46. Репин А.И., Смирнов Н.И., Сабанин В.Р. Идентификация и адаптация САР с использованием эволюционных алгоритмов оптимизации. // Промышленные АСУ и контроллеры. 2008. №3.
47. Репин А.И., Смирнов Н.И., Сабанин В.Р., Шаровин И.М. Оптимальный синтез систем автоматического регулирования дробного порядка. // Автоматизация и ИТ в энергетике. 2011. №7.
48. Ротач В.Я. К расчету оптимальных параметров реальных ПИД регуляторов по экспертным критериям. // Промышленные АСУ и контроллеры. 2006. №2.
49. Ротач В.Я. О выборе критериев оптимальности систем управления с учетом случайного характера воздействий. // Промышленные АСУ и контроллеры. 2006. №9.
50. Ротач В.Я. Об особенностях критериев оптимальности систем автоматического управления технологическими процессами. // Сб. трудов конференции CONTROL 2008. – М.: Издательский дом МЭИ, 2008.
51. Ротач В.Я. Расчет динамики промышленных автоматических систем регулирования. – М.: Энергия. 1973. – 440 с.
52. Ротач В.Я. Расчет каскадных систем автоматического регулирования. // Теплоэнергетика. 1997. №10.
53. Ротач В.Я. Расчет настройки промышленных систем регулирования. – М.: Госэнергоиздат. 1961. 344 с.
54. Ротач В.Я. Расчет настройки реальных ПИД регуляторов. // Теплоэнергетика. 1993. №10.
55. Ротач В.Я. Расчет робастной настройки автоматических регуляторов. // Теплоэнергетика. 1944. №10.
56. Ротач В.Я. Теория автоматического управления теплоэнергетическими процессами. – М.: Энергоатомиздат. 1985. – 294 с.

57. Ротач В.Я. Теория автоматического управления. – М.: МЭИ, 2004. – 400 с.
58. Ротач В.Я., Кузищин В.Ф., Ключев А.С. и др. Автоматизация настройки систем управления. – М.: Энергоатомиздат. 1984. – 294 с.
59. Ротач В.Я., Кузищин В.Ф., Лысенко С.Б. Реализация функции автоматизированной настройки в микропроцессорном контроллере ПРОТАР. // Теплоэнергетика. 1988. №10.
60. Ротач В.Я., Кузищин В.Ф., Фишбейн М.В. Алгоритм автоматизированной настройки в микропроцессорном контроллере Ремиконт Р-130. // Приборы и системы управления. 1990. №11.
61. Рутковская Д., Пилиньский М., Рутковский Л. Нейронные сети, генетические алгоритмы и нечеткие системы. – М.: Горячая линия – Телеком, 2006. – 383 с.
62. Сабанин В.Р., Смирнов Н.И., Репин А.И. Модифицированный генетический алгоритм для задач оптимизации и управления. // Exponenta Pro. Математика в приложениях. 2004. №3.
63. Сайт «Теория и практика промышленной автоматизации»
URL: <http://www.systemautomation.ru/>
64. Смирнов Н.И., Сабанин В.Р., Репин А.И. О корректности настройки ПИД регулятора при аппроксимации переходной характеристики объекта регулирования апериодическим звеном с транспортным запаздыванием. // Промышленные АСУ и контроллеры. 2007. №1.
65. Смирнов Н.И., Сабанин В.Р., Репин А.И. Чувствительность и робастная настройка ПИД регуляторов с реальным дифференцированием. // Теплоэнергетика. 2007. №10.
66. Смирнов Н.И., Шаровин И.М. О выборе критерия оптимальности в численных методах расчета САР с ПИД регулятором. // Промышленные АСУ и контроллеры. 2010. №2.
67. Смирнов Н.И., Шаровин И.М. О выборе критерия оптимальности в численных методах расчета САР. // Промышленные АСУ и контроллеры. 2009. №5.

68. Терехов В.А., Ефимов Д.В., Тюкин И.Ю. Нейросетевые системы управления. – М.: Изд. Радиотехника, 2002. – 480 с.
69. Уоссермен Ф. Нейрокомпьютерная техника. – М.: Мир, 1992.
70. Усков А.А., Кузьмин А.В. Интеллектуальные технологии управления. Искусственные нейронные сети и нечеткая логика. – М.: Горячая линия – Телеком, 2004. – 143 с.
71. Хилькевич В.В. Искусственные нейронные сети и их применение: Учеб. пособие. – М.: Издательство МЭИ, 2004. – 68 с.
72. Чернодуб А.Н., Дзюба Д.А. Обзор методов нейроуправления. // Проблемы программирования. 2011. №2.
73. Чураков Е.П. Оптимальные и адаптивные системы. // Учебное пособие для вузов. – М.: Энергоатомиздат, 1987. – 256 с.
74. Шаровин И.М., Репин А.И., Смирнов Н.И., Панько М.А. Сб.тр. МНК ММТТ-24. Т6. Киев, 2011.
75. Шаровин И.М., Смирнов Н.И., Репин А.И. Применение искусственных нейронных сетей для адаптации САР в процессе их эксплуатации. // Промышленные АСУ и контроллеры. 2012. №4.
76. Шаровин И.М., Смирнов Н.И. Критерии оптимальности в численных методах расчета АСР. // Радиоэлектроника, электротехника и энергетика. Тез. докл. XV МНТК студентов и аспирантов: В 3-х т. М.: МЭИ, 2009. Т.3. С.219-221.
77. Шаровин И.М., Смирнов Н.И. О критериях оптимальности в численных методах расчета АСР с реальным ПИД-регулятором. // Радиоэлектроника, электротехника и энергетика. Тез. докл. XVI МНТК студентов и аспирантов: В 3-х т. М.: МЭИ, 2010. Т.3. С.259-261.
78. Шаровин И.М., Смирнов Н.И. О применении искусственных нейросетей в задачах адаптации АСР. // Радиоэлектроника, электротехника и энергетика. Тез. докл. XVII МНТК студентов и аспирантов: В 3-х т. М.: МЭИ, 2011. Т.3. С.219-220.

79. Шаровин И.М., Смирнов Н.И., Репин А.И. Аппроксимация функционала адаптивных настроек с использованием искусственных нейронных сетей. // Радиоэлектроника, электротехника и энергетика. Тез. докл. XVIII МНТК студентов и аспирантов: В 4-х т. М.: МЭИ, 2012. Т.4. С.231-232.
80. Шаровин И.М., Фролов А. Модернизация лабораторных стендов на базе контроллеров АС 800F “ABB”. // Радиоэлектроника, электротехника и энергетика. Тез. докл. XVIII МНТК студентов и аспирантов: В 4-х т. М.: МЭИ, 2012. Т.4. С.233.
81. Штейнберг Ш.Е., Серёжин Л.П. и др. Проблемы создания и эксплуатации эффективных систем регулирования. // Промышленные АСУ и контроллеры. 2004. №7.
82. Шубладзе А.М., Гуляев С.В. и др. Автоматические настраивающиеся адаптивные промышленные регуляторы. // АСУ для промышленных предприятий. 2007. №7.
83. Яковис Л.М. Простые способы расчета типовых регуляторов для сложных объектов промышленной автоматизации. // Автоматизация в промышленности. 2007. №6.
84. Astrom K.J., Hagglund T. Advanced PID control. ISA. The Instrumentation Systems and Automation Society, 2006. – 460 p.
85. Chang W.D., Hwang R.C., Hsieh J.G. A multivariable on-line adaptive PID controller using auto-tuning neurons // Engineering Applications of Artificial Intelligence. – 2003. – Vol. 16, Issue 1. – P. 57 – 63.
86. Cohen G.H., Coon G.A. Theoretical consideration of retarded control. // Transactions of the ASME, Vol.75. pp. 827-834, 1953
87. Control Conference. – San Diego, USA, 1999. – Vol. 3. – P. 1642 – 1656.
88. D’Emilia G., Marrab A., Natalea E. Use of neural networks for quick and accurate autotuning of PID controller // Robotics and Computer-Integrated Manufacturing. – 2007. – Vol. 23. – P. 170 – 179.

89. Dias F.M., Mota A.M. Comparison between Different Control Strategies using Neural Networks // 9th Mediterranean Conference on Control and Automation. – Dubrovnik, Croatia, 2001.
90. Fausett L.V. Fundamentals of neural networks: architectures, algorithms and applications, prentice hall, 1994.
91. Fleming P.J., Purshouse R.C. Genetic algorithms in control systems engineering. // IFAC professional brief. URL: <http://www.ifac-control.org>.
92. Hagan M.T., Demuth H.B. Neural networks for control // Proceedings of the American
93. Hunt K.J., Sbarbaro D., Zbikowski R., Gawthrop P.J. Neural Networks for Control: A Survey // Automatica 28. – 1992. – N 6. – P. 1083 – 1112.
94. IEC 61131-7 (2000) Programmable controllers. Part 7. Fuzzy control programming. 2000.
95. Kato M., Yamamoto T., Fujisawa S. A skill-based PID controller using artificial neural networks. // Computational intelligence for modeling. Control and automation. 2005. Vol.1. P. 702-707.
96. Kawafuku R., Sasaki M., Kato S. Self-tuning PID control of flexible microactuator using neural networks. // Systems man. and cybernetics. 1998. Vol.3. P. 3067-3072.
97. Li J., Xie J., Wu Z. Design of disturbance rejection PID controllers for time delay system based on genetic algorithms. // International conference neural networks and brain. 2005. Vol.2. P. 876-880.
98. Li Y., Ang K., Chong G. Patents, software and hardware for PID control. An overview and analysis of the current art. // IEEE Control systems magazine. Feb. 2006. P. 41-54.
99. Mamdani E. Application of fuzzy algorithms for control of simple dynamic plant. // Proc. inst. elect. eng. contr. sci. 1974. Vol.121. P. 1585-1588.
100. Mamdani E., Assilian S. An experiment in linguistic synthesis with a fuzzy logic controller. // Int. J. man-mach. stud. 1975. Vol.7. P. 1-13.

101. Omidvar O., Elliott D.L. eds. Neural Systems for Control // Academic Press, New York, 1997. – 272 c.
102. Psaltis D., Sideris A., Yamamura A.A. A Multilayered Neural Network Controller // IEEE Control Systems Magazine. – 1988. – Vol. 8, Issue 2. – P. 17 – 21.
103. Repin A., Sabanin V., Smirnov N. Artificial intelligence technologies in problems of diagnostic. // Proc. 12th Zittau fuzzy colloquium, Zittau. 2005.
104. Ronco E. Incremental Polynomial Controller Networks: Two Self-Organising Non-Linear Controllers // Ph.D. Disseration Thesis, Glasgow, 1997. – 207 c.
105. Saiful A., Omatu S. Neuromorphic self-tuning PID controller // Proceedings of IEEE International Conference on Neural Networks, San Francisco, USA, 1993. – P. 552 – 557.
106. Shepherd G., Koch C. Introduction to synaptic circuits. // The Synaptic organization of the brain. // Oxford university press. 1990. pp. 3-31.
107. Venayagamoorthy G.K., Harley R.G., Wunsch D.C. Implementation of Adaptive Critic-based Neurocontrollers for Turbogenerators in a Multimachine Power System”, IEEE Trans-actions on Neural Networks. – 2003. – Vol. 14, Issue 5. – P. 1047 – 1064.
108. Widrow B., Smith F.W. Pattern-recognizing control systems // Proceedings of Computer and Information Sciences. – Washington, USA – 1964. – Vol. 12. – P. 288 – 317.
109. Wolfram-M. Lippe, Institut für informatik westfälische Wilhelms universität–münster. URL: <http://wwwmath.uni-muenster.de/math/SoftComputing/>
110. Zadel L.A. Fuzzy sets. // Information and Control. 1965. №8. P. 338-353.
111. Ziegler J.G., Nichols N.B. Optimum settings for automatic controllers. // Transactions of the ASME, Vol.64. pp. 759-768, 1942.

ПРИЛОЖЕНИЯ

На всех представленных в приложениях графиках нанесены аббревиатуры используемых для расчета настроечных параметров регуляторов программ:

- MGA – настроечные параметры, полученные численными методами с созданием соответствующих имитационных моделей и применением для расчета оптимальных параметров алгоритма «Optim-MGA»;
- ИНС – настроечные параметры, воспроизведенные обученной нейросетью.


Критерии настройки всех представленных ниже нейросетей определяются выражением (3.3).

Приложение А. Обучение тренировочными множествами, полученными на минимум интегрального критерия по модулю, искусственных нейросетей на воспроизведение настроечных параметров исследуемых регуляторов


Таблица А1 – Результаты обучения нейросети, воспроизводящей настроечные параметры ПИ регулятора ($M=const$)

№	Параметры объекта регулирования			Параметры настройки ПИД регулятора, полученные с помощью			
				MGA		ИНС	
	k_o	T_o	τ_o	k_p	T_u	k_p	T_u
1	0.9	9	1.8	2.621	16.3	2.667	15.839
2	1.1	9	1.8	2.14	16.25	2.126	16.378
3	0.9	9	2.2	2.431	16.82	2.402	16.434
4	1.1	9	2.2	1.986	16.78	1.863	17.003
5	0.9	11	1.8	2.79	19.21	2.719	19.186
6	1.1	11	1.8	2.286	19.25	2.321	19.711
7	0.9	11	2.2	2.61	19.81	2.619	19.876
8	1.1	11	2.2	2.158	20.11	2.132	20.327
9	0.75	7.5	1.5	3.151	13.63	3.318	12.903
10	1.25	7.5	1.5	1.889	13.61	1.85	13.112
11	0.75	7.5	2.5	2.537	14.53	2.502	14.05
12	1.25	7.5	2.5	1.524	14.57	1.381	14.667
13	0.75	12.5	1.5	3.695	21.19	3.728	21.135
14	1.25	12.5	1.5	2.224	21.27	2.257	21.723
15	0.75	12.5	2.5	3.14	22.6	3.118	22.878
16	1.25	12.5	2.5	1.873	22.42	1.901	23.018
17	0.5	5	1	4.739	9.122	4.731	10.194
18	1.5	5	1	1.564	8.989	1.575	9.531
19	0.5	5	3	2.846	10.67	2.836	11.274
20	1.5	5	3	0.954	10.78	1.131	10.677
21	0.5	15	1	6.613	24.31	6.348	24.324
22	1.5	15	1	2.115	24.05	2.083	23.923
23	0.5	15	3	4.721	27.19	4.774	26.084
24	1.5	15	3	1.571	27.16	1.68	25.523


Критерии настройки нейросети для воспроизведения настроечных параметров ПИ регулятора $S_{k_p} = 2.98$, $S_{T_u} = 2.73$.



а)




б)




в)


Рисунок А1 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 3-6-2), воспроизводящей параметры ПИ регулятора, тестовым объектом регулирования ($k_o=1.4$, $\tau_o=1.5$ с., $T_o=11.5$ с.)



а)




б)




в)


Рисунок А2 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 3-6-2), воспроизводящей параметры ПИ регулятора, тестовым объектом регулирования ($k_o=0.85$, $\tau_o=3.0$ с., $T_o=14$ с.)



а)



б)




в)

Рисунок А3 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 3-6-2), воспроизводящей параметры ПИ регулятора, тестовым объектом регулирования ($k_O=1.3$, $\tau_O=2.0$ с., $T_O=8$ с.)


Таблица А2 – Результаты обучения нейросети, воспроизводящей настроечные параметры идеального ПИД регулятора ($M=const$)

№	Параметры объекта регулирования			Параметры настройки ПИД регулятора, полученные с помощью					
				MGA			ИНС		
	k_o	T_o	τ_o	k_p	T_u	T_d	k_p	T_u	T_d
1	1.1	11	2.2	8.324	7.970	4.509	8.081	8.255	4.563
2	1.1	11	1.8	10.66	9.397	3.939	10.19	7.972	4.213
3	1.1	9	2.2	6.506	7.412	3.948	6.525	7.354	3.906
4	1.1	9	1.8	8.274	7.187	3.540	8.017	6.794	3.654
5	0.9	11	2.2	10.11	8.138	4.562	9.931	8.423	4.616
6	0.9	11	1.8	12.65	6.443	4.549	13.08	7.469	4.264
7	0.9	9	2.2	7.930	8.015	3.917	7.720	8.165	3.956
8	0.9	9	1.8	10.17	6.994	3.732	10.04	6.740	3.700
9	1.25	12.5	2.5	7.332	9.341	5.063	7.268	9.233	5.135
10	1.25	12.5	1.5	14.44	7.088	4.096	14.55	7.714	4.096
11	1.25	7.5	2.5	3.989	7.804	3.636	4.343	7.576	3.540
12	1.25	7.5	1.5	7.300	5.655	3.024	6.928	5.893	2.909
13	0.75	12.5	2.5	12.21	10.04	4.987	12.62	9.892	5.258
14	0.75	12.5	1.5	23.93	6.331	4.238	23.65	6.313	4.288
15	0.75	7.5	2.5	6.667	7.499	3.728	6.483	8.003	3.616
16	0.75	7.5	1.5	12.10	5.583	3.070	12.66	5.684	2.956
17	1.5	15	3	6.105	10.48	6.308	6.473	10.29	5.854
18	1.5	15	1	28.68	5.602	3.491	28.78	5.343	3.619
19	1.5	5	3	1.812	7.443	2.923	2.272	7.648	3.052
20	1.5	5	1	6.112	3.859	2.042	5.887	4.067	2.025
21	0.5	15	3	18.24	11.56	6.306	17.75	11.09	6.324
22	0.5	15	1	33.02	4.684	7.083	32.44	4.433	7.018
23	0.5	5	3	5.429	7.759	2.801	5.375	7.180	2.869
24	0.5	5	1	18.06	4.393	2.010	18.51	4.121	2.116


Критерии настройки нейросети для воспроизведения настроечных параметров идеального ПИД регулятора $S_{k_p} = 3.78$, $S_{T_u} = 4.79$, $S_{T_d} = 2.83$.



а)




б)




в)


Рисунок А4 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 3-12-3), воспроизводящей параметры идеального ПИД регулятора, тестовым объектом регулирования ($k_o=1.4$, $\tau_o=1.5$ с., $T_o=11.5$ с.)



а)




б)




в)


Рисунок А5 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 3-12-3), воспроизводящей параметры идеального ПИД регулятора, тестовым объектом регулирования ($k_o=0.85$, $\tau_o=3.0$ с., $T_o=14$ с.)



а)



б)




в)

Рисунок А6 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 3-12-3), воспроизводящей параметры идеального ПИД регулятора, тестовым объектом регулирования ($k_O=1.3$, $\tau_O=2.0$ с., $T_O=8$ с.)


Таблица А3 – Результаты обучения нейросети, воспроизводящей настроечные параметры реального ПИД регулятора ($M=const$)

№	Параметры объекта регулирования			Параметры настройки ПИД регулятора, полученные с помощью					
				MGA			ИНС		
	k_o	T_o	τ_o	k_p	T_u	T_∂	k_p	T_u	T_∂
1	1.1	11	2.2	4.942	11.16	4.272	4.80	11.312	4.359
2	1.1	11	1.8	5.619	8.987	4.35	5.74	10.115	4.223
3	1.1	9	2.2	4.085	9.202	3.757	3.98	9.789	3.669
4	1.1	9	1.8	4.876	8.626	3.563	4.80	8.657	3.55
5	0.9	11	2.2	6.098	11.82	3.973	5.94	11.522	4.19
6	0.9	11	1.8	6.987	9.445	4.261	7.11	10.325	4.028
7	0.9	9	2.2	5.102	10.36	3.434	4.87	10.03	3.50
8	0.9	9	1.8	6.092	9.467	3.414	5.92	8.87	3.414
9	0.6	6	2.8	4.13	9.125	2.83	4.23	8.671	2.702
10	1.25	12.5	1.5	6.868	10.53	4.208	6.77	10.027	4.436
11	1.25	7.5	2.5	2.818	9.607	3.141	2.89	9.178	3.169
12	1.25	7.5	1.5	4.336	7.519	2.836	4.59	6.888	2.708
13	0.75	12.5	2.5	7.288	13.03	4.636	7.40	13.212	4.78
14	0.75	12.5	1.5	11.46	10.62	4.11	11.43	10.48	4.112
15	0.75	7.5	2.5	4.703	9.661	3.149	4.47	9.733	2.973
16	0.75	7.5	1.5	7.265	7.709	2.786	7.626	7.23	2.751
17	1.5	15	3	3.641	15.53	5.579	4.036	14.386	5.364
18	1.5	15	1	9.481	9.682	4.238	9.647	9.618	4.203
19	1.5	5	3	1.426	7.738	2.652	2.161	7.981	2.636
20	1.5	5	1	3.626	5.112	1.855	3.411	5.432	1.971
21	0.5	15	3	10.87	15.14	5.704	10.90	14.674	5.428
22	0.5	15	1	29.04	10.46	4.051	29.01	10.293	4.055
23	0.5	5	3	4.284	7.705	2.567	4.219	7.639	2.636
24	0.5	5	1	10.75	4.871	1.917	10.74	5.397	2.122


Критерии настройки нейросети для воспроизведения настроечных параметров реального ПИД регулятора $S_{k_p} = 4.82$, $S_{T_u} = 4.44$, $S_{T_\partial} = 3.09$.



а)




б)




в)


Рисунок А7 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 3-12-3), воспроизводящей параметры реального ПИД регулятора, тестовым объектом регулирования ($k_o=1.4$, $\tau_o=1.5$ с., $T_o=11.5$ с.)



а)




б)




в)


Рисунок А8 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 3-12-3), воспроизводящей параметры реального ПИД регулятора, тестовым объектом регулирования ($k_o=0.85$, $\tau_o=3.0$ с., $T_o=14$ с.)



а)



б)



в)

Рисунок А9 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 3-12-3), воспроизводящей параметры реального ПИД регулятора, тестовым объектом регулирования ($k_o=1.3$, $\tau_o=2.0$ с., $T_o=8$ с.)


Таблица А4 – Результаты обучения нейросети, воспроизводящей настроечные
параметры ПИ регулятора ($M=var$)

№	Параметры объекта регулирования			М	Параметры настройки ПИД регулятора, полученные с помощью			
					МГА		ИНС	
	k_o	T_o	τ_o		k_p	T_u	k_p	T_u
1	1.1	11	2.2	1.1	1.35	19.19	1.345	19.596
2	1.1	11	1.8	1.1	1.46	19.24	1.384	19.078
3	1.1	9	2.2	1.1	1.273	15.65	1.313	15.632
4	1.1	9	1.8	1.1	1.375	15.74	1.356	15.019
5	0.9	11	2.2	1.1	1.68	19.15	1.549	19.568
6	0.9	11	1.8	1.1	1.832	19.29	1.617	19.048
7	0.9	9	2.2	1.1	1.521	15.68	1.505	15.59
8	0.9	9	1.8	1.1	1.678	15.73	1.577	14.978
9	1.25	12.5	2.5	1.1	1.229	21.71	1.254	22.233
10	1.25	12.5	1.5	1.1	1.374	21.9	1.322	22.011
11	1.25	7.5	2.5	1.1	0.982	13.06	1.155	12.729
12	1.25	7.5	1.5	1.1	1.235	13.12	1.242	11.943
13	0.75	12.5	2.5	1.1	1.98	21.73	1.837	22.187
14	0.75	12.5	1.5	1.1	2.306	22.17	2.119	21.957
15	0.75	7.5	2.5	1.1	1.652	13.1	1.622	12.615
16	0.75	7.5	1.5	1.1	2.013	13.11	1.926	11.847
17	1.5	15	3	1.1	1.016	26.45	1.168	24.782
18	1.5	15	1	1.1	1.266	26.7	1.265	26.269
19	1.5	5	3	1.1	0.623	8.752	0.906	9.23
20	1.5	5	1	1.1	0.983	8.752	1.024	9.438
21	0.5	15	3	1.1	3.008	26.39	3.014	24.743
22	0.5	15	1	1.1	4.017	26.9	4.111	26.247
23	0.5	5	3	1.1	1.95	9.155	1.912	9.167
24	0.5	5	1	1.1	3.034	8.832	3.101	9.366
25	1.1	11	2.2	1.3	1.654	18.61	1.675	19.787
26	1.1	11	1.8	1.3	1.841	18.42	1.774	19.00
27	1.1	9	2.2	1.3	1.559	15.63	1.594	16.232
28	1.1	9	1.8	1.3	1.659	15.27	1.697	15.363
29	0.9	11	2.2	1.3	2.022	18.61	1.997	19.787
30	0.9	11	1.8	1.3	2.275	18.49	2.146	19.002
31	0.9	9	2.2	1.3	1.907	15.64	1.889	16.233
32	0.9	9	1.8	1.3	2.025	15.26	2.042	15.368
33	1.25	12.5	2.5	1.3	1.455	21.14	1.517	22.321
34	1.25	12.5	1.5	1.3	1.73	21.14	1.706	21.217


35	1.25	7.5	2.5	1.3	1.235	13.62	1.31	13.706
36	1.25	7.5	1.5	1.3	1.458	12.71	1.514	12.208
37	0.75	12.5	2.5	1.3	2.426	21.15	2.413	22.318
38	0.75	12.5	1.5	1.3	2.84	21.17	2.946	21.219
39	0.75	7.5	2.5	1.3	2.056	13.61	1.991	13.697
40	0.75	7.5	1.5	1.3	2.434	12.73	2.542	12.213
41	1.5	15	3	1.3	1.214	25.4	1.356	24.807
42	1.5	15	1	1.3	1.656	25.82	1.615	25.642
43	1.5	5	3	1.3	0.807	10.03	0.943	9.733
44	1.5	5	1	1.3	1.218	8.496	1.184	9.438
45	0.5	15	3	1.3	3.655	25.4	3.832	24.807
46	0.5	15	1	1.3	5.125	25.76	5.076	25.643
47	0.5	5	3	1.3	2.429	10.08	2.315	9.684
48	0.5	5	1	1.3	3.672	8.526	3.921	9.403
49	0.9	9	1.8	1.55	2.621	16.30	2.631	15.927
50	1.1	9	1.8	1.55	2.14	16.25	2.126	15.836
51	0.9	9	2.2	1.55	2.431	16.82	2.394	16.957
52	1.1	9	2.2	1.55	1.986	16.78	1.956	16.864
53	0.9	11	1.8	1.55	2.79	19.21	2.856	19.193
54	1.1	11	1.8	1.55	2.286	19.25	2.303	19.107
55	0.9	11	2.2	1.55	2.61	19.81	2.615	20.122
56	1.1	11	2.2	1.55	2.158	20.11	2.128	20.043
57	0.75	7.5	1.5	1.55	3.151	13.63	3.239	12.781
58	1.25	7.5	1.5	1.55	1.889	13.61	1.82	12.652
59	0.75	7.5	2.5	1.55	2.537	14.53	2.485	14.895
60	1.25	7.5	2.5	1.55	1.524	14.57	1.495	14.729
61	0.75	12.5	1.5	1.55	3.695	21.19	3.961	20.895
62	1.25	12.5	1.5	1.55	2.224	21.27	2.259	20.731
63	0.75	12.5	2.5	1.55	3.14	22.6	3.214	22.554
64	1.25	12.5	2.5	1.55	1.873	22.42	1.887	22.432
65	0.5	5	1	1.55	4.739	9.122	4.624	9.506
66	1.5	5	1	1.55	1.564	8.989	1.351	9.52
67	0.5	5	3	1.55	2.846	10.67	2.928	10.637
68	1.5	5	3	1.55	0.954	10.78	0.995	10.645
69	0.5	15	1	1.55	6.613	24.31	5.815	24.621
70	1.5	15	1	1.55	2.115	24.05	2.216	24.497
71	0.5	15	3	1.55	4.721	27.19	4.738	24.937
72	1.5	15	3	1.55	1.571	27.16	1.616	24.837

Критерии настройки нейросети для воспроизведения настроечных параметров


ПИ регулятора $S_{k_p} = 4.50$, $S_{T_u} = 3.16$.



а)




б)




в)


Рисунок А10 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 4-8-2), воспроизводящей параметры ПИ регулятора, тестовым объектом регулирования ($k_o=1.4$, $\tau_o=1.5$ с., $T_o=11.5$ с.), $M=1.55$



а)




б)




в)


Рисунок А11 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 4-8-2), воспроизводящей параметры ПИ регулятора, тестовым объектом регулирования ($k_o=0.85$, $\tau_o=3.0$ с., $T_o=14$ с.), $M=1.4$



а)



б)



в)

Рисунок А12 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 4-8-2), воспроизводящей параметры ПИ регулятора, тестовым объектом регулирования ($k_o=1.3$, $\tau_o=2.0$ с., $T_o=8$ с.), $M=1.3$

Таблица А5 – Результаты обучения нейросети, воспроизводящей настроечные параметры идеального ПИД регулятора ($M=var$)

№	Параметры объекта регулирования			M	Параметры настройки ПИД регулятора, полученные с помощью					
					МГА			ИНС		
	k_o	T_o	τ_o		k_p	T_u	T_d	k_p	T_u	T_d
1	1.1	11	2.2	1.1	5.531	14.33	5.812	5.355	14.481	5.838
2	1.1	11	1.8	1.1	6.822	13.49	5.629	6.746	13.729	5.606
3	1.1	9	2.2	1.1	4.543	12.48	4.841	4.397	12.652	4.847
4	1.1	9	1.8	1.1	5.586	12.01	4.619	5.346	11.974	4.629
5	0.9	11	2.2	1.1	6.803	14.53	5.713	6.90	14.524	5.831
6	0.9	11	1.8	1.1	8.311	13.55	5.612	8.796	13.754	5.612
7	0.9	9	2.2	1.1	5.568	12.59	4.789	5.51	12.694	4.839
8	0.9	9	1.8	1.1	6.805	11.95	4.643	6.814	11.994	4.633
9	1.25	12.5	2.5	1.1	4.899	16.47	6.527	4.645	15.741	6.50
10	1.25	12.5	1.5	1.1	8.344	13.76	6.114	8.517	13.744	5.901
11	1.25	7.5	2.5	1.1	2.953	11.15	4.212	3.175	11.151	4.165
12	1.25	7.5	1.5	1.1	4.878	9.833	3.923	4.69	9.67	3.661
13	0.75	12.5	2.5	1.1	8.015	15.82	6.82	8.818	15.847	6.47
14	0.75	12.5	1.5	1.1	14.06	14.15	5.944	16.649	13.745	5.944
15	0.75	7.5	2.5	1.1	4.932	11.32	4.138	5.087	11.258	4.138
16	0.75	7.5	1.5	1.1	8.063	9.645	4.01	8.454	9.642	3.685
17	1.5	15	3	1.1	4.035	19.15	8.08	3.91	17.025	7.158
18	1.5	15	1	1.1	13.95	13.37	6.257	13.634	12.573	5.956
19	1.5	5	3	1.1	1.445	8.323	3.128	2.386	8.479	3.328
20	1.5	5	1	1.1	4.041	6.414	2.682	4.039	6.397	2.579
21	0.5	15	3	1.1	12.22	19.72	7.83	12.795	17.182	7.094
22	0.5	15	1	1.1	40.11	12.45	6.697	36.946	12.451	6.111
23	0.5	5	3	1.1	4.32	8.30	3.134	4.507	8.66	3.307
24	0.5	5	1	1.1	12.12	6.495	2.692	12.553	6.232	2.605
25	1.1	11	2.2	1.3	6.899	9.801	5.135	6.58	10.447	5.128
26	1.1	11	1.8	1.3	8.778	9.076	4.76	8.623	9.317	4.773
27	1.1	9	2.2	1.3	5.514	9.492	4.239	5.193	9.192	4.303
28	1.1	9	1.8	1.3	6.933	8.336	4.105	6.604	8.259	4.017
29	0.9	11	2.2	1.3	8.474	10.30	4.952	8.357	10.492	5.134
30	0.9	11	1.8	1.3	10.75	9.581	4.611	10.972	9.333	4.795
31	0.9	9	2.2	1.3	6.747	9.202	4.307	6.469	9.222	4.307
32	0.9	9	1.8	1.3	8.401	8.445	4.114	8.316	8.264	4.035
33	1.25	12.5	2.5	1.3	6.086	11.32	5.773	5.704	11.851	5.831
34	1.25	12.5	1.5	1.3	11.28	8.615	4.928	11.415	8.872	4.878
35	1.25	7.5	2.5	1.3	3.472	8.67	3.884	3.517	8.541	3.768
36	1.25	7.5	1.5	1.3	6.052	6.695	3.503	5.798	6.737	3.235

37	0.75	12.5	2.5	1.3	10.11	11.49	5.716	10.502	12.011	5.819
38	0.75	12.5	1.5	1.3	19.05	9.366	4.744	20.103	8.867	4.961
39	0.75	7.5	2.5	1.3	5.779	8.515	3.976	5.674	8.598	3.752
40	0.75	7.5	1.5	1.3	10.16	6.84	3.439	10.217	6.687	3.282
41	1.5	15	3	1.3	5.082	14.44	6.64	4.759	13.612	6.645
42	1.5	15	1	1.3	20.94	7.125	4.595	18.545	7.716	4.733
43	1.5	5	3	1.3	1.623	7.49	2.958	2.448	7.054	2.96
44	1.5	5	1	1.3	5.085	4.926	2.231	4.896	5.046	2.438
45	0.5	15	3	1.3	15.22	14.43	6.852	15.255	13.952	6.572
46	0.5	15	1	1.3	60.91	7.189	4.671	39.227	7.721	4.961
47	0.5	5	3	1.3	4.881	7.085	3.081	4.913	7.083	2.921
48	0.5	5	1	1.3	14.89	5.102	2.338	14.892	4.933	2.48
49	1.1	11	2.2	1.55	8.324	7.97	4.509	8.335	8.124	4.497
50	1.1	11	1.8	1.55	10.66	9.397	3.939	11.218	6.896	4.123
51	1.1	9	2.2	1.55	6.506	7.412	3.948	6.431	7.743	3.948
52	1.1	9	1.8	1.55	8.274	7.187	3.54	8.502	6.651	3.635
53	0.9	11	2.2	1.55	10.11	8.138	4.562	10.193	8.137	4.535
54	0.9	11	1.8	1.55	12.65	6.443	4.549	13.62	6.883	4.172
55	0.9	9	2.2	1.55	7.93	8.015	3.917	7.803	7.752	3.982
56	0.9	9	1.8	1.55	10.17	6.994	3.732	10.347	6.636	3.677
57	1.25	12.5	2.5	1.55	7.332	9.341	5.063	7.287	9.154	5.066
58	1.25	12.5	1.5	1.55	14.44	7.088	4.096	15.289	6.124	4.082
59	1.25	7.5	2.5	1.55	3.989	7.804	3.636	4.144	7.953	3.636
60	1.25	7.5	1.5	1.55	7.3	5.655	3.024	7.649	5.715	3.036
61	0.75	12.5	2.5	1.55	12.21	10.04	4.987	12.234	9.238	5.133
62	0.75	12.5	1.5	1.55	23.93	6.331	4.238	23.28	6.076	4.22
63	0.75	7.5	2.5	1.55	6.667	7.499	3.728	6.479	7.992	3.686
64	0.75	7.5	1.5	1.55	12.1	5.583	3.07	12.49	5.655	3.123
65	1.5	15	3	1.55	6.105	10.48	6.308	6.107	10.497	5.802
66	1.5	15	1	1.55	28.68	5.602	3.491	24.309	5.147	3.855
67	1.5	5	3	1.55	1.812	7.443	2.923	2.642	7.429	2.955
68	1.5	5	1	1.55	6.112	3.859	2.042	6.567	4.712	2.417
69	0.5	15	3	1.55	18.24	11.56	6.306	17.254	10.739	5.844
70	0.5	15	1	1.55	33.02	4.684	7.083	40.05	5.128	4.159
71	0.5	5	3	1.55	5.429	7.759	2.801	5.517	7.437	2.967
72	0.5	5	1	1.55	18.06	4.393	2.01	17.597	4.63	2.497


Критерии настройки нейросети для воспроизведения настроечных параметров идеального ПИД регулятора $S_{k_p} = 6.53$, $S_{T_u} = 3.99$, $S_{T_d} = 4.21$.

Таблица А6 – Результаты обучения нейросети, воспроизводящей настроечные параметры реального ПИД регулятора ($M=var$)


№	Параметры объекта регулирования			M	Параметры настройки ПИД регулятора, полученные с помощью					
					MGA			ИНС		
	k_o	T_o	τ_o		k_p	T_u	T_d	k_p	T_u	T_d
1	1.1	11	2.2	1.1	3.418	15.45	5.138	3.341	15.875	5.366
2	1.1	11	1.8	1.1	3.89	14.93	5.073	3.596	15.446	5.227
3	1.1	9	2.2	1.1	2.98	13.03	4.277	2.99	13.256	4.361
4	1.1	9	1.8	1.1	3.409	12.59	4.214	3.203	12.745	4.223
5	0.9	11	2.2	1.1	4.141	15.15	5.271	4.088	15.986	5.369
6	0.9	11	1.8	1.1	4.78	15.11	4.994	4.423	15.577	5.225
7	0.9	9	2.2	1.1	3.657	13.34	4.19	3.599	13.365	4.364
8	0.9	9	1.8	1.1	4.189	12.75	4.153	3.879	12.874	4.22
9	1.25	12.5	2.5	1.1	2.994	17.34	5.917	3.002	17.383	5.996
10	1.25	12.5	1.5	1.1	4.187	16.50	5.50	3.624	16.50	5.686
11	1.25	7.5	2.5	1.1	2.095	11.25	3.732	2.392	11.248	3.643
12	1.25	7.5	1.5	1.1	3.017	10.63	3.465	2.762	10.003	3.349
13	0.75	12.5	2.5	1.1	4.984	17.31	5.944	5.033	17.582	6.008
14	0.75	12.5	1.5	1.1	6.915	16.29	5.586	6.65	16.789	5.675
15	0.75	7.5	2.5	1.1	3.506	11.44	3.655	3.604	11.39	3.662
16	0.75	7.5	1.5	1.1	4.963	10.38	3.568	4.384	10.244	3.332
17	1.5	15	3	1.1	2.483	20.6	7.186	2.562	18.784	6.611
18	1.5	15	1	1.1	4.775	18.02	6.395	4.217	17.555	6.121
19	1.5	5	3	1.1	1.144	8.217	2.713	1.901	8.448	2.75
20	1.5	5	1	1.1	2.504	7.019	2.343	2.314	6.81	2.386
21	0.5	15	3	1.1	7.394	20.4	7.295	7.166	18.986	6.632
22	0.5	15	1	1.1	14.54	18.77	6.249	15.545	17.913	6.083
23	0.5	5	3	1.1	3.421	8.086	2.794	3.622	8.267	2.799
24	0.5	5	1	1.1	7.49	7.027	2.343	5.836	6.908	2.355
25	1.1	11	2.2	1.3	4.056	11.71	4.762	3.992	11.973	4.849
26	1.1	11	1.8	1.3	4.744	11.11	4.602	4.549	11.028	4.621
27	1.1	9	2.2	1.3	3.499	10.56	3.936	3.49	10.046	3.98
28	1.1	9	1.8	1.3	4.034	9.413	3.968	3.895	9.203	3.787
29	0.9	11	2.2	1.3	4.987	12.15	4.62	5.019	12.065	4.848
30	0.9	11	1.8	1.3	5.815	11.36	4.547	5.852	11.143	4.614
31	0.9	9	2.2	1.3	4.21	9.871	4.128	4.312	10.112	3.976
32	0.9	9	1.8	1.3	4.983	9.786	3.836	4.902	9.284	3.778
33	1.25	12.5	2.5	1.3	3.566	13.32	5.392	3.498	13.836	5.517
34	1.25	12.5	1.5	1.3	5.309	11.74	4.904	5.012	11.498	4.963
35	1.25	7.5	2.5	1.3	2.38	9.041	3.689	2.657	9.141	3.411
36	1.25	7.5	1.5	1.3	3.564	7.935	3.273	3.32	7.434	3.063
37	0.75	12.5	2.5	1.3	6.043	14.24	5.195	6.178	14.02	5.531

38	0.75	12.5	1.5	1.3	8.948	12.35	4.733	10.63	11.838	4.935
39	0.75	7.5	2.5	1.3	4.005	9.423	3.564	4.237	9.201	3.407
40	0.75	7.5	1.5	1.3	6.003	8.252	3.202	5.962	7.559	3.033
41	1.5	15	3	1.3	2.962	15.69	6.567	2.896	16.116	6.254
42	1.5	15	1	1.3	6.723	11.88	5.302	7.457	12.113	5.307
43	1.5	5	3	1.3	1.289	7.956	2.63	1.999	7.738	2.605
44	1.5	5	1	1.3	2.985	5.445	2.119	2.723	5.78	2.301
45	0.5	15	3	1.3	8.939	16.11	6.432	8.661	16.287	6.303
46	0.5	15	1	1.3	20.2	12.12	5.223	20.365	12.826	5.218
47	0.5	5	3	1.3	3.854	8.082	2.512	4.179	7.555	2.611
48	0.5	5	1	1.3	8.716	5.104	2.279	9.777	5.815	2.261
49	1.1	11	2.2	1.55	4.942	11.16	4.272	4.926	11.15	4.222
50	1.1	11	1.8	1.55	5.619	8.987	4.35	5.571	10.09	3.953
51	1.1	9	2.2	1.55	4.085	9.202	3.757	4.266	9.726	3.609
52	1.1	9	1.8	1.55	4.876	8.626	3.563	4.767	8.82	3.385
53	0.9	11	2.2	1.55	6.098	11.82	3.973	6.209	11.264	4.195
54	0.9	11	1.8	1.55	6.987	9.445	4.261	7.084	10.226	3.92
55	0.9	9	2.2	1.55	5.102	10.36	3.434	5.331	9.834	3.584
56	0.9	9	1.8	1.55	6.092	9.467	3.414	5.994	8.942	3.356
57	1.25	12.5	2.5	1.55	4.33	12.41	4.751	4.289	12.814	4.835
58	1.25	12.5	1.5	1.55	6.868	10.53	4.208	6.005	10.03	4.151
59	1.25	7.5	2.5	1.55	2.818	9.607	3.141	3.123	9.143	3.279
60	1.25	7.5	1.5	1.55	4.336	7.519	2.836	3.995	7.309	2.858
61	0.75	12.5	2.5	1.55	7.288	13.03	4.636	7.624	13.008	4.785
62	0.75	12.5	1.5	1.55	11.46	10.62	4.11	11.839	10.379	4.052
63	0.75	7.5	2.5	1.55	4.703	9.661	3.149	5.236	9.334	3.23
64	0.75	7.5	1.5	1.55	7.265	7.709	2.786	7.032	7.545	2.8
65	1.5	15	3	1.55	3.641	15.53	5.579	3.475	15.127	5.621
66	1.5	15	1	1.55	9.481	9.682	4.238	8.645	9.71	4.365
67	1.5	5	3	1.55	1.426	7.738	2.652	2.181	7.978	2.671
68	1.5	5	1	1.55	3.626	5.112	1.855	3.149	5.818	2.277
69	0.5	15	3	1.55	10.87	15.14	5.704	10.449	15.192	5.586
70	0.5	15	1	1.55	29.04	10.46	4.051	25.794	10.299	4.121
71	0.5	5	3	1.55	4.284	7.705	2.567	5.121	8.058	2.611
72	0.5	5	1	1.55	10.75	4.871	1.917	10.552	5.998	2.224


Критерии настройки нейросети для воспроизведения настроечных параметров реального ПИД регулятора $S_{k_p} = 2.74$, $S_{T_u} = 3.74$, $S_{T_d} = 3.54$.



а)




б)




в)


Рисунок А13 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 4-15-3), воспроизводящей параметры реального ПИД регулятора, тестовым объектом регулирования ($k_o=1.4$, $\tau_o=1.5$ с., $T_o=11.5$ с.), $M=1.55$



а)




б)




в)


Рисунок А14 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 4-15-3), воспроизводящей параметры реального ПИД регулятора, тестовым объектом регулирования ($k_o=0.85$, $\tau_o=3.0$ с., $T_o=14$ с.), $M=1.4$



а)



б)



в)

Рисунок А15 - Переходные процессы по каналам регулирующего органа (а) и задания (б) и АЧХ замкнутого контура (в). Проверка обученной нейросети (структура 4-15-3), воспроизводящей параметры реального ПИД регулятора, тестовым объектом регулирования ($k_o=1.3$, $\tau_o=2.0$ с., $T_o=8$ с.), $M=1.3$

Приложение Б. Обучение тренировочными множествами, полученными на минимум интегрального критерия по модулю, искусственной нейросети на воспроизведение настроечных параметров регуляторов каскадной адаптивной системы регулирования

Таблица Б1 – Результаты обучения нейросети, воспроизводящей настроечные параметры корректирующего (П) и стабилизирующего (ПИ) регуляторов ($M=const$) в каскадной адаптивной АСР

№	Параметры объектов регулирования для контуров					Настроечные параметры регуляторов, найденные с помощью					
						МГА			ИНС		
	внешнего			внутренне го		корр.	стаб.		корр.	стаб.	
	k_Y	T_Y	τ_Y	k_Z	T_Z	k_P	k_P	T_{Π}	k_P	k_P	T_{Π}
1.	1.1	11	4.4	0.55	5.5	9.15	1.03	27.81	9.14	1.04	28.37
2.	1.1	11	3.6	0.55	5.5	9.14	1.12	27.76	9.13	1.12	28.11
3.	1.1	9	4.4	0.55	5.5	9.11	0.97	22.64	9.12	0.97	22.52
4.	1.1	9	3.6	0.55	5.5	9.10	1.08	22.65	9.11	1.05	21.95
5.	0.9	11	4.4	0.55	5.5	9.15	1.27	28.24	9.14	1.29	28.35
6.	0.9	11	3.6	0.55	5.5	9.13	1.38	27.92	9.13	1.37	28.04
7.	0.9	9	4.4	0.55	5.5	9.12	1.20	23.15	9.12	1.20	22.31
8.	0.9	9	3.6	0.55	5.5	9.10	1.30	21.98	9.11	1.29	21.65
9.	1.1	11	4.4	0.45	4.5	9.38	0.85	29.28	9.38	0.85	29.57
10.	1.1	11	3.6	0.45	4.5	9.36	0.91	28.69	9.37	0.90	29.34
11.	1.1	9	4.4	0.45	4.5	9.36	0.81	23.76	9.37	0.80	23.76
12.	1.1	9	3.6	0.45	4.5	9.33	0.88	23.33	9.34	0.85	23.10
13.	0.9	11	4.4	0.45	4.5	9.38	1.05	29.95	9.38	1.04	30.08
14.	0.9	11	3.6	0.45	4.5	9.36	1.12	29.08	9.37	1.13	29.81
15.	0.9	9	4.4	0.45	4.5	9.36	0.99	23.76	9.37	0.96	23.67
16.	0.9	9	3.6	0.45	4.5	9.33	1.06	22.88	9.35	1.05	22.88
17.	1.1	11	4.4	0.55	4.5	7.68	1.04	29.31	7.68	1.03	29.63
18.	1.1	11	3.6	0.55	4.5	7.66	1.12	29.05	7.67	1.12	29.64
19.	1.1	9	4.4	0.55	4.5	7.66	0.99	23.92	7.68	0.96	23.94
20.	1.1	9	3.6	0.55	4.5	7.62	1.09	23.75	7.67	1.05	23.75
21.	0.9	11	4.4	0.55	4.5	7.68	1.29	30.16	7.68	1.29	29.61
22.	0.9	11	3.6	0.55	4.5	7.66	1.36	28.86	7.67	1.38	29.57
23.	0.9	9	4.4	0.55	4.5	7.66	1.20	23.70	7.68	1.20	23.53

24.	0.9	9	3.6	0.55	4.5	7.63	1.32	23.35	7.67	1.32	23.26
25.	1.1	11	4.4	0.45	5.5	11.19	0.86	28.67	11.18	0.85	28.69
26.	1.1	11	3.6	0.45	5.5	11.16	0.92	28.09	11.18	0.91	28.07
27.	1.1	9	4.4	0.45	5.5	11.14	0.80	22.50	11.18	0.80	22.65
28.	1.1	9	3.6	0.45	5.5	11.12	0.88	22.29	11.18	0.86	21.42
29.	0.9	11	4.4	0.45	5.5	11.18	1.05	28.95	11.18	1.04	29.25
30.	0.9	11	3.6	0.45	5.5	11.17	1.13	27.95	11.18	1.13	28.55
31.	0.9	9	4.4	0.45	5.5	11.15	0.97	22.54	11.18	0.97	22.64
32.	0.9	9	3.6	0.45	5.5	11.12	1.05	21.49	11.18	1.05	21.30
33.	1.25	12.5	5	0.55	5.5	9.19	0.90	33.37	9.19	0.88	31.00
34.	1.25	12.5	3	0.55	5.5	9.17	1.07	31.71	9.17	1.07	30.70
35.	1.25	7.5	5	0.55	5.5	9.16	0.75	19.09	9.16	0.78	19.31
36.	1.25	7.5	3	0.55	5.5	9.12	0.96	17.80	9.12	0.94	18.28
37.	0.75	12.5	5	0.55	5.5	9.19	1.50	33.46	9.21	1.47	31.83
38.	0.75	12.5	3	0.55	5.5	9.17	1.77	31.37	9.17	1.58	31.48
39.	0.75	7.5	5	0.55	5.5	9.17	1.23	18.66	9.16	1.27	19.10
40.	0.75	7.5	3	0.55	5.5	9.12	1.58	17.46	9.12	1.52	18.03
41.	1.25	12.5	5	0.45	4.5	9.41	0.73	34.09	9.41	0.77	31.68
42.	1.25	12.5	3	0.45	4.5	9.39	0.86	32.60	9.39	0.87	31.46
43.	1.25	7.5	5	0.45	4.5	9.41	0.63	20.21	9.40	0.71	20.07
44.	1.25	7.5	3	0.45	4.5	9.33	0.79	18.55	9.31	0.79	18.64
45.	0.75	12.5	5	0.45	4.5	9.41	1.22	34.03	9.41	1.24	32.71
46.	0.75	12.5	3	0.45	4.5	9.39	1.45	33.25	9.39	1.45	32.47
47.	0.75	7.5	5	0.45	4.5	9.41	1.04	19.76	9.41	1.03	19.86
48.	0.75	7.5	3	0.45	4.5	9.33	1.34	19.07	9.32	1.37	18.30
49.	1.25	12.5	5	0.55	4.5	7.70	0.90	34.06	7.69	0.90	31.77
50.	1.25	12.5	3	0.55	4.5	7.68	1.06	33.21	7.67	1.07	31.77
51.	1.25	7.5	5	0.55	4.5	7.70	0.78	20.48	7.69	0.78	20.48
52.	1.25	7.5	3	0.55	4.5	7.64	0.97	18.82	7.67	0.99	19.51
53.	0.75	12.5	5	0.55	4.5	7.70	1.49	33.87	7.69	1.46	32.52
54.	0.75	12.5	3	0.55	4.5	7.68	1.75	32.38	7.67	1.60	32.42
55.	0.75	7.5	5	0.55	4.5	7.70	1.27	19.82	7.69	1.27	19.83
56.	0.75	7.5	3	0.55	4.5	7.64	1.63	19.05	7.67	1.59	18.72
57.	1.25	12.5	5	0.45	5.5	11.24	0.73	33.16	11.17	0.76	31.17
58.	1.25	12.5	3	0.45	5.5	11.21	0.87	31.14	11.18	0.88	30.59
59.	1.25	7.5	5	0.45	5.5	11.21	0.60	18.69	11.17	0.71	19.31
60.	1.25	7.5	3	0.45	5.5	11.15	0.78	17.67	11.17	0.79	18.03
61.	0.75	12.5	5	0.45	5.5	11.22	1.22	32.85	11.17	1.23	32.59
62.	0.75	12.5	3	0.45	5.5	11.21	1.47	32.15	11.18	1.43	32.10
63.	0.75	7.5	5	0.45	5.5	11.20	1.03	19.40	11.17	1.03	19.42
64.	0.75	7.5	3	0.45	5.5	11.14	1.28	17.27	11.18	1.28	18.08

Приложение В. Реализация имитационной модели одноконтурной АСР и поиск оптимальных настроечных параметров реального ПИД регулятора

Эволюционный алгоритм многопараметрической, многоэкстремальной оптимизации "Optim-MGA" в виде пользовательской версии для программного пакета MathCAD

```

MGA(N, μ, xx, xn, ε, Sqr) :=
  m ← floor  $\left[ \frac{[(\mu + N) + 1]}{9} \right]$ 
  for j ∈ 0..m
    for i ∈ 0..N - 1
       $x_{1,j} \leftarrow \text{rnd}(xx_1 - xn_1) + xn_1$ 
       $x_{N,j} \leftarrow \text{Sqr}(x^{(j)})$ 
  z ← 0
  x ← rsort(x, N)
  while  $|x_{N,m} - x_{N,0}| > \varepsilon$ 
    z ← z + 1
    r ← 0
    while r ≤ ceil(1·m)
      r ← r + 1
      h ← 0
      while h = 0
        Mt ← 0
        for j ∈ 0..N
           $P_j \leftarrow \text{floor}(\text{rnd}(9 \cdot m))$ 
          for jj ∈ 1..N
            for j̄j ∈ 0..j - 1
              Mt ← 1 if  $P_{j̄j} = P_j$ 
          h ← 1 if Mt = 0
        for j ∈ 0..N
           $as^{(j)} \leftarrow x^{(P_j)}$ 
        k ← 0
        as ← rsort(as, N)
        while  $|as_{N,N} - as_{N,0}| > \varepsilon$ 
          a ← as
          for i ∈ 0..N - 1

```

				$a_{i,N+1} \leftarrow \frac{1}{N} \cdot \left[\left(\sum_{j=0}^N a_{i,j} \right) - a_{i,N} \right]$ $a_{i,N+2} \leftarrow a_{i,N+1} + 1 \cdot (a_{i,N+1} - a_{i,N})$ $a_{N,N+2} \leftarrow \text{Sqr}(a^{\langle N+2 \rangle})$ if $a_{N,N+2} \leq a_{N,0}$ <table border="1" style="border-collapse: collapse; width: 100%;"> <tr> <td style="width: 30%;"></td> <td style="width: 30%;"></td> <td style="width: 30%;"></td> <td style="width: 10%;"></td> <td> for $i \in 0..N-1$ $a_{i,N+3} \leftarrow a_{i,N+1} + 2 \cdot (a_{i,N+2} - a_{i,N+1})$ $a_{N,N+3} \leftarrow \text{Sqr}(a^{\langle N+3 \rangle})$ $a^{\langle N \rangle} \leftarrow a^{\langle N+3 \rangle} \quad \text{if } a_{N,N+3} \leq a_{N,0}$ $a^{\langle N \rangle} \leftarrow a^{\langle N+2 \rangle} \quad \text{otherwise}$ </td> </tr> </table> otherwise <table border="1" style="border-collapse: collapse; width: 100%;"> <tr> <td style="width: 30%;"></td> <td style="width: 30%;"></td> <td style="width: 30%;"></td> <td style="width: 10%;"></td> <td> $a^{\langle N \rangle} \leftarrow a^{\langle N+2 \rangle} \quad \text{if } a_{N,N+2} < a_{N,N-1}$ $a^{\langle N \rangle} \leftarrow a^{\langle N+2 \rangle} \quad \text{if } a_{N,N+2} < a_{N,N} \quad \text{otherwise}$ for $i \in 0..N-1$ $a_{i,N+4} \leftarrow a_{i,N+1} + 0.5 \cdot (a_{i,N} - a_{i,N+1})$ $a_{N,N+4} \leftarrow \text{Sqr}(a^{\langle N+4 \rangle})$ for $j \in 0..N$ <div style="text-align: right;">if $a_{N,N+4} \geq a_{N,N}$</div> <table border="1" style="border-collapse: collapse; width: 100%;"> <tr> <td style="width: 30%;"></td> <td style="width: 30%;"></td> <td style="width: 30%;"></td> <td style="width: 10%;"></td> <td> for $i \in 0..N-1$ $a_{i,j} \leftarrow a_{i,0} + 0.5 \cdot (a_{i,j} - a_{i,0})$ $a_{N,j} \leftarrow \text{Sqr}(a^{\langle j \rangle})$ </td> </tr> </table> $a^{\langle N \rangle} \leftarrow a^{\langle N+4 \rangle} \quad \text{otherwise}$ for $j \in 0..N$ $as^{\langle j \rangle} \leftarrow a^{\langle j \rangle}$ $as \leftarrow \text{rsort}(as, N)$ $k \leftarrow k + 1$ return a if $k > 100 \cdot N$ </td> </tr> </table> $x^{\langle \text{floor}(9 \cdot m) + r \rangle} \leftarrow a^{\langle 0 \rangle}$ $x \leftarrow \text{rsort}(x, N)$ return x if $z > 2 \cdot m$					for $i \in 0..N-1$ $a_{i,N+3} \leftarrow a_{i,N+1} + 2 \cdot (a_{i,N+2} - a_{i,N+1})$ $a_{N,N+3} \leftarrow \text{Sqr}(a^{\langle N+3 \rangle})$ $a^{\langle N \rangle} \leftarrow a^{\langle N+3 \rangle} \quad \text{if } a_{N,N+3} \leq a_{N,0}$ $a^{\langle N \rangle} \leftarrow a^{\langle N+2 \rangle} \quad \text{otherwise}$					$a^{\langle N \rangle} \leftarrow a^{\langle N+2 \rangle} \quad \text{if } a_{N,N+2} < a_{N,N-1}$ $a^{\langle N \rangle} \leftarrow a^{\langle N+2 \rangle} \quad \text{if } a_{N,N+2} < a_{N,N} \quad \text{otherwise}$ for $i \in 0..N-1$ $a_{i,N+4} \leftarrow a_{i,N+1} + 0.5 \cdot (a_{i,N} - a_{i,N+1})$ $a_{N,N+4} \leftarrow \text{Sqr}(a^{\langle N+4 \rangle})$ for $j \in 0..N$ <div style="text-align: right;">if $a_{N,N+4} \geq a_{N,N}$</div> <table border="1" style="border-collapse: collapse; width: 100%;"> <tr> <td style="width: 30%;"></td> <td style="width: 30%;"></td> <td style="width: 30%;"></td> <td style="width: 10%;"></td> <td> for $i \in 0..N-1$ $a_{i,j} \leftarrow a_{i,0} + 0.5 \cdot (a_{i,j} - a_{i,0})$ $a_{N,j} \leftarrow \text{Sqr}(a^{\langle j \rangle})$ </td> </tr> </table> $a^{\langle N \rangle} \leftarrow a^{\langle N+4 \rangle} \quad \text{otherwise}$ for $j \in 0..N$ $as^{\langle j \rangle} \leftarrow a^{\langle j \rangle}$ $as \leftarrow \text{rsort}(as, N)$ $k \leftarrow k + 1$ return a if $k > 100 \cdot N$					for $i \in 0..N-1$ $a_{i,j} \leftarrow a_{i,0} + 0.5 \cdot (a_{i,j} - a_{i,0})$ $a_{N,j} \leftarrow \text{Sqr}(a^{\langle j \rangle})$
				for $i \in 0..N-1$ $a_{i,N+3} \leftarrow a_{i,N+1} + 2 \cdot (a_{i,N+2} - a_{i,N+1})$ $a_{N,N+3} \leftarrow \text{Sqr}(a^{\langle N+3 \rangle})$ $a^{\langle N \rangle} \leftarrow a^{\langle N+3 \rangle} \quad \text{if } a_{N,N+3} \leq a_{N,0}$ $a^{\langle N \rangle} \leftarrow a^{\langle N+2 \rangle} \quad \text{otherwise}$															
				$a^{\langle N \rangle} \leftarrow a^{\langle N+2 \rangle} \quad \text{if } a_{N,N+2} < a_{N,N-1}$ $a^{\langle N \rangle} \leftarrow a^{\langle N+2 \rangle} \quad \text{if } a_{N,N+2} < a_{N,N} \quad \text{otherwise}$ for $i \in 0..N-1$ $a_{i,N+4} \leftarrow a_{i,N+1} + 0.5 \cdot (a_{i,N} - a_{i,N+1})$ $a_{N,N+4} \leftarrow \text{Sqr}(a^{\langle N+4 \rangle})$ for $j \in 0..N$ <div style="text-align: right;">if $a_{N,N+4} \geq a_{N,N}$</div> <table border="1" style="border-collapse: collapse; width: 100%;"> <tr> <td style="width: 30%;"></td> <td style="width: 30%;"></td> <td style="width: 30%;"></td> <td style="width: 10%;"></td> <td> for $i \in 0..N-1$ $a_{i,j} \leftarrow a_{i,0} + 0.5 \cdot (a_{i,j} - a_{i,0})$ $a_{N,j} \leftarrow \text{Sqr}(a^{\langle j \rangle})$ </td> </tr> </table> $a^{\langle N \rangle} \leftarrow a^{\langle N+4 \rangle} \quad \text{otherwise}$ for $j \in 0..N$ $as^{\langle j \rangle} \leftarrow a^{\langle j \rangle}$ $as \leftarrow \text{rsort}(as, N)$ $k \leftarrow k + 1$ return a if $k > 100 \cdot N$					for $i \in 0..N-1$ $a_{i,j} \leftarrow a_{i,0} + 0.5 \cdot (a_{i,j} - a_{i,0})$ $a_{N,j} \leftarrow \text{Sqr}(a^{\langle j \rangle})$										
				for $i \in 0..N-1$ $a_{i,j} \leftarrow a_{i,0} + 0.5 \cdot (a_{i,j} - a_{i,0})$ $a_{N,j} \leftarrow \text{Sqr}(a^{\langle j \rangle})$															

 $x^{\langle 0 \rangle}$

Параметры объекта регулирования

$k := 1$	коэффициент усиления
$T := 10$	постоянная времени
$\tau := 2$	запаздывание

Параметры имитационной модели АЧХ замкнутой АСР для оценки показателя колебательности М:

$N1 := 1000$	количество точек частотного диапазона
$i := 0..N1$	интервал (в точках) частотного диапазона
$w_1 := (i + 1) \cdot 0.001$	частотный диапазон
$Mz := 1.55$	частотный показатель колебательности
$shtraf := 10^5$	масштабный коэффициент функции штрафа для обеспечения заданного запаса устойчивости.
$\omega_{end} := N1 \cdot 0.001$	верхний предел частоты при расчете квадратичного интегрального критерия по аналитической зависимости
$f := \sqrt{-1}$	мнимая единица

Параметры имитационной модели исследуемой АСР во временно области:

$te := 100$	время переходного процесса
$N := 2000$	количество точек в переходном процессе
$dt := \frac{te}{N}$	шаг переходного процесса
$j := 0..N$	диапазон переходного процесса в точках
$t_j := dt \cdot j$	временной диапазон переходного процесса
$kf := 8$	

Имитационная модель одноконтурной АСР с реальным ПИД регулятором

$$\begin{aligned}
\text{PID_REAL_MOD}(W) := & \left(\mu_0 \leftarrow 0 \quad \mu s_0 \leftarrow 0 \quad x_0 \leftarrow 0 \quad x1_0 \leftarrow 0 \quad x2_0 \leftarrow 0 \quad x3_0 \leftarrow 0 \quad x4_0 \leftarrow 0 \quad e1_0 \leftarrow 0 \right) \\
& \left(x5_0 \leftarrow 0 \quad x6_0 \leftarrow 0 \quad x7_0 \leftarrow 0 \quad x8_0 \leftarrow 0 \quad \lambda \leftarrow 1 \quad x9_0 \leftarrow 0 \quad x10_0 \leftarrow 0 \quad I \leftarrow 0 \right) \\
& u \leftarrow 0 \\
& \text{for } j \in 0.. \frac{te}{dt} \\
& \quad x_{j+1} \leftarrow \lambda + \mu_j \\
& \quad x1_{j+1} \leftarrow \text{if} \left(t_j < \tau, 0, x_{j-\frac{\tau}{dt}} \right) \\
& \quad x2_{j+1} \leftarrow x2_j + dt \cdot \left[\frac{1}{2} \cdot \left[\frac{k \cdot x1_j - x2_j}{T} + \frac{k \cdot x1_{j+1} - \left(x2_j + dt \cdot \frac{k \cdot x1_j - x2_j}{T} \right)}{T} \right] \right] \\
& \quad x3_{j+1} \leftarrow x3_j + dt \cdot \left[\frac{1}{2} \cdot \left[\frac{1 \cdot x2_j - x3_j}{T} + \frac{1 \cdot x2_{j+1} - \left(x3_j + dt \cdot \frac{1 \cdot x2_j - x3_j}{T} \right)}{T} \right] \right] \\
& \quad e1_{j+1} \leftarrow u - x3_{j+1} \\
& \quad e2_{j+1} \leftarrow \frac{e1_{j+1} - e1_j}{dt} \\
& \quad x4_{j+1} \leftarrow x4_j + dt \cdot \left[\frac{1}{2} \cdot \left[\frac{1 \cdot e2_j - x4_j}{\frac{W_2}{kf}} + \frac{1 \cdot e2_{j+1} - \left(x4_j + dt \cdot \frac{1 \cdot e2_j - x4_j}{\frac{W_2}{kf}} \right)}{\frac{W_2}{kf}} \right] \right] \\
& \quad x5_{j+1} \leftarrow x5_j + dt \cdot \left[\frac{1}{2} \cdot \left[\frac{1 \cdot x4_j - x5_j}{\frac{W_2}{kf}} + \frac{1 \cdot x4_{j+1} - \left(x5_j + dt \cdot \frac{1 \cdot x4_j - x5_j}{\frac{W_2}{kf}} \right)}{\frac{W_2}{kf}} \right] \right] \\
& \quad e3_{j+1} \leftarrow \frac{x5_{j+1} - x5_j}{dt} \\
& \quad \mu s_{j+1} \leftarrow W_0 \cdot e2_{j+1} + \frac{W_0}{W_1} \cdot e1_{j+1} + W_0 \cdot W_2 \cdot e3_{j+1} \\
& \quad \mu_{j+1} \leftarrow \mu_j + \mu s_{j+1} \cdot dt \\
& \quad I \leftarrow I + |x3_{j+1}| \cdot dt
\end{aligned}$$

```

for i ∈ 0..N1
    
$$A_i \leftarrow \frac{k \cdot \frac{e^{-\tau \cdot w_i \cdot f}}{[T \cdot (w_i \cdot f) + 1]^2} \cdot \left[ W_0 + \frac{W_0}{W_1 \cdot (w_i \cdot f)} + \frac{[W_0 \cdot W_2 \cdot (w_i \cdot f)]}{\left[ \frac{W_2}{kf} \cdot (w_i \cdot f) + 1 \right]^2} \right]}{1 + k \cdot \frac{e^{-\tau \cdot w_i \cdot f}}{[T \cdot (w_i \cdot f) + 1]^2} \cdot \left[ W_0 + \frac{W_0}{W_1 \cdot (w_i \cdot f)} + \frac{[W_0 \cdot W_2 \cdot (w_i \cdot f)]}{\left[ \frac{W_2}{kf} \cdot (w_i \cdot f) + 1 \right]^2} \right]}$$

    if  $A_i > \text{MAXA}$ 
         $\text{MAXA} \leftarrow A_i$ 
         $wr \leftarrow w_i$ 
     $fi \leftarrow \arg \frac{k \cdot \frac{e^{-\tau \cdot wr \cdot f}}{[T \cdot (wr \cdot f) + 1]^2} \cdot \left[ W_0 + \frac{W_0}{W_1 \cdot (wr \cdot f)} + \frac{W_0 \cdot W_2 \cdot (wr \cdot f)}{\left[ \frac{W_2}{kf} \cdot (wr \cdot f) + 1 \right]^2} \right]}{1 + k \cdot \frac{e^{-\tau \cdot wr \cdot f}}{[T \cdot (wr \cdot f) + 1]^2} \cdot \left[ W_0 + \frac{W_0}{W_1 \cdot (wr \cdot f)} + \frac{W_0 \cdot W_2 \cdot (wr \cdot f)}{\left[ \frac{W_2}{kf} \cdot (wr \cdot f) + 1 \right]^2} \right]}$ 
return  $10^5 \cdot \text{MAXA}$  if  $fi > 0$ 
 $I \leftarrow I + \text{shtraf} \cdot |\text{Mz} - \text{MAXA}|$  if  $\text{MAXA} > \text{Mz}$ 
return I

```

Ввод параметров алгоритма Optim-MGA

$n := 3$	количество искомых параметров
$\mu := 100$	количество особей в потомстве
$xn := \begin{pmatrix} 5 \\ 9 \\ 3 \end{pmatrix}$	начальная точка поискового диапазона
$xx := \begin{pmatrix} 6 \\ 11 \\ 4 \end{pmatrix}$	конечная точка поискового диапазона
$\varepsilon := 0.01$	точность искомого решения
$\omega := 0.001, 0.002 \dots \omega_{\text{end}}$	задание частотного диапазона
$t := 0, 1 \dots te$	задание временного диапазона

Функция обращения к алгоритму Optim-MGA для вычисления оптимальных настроечных параметров реального ПИД регулятора в составе одноконтурной АСР

$$\text{Settings} := \text{MGA}(n, \mu, xx, xn, \varepsilon, \text{PID_REAL_MOD}) \quad \text{Settings} = \begin{pmatrix} 5.454 \\ 10.235 \\ 3.75 \\ 2.098 \end{pmatrix}$$

Передаточные функции

$$Wol(\omega) := k \cdot \frac{e^{-\tau \cdot \omega \cdot f}}{[T \cdot (\omega \cdot f) + 1]^2} \quad \text{объекта регулирования}$$

$$Wp1(\omega) := \text{Settings}_0 + \frac{\text{Settings}_0}{\text{Settings}_1 \cdot \omega \cdot f} + \frac{\text{Settings}_0 \cdot \text{Settings}_2 \cdot (\omega \cdot f)}{\left[\frac{\text{Settings}_2}{kf} \cdot (\omega \cdot f) + 1 \right]^2} \quad \text{реального ПИД регулятора}$$

Преобразование Фурье для построения переходного процесса по каналам:

$$u1(t) := \frac{2}{\pi} \left(\int_0^{\omega_{\text{end}}} \frac{\sin(\omega \cdot t) \cdot \text{Re} \left(\frac{Wp1(\omega) \cdot Wol(\omega)}{1 + Wp1(\omega) \cdot Wol(\omega)} \right)}{\omega} d\omega \right) \quad \text{задания}$$


$$\lambda1(t) := \frac{2}{\pi} \cdot \left(\int_0^{\omega_{\text{end}}} \frac{\sin(\omega \cdot t) \cdot \text{Re} \left(\frac{Wol(\omega)}{1 + Wp1(\omega) \cdot Wol(\omega)} \right)}{\omega} d\omega \right) \quad \text{регулирующего органа}$$

$$\text{АЧХ замкнутого контура} \quad A1(\omega) := \left| \frac{Wp1(\omega) \cdot Wol(\omega)}{1 + Wp1(\omega) \cdot Wol(\omega)} \right|$$


Вычисление различных интегралов переходного процесса с настроечными параметрами, полученными в ходе проведения процедуры численной оптимизации

$$\text{Lin} := \sum_t (\lambda1(t)) = 1.876 \quad \text{Mod} := \sum_t (|\lambda1(t)|) = 2.115 \quad \text{Kv} := \sum_t [(\lambda1(t))^2] = 0.224$$

Переходные процессы по каналам задания и регулирующего органа:



Амплитудно-частотная характеристика замкнутого контура



Приложение Г. Реализация нейросети параметрической идентификации объекта регулирования с самовыравниванием

В скрытой области находится эволюционный алгоритм многопараметрической, многоэкстремальной оптимизации "Optim-MGA" в виде пользовательской версии для программного пакета MathCAD

► MGA

Чтение массивов данных полных факторных экспериментов с различными коэффициентами интервалов варьирования и объединение их в тренировочные множества для обучения нейросети:

постоянная времени

```
T1 := READPRN("experiment_1_T.txt")
T2 := READPRN("experiment_2_T.txt")
T3 := READPRN("experiment_3_T.txt")
T4 := READPRN("experiment_4_T.txt")
T5 := READPRN("experiment_5_T.txt")
T6 := READPRN("experiment_6_T.txt")
```

запаздывание

```
tau1 := READPRN("experiment_1_tau.txt")
tau2 := READPRN("experiment_2_tau.txt")
tau3 := READPRN("experiment_3_tau.txt")
tau4 := READPRN("experiment_4_tau.txt")
tau5 := READPRN("experiment_5_tau.txt")
tau6 := READPRN("experiment_6_tau.txt")
```

Ординаты реперных точек переходных процессов и соответствующих им импульсных переходных характеристик для определения:

постоянной времени

```
LT1 := READPRN("experiment_vib_T_1.txt")
LT2 := READPRN("experiment_vib_T_2.txt")
LT3 := READPRN("experiment_vib_T_3.txt")
LT4 := READPRN("experiment_vib_T_4.txt")
LT5 := READPRN("experiment_vib_T_5.txt")
LT6 := READPRN("experiment_vib_T_6.txt")
```

запаздывания

```
Ltau1 := READPRN("experiment_vib_tau_1.txt")
Ltau2 := READPRN("experiment_vib_tau_2.txt")
Ltau3 := READPRN("experiment_vib_tau_3.txt")
Ltau4 := READPRN("experiment_vib_tau_4.txt")
Ltau5 := READPRN("experiment_vib_tau_5.txt")
Ltau6 := READPRN("experiment_vib_tau_6.txt")
```

Объединение массивов данных в одну обучающую выборку:

Постоянной времени

```
T_obj2 := stack(T1,T2,T3)
```

Запаздывания

```
tau_obj2 := stack(tau1,tau2,tau3)
```

Ординат реперных точек для определения:

Постоянной времени

```
Lxx := augment(LT1,LT2,LT3)
```

Запаздывания

```
Lxx_tau := augment(Ltau1,Ltau2,Ltau3)
```

Нормирование данных для подачи на входы нейросети:

```

L :=
  for j ∈ 0..cols(Lxx) - 1
    for i ∈ 0..rows(Lxx) - 1
      
$$M_{i,j} \leftarrow \frac{-Lxx_{i,j} + \max(Lxx^{(j)})}{\min(Lxx^{(j)}) - \max(Lxx^{(j)})} + 1$$

    return M

```

```

L_tau :=
  for j ∈ 0..cols(Lxx_tau) - 1
    for i ∈ 0..rows(Lxx_tau) - 1
      
$$M_{i,j} \leftarrow \frac{-Lxx\_tau_{i,j} + \max(Lxx\_tau^{(j)})}{\min(Lxx\_tau^{(j)}) - \max(Lxx\_tau^{(j)})} + 1$$

    return M

```

$T_obj := T_obj2^T$

$tau_obj := tau_obj2^T$

```

L_norm_T :=
  for j ∈ 0..cols(T_obj) - 1
    
$$M_j \leftarrow \frac{-T\_obj_{0,j} + \max(T\_obj)}{\min(T\_obj) - \max(T\_obj)} + 1$$

  return M

```

```

L_norm_tau :=
  for j ∈ 0..cols(tau_obj) - 1
    
$$M_j \leftarrow \frac{-tau\_obj_{0,j} + \max(tau\_obj)}{\min(tau\_obj) - \max(tau\_obj)} + 1$$

  return M

```

Количество строк в обучающей выборке для определения

постоянной времени

$$N_{str} := \text{rows}(L) - 1 = 6$$

запаздывания

$$N_{tau_str} := \text{rows}(L_tau) - 1 = 9$$

Суммарное количество выборок (все столбцы)

постоянной времени

$$N_{vib} := \text{cols}(L) - 1 = 53$$

запаздывания

$$N2_{vib} := \frac{\text{cols}(L)}{2} - 1 = 26$$

Количество строк в искомом параметре

$$N_X := \text{rows}(L_norm_T) - 1 = 26$$

Нейронные сети для выявления функциональных зависимостей "ординаты реперных точек переходных процессов и импульсных переходных характеристик" - "параметр объекта регулирования"

нейросеть для воспроизведения
постоянной времени

```
Fit(W) :=
  F ← 0
  T0 ← 0
  count ← 0
  countT ← 0
  for k ∈ 0, 2..Nvib
    Y ← L(k)
    dY ← L(k+1)
    count ← 0
    for i ∈ 0..Nstr
      Si ← Yi · Wcount + dYi · Wcount+1
      count ← count + 2
    R ← 0
    for j ∈ 0..Nstr
      R ← R + Sj · Wcount
      count ← count + 1
    TcountT ← R
    countT ← countT + 1
  for d ∈ 0..NX
    F ← F + (Td - Lnorm_Td,0)2
  return F
```

нейросеть для воспроизведения
запаздывания

```
Fit_tau(W) :=
  F ← 0
  T0 ← 0
  count ← 0
  countT ← 0
  for k ∈ 0, 2..Nvib
    Y ← Ltau(k)
    dY ← Ltau(k+1)
    count ← 0
    for i ∈ 0..Ntaustr
      Si ← Yi · Wcount + dYi · Wcount+1
      count ← count + 2
    R ← 0
    for j ∈ 0..Ntaustr
      R ← R + Sj · Wcount
      count ← count + 1
    TcountT ← R
    countT ← countT + 1
  for d ∈ 0..NX
    F ← F + (Td - Lnorm_tau_d,0)2
  return F
```

Ввод параметров алгоритма "Optim-MGA"

Количество искомых параметров:

nn := 30	для определения постоянной времени
nn := 21 [■]	для определения запаздывания
j := 0..nn	
μ := 200	количество особей в потомстве
ε := 0.001	точность искомого решения
xx _j := 10	конечная точка искомого диапазона
xx _j := -xx _j	начальная точка поискового диапазона

Функция обращения к алгоритму "Optim-MGA" для вычисления оптимальных синаптических весов нейросети:

$F := \text{MGA}(nn, \mu, xx, xn, \varepsilon, \text{Fit})$

$F_tau := \text{MGA}(nn, \mu, xx, xn, \varepsilon, \text{Fit_tau})$

Синаптические веса активационных функций нейронов:

$F_tau =$

	0
0	0.244
1	-0.838
2	1.677
3	2.008
4	2.228
5	-2.44
6	-0.688
7	-1.583
8	-0.346
9	0.793
10	-0.072
11	-0.792
12	0.222
13	-1.397
14	-0.499
15	-0.032
16	-0.454
17	1.368
18	1.226
19	1.248
20	-1.295
21	$4.773 \cdot 10^{-5}$

$F =$

	0
0	0.645
1	1.484
2	-3.85
3	1.711
4	-0.531
5	-2.476
6	3.31
7	-0.984
8	1.161
9	1.007
10	-0.605
11	-2.69
12	-0.965
13	-2.648
14	4.299
15	-1.984
16	0.107
17	1.149
18	-0.258
19	2.015
20	-1.455
21	0.031
22	-2.484
23	1.747
24	0.596
25	1.429
26	-1.038
27	-1.356
28	-0.434
29	-1.535
30	-0.14
31	0.078
32	-0.493
33	$9.13 \cdot 10^{-4}$

Программа для воспроизведения всех значений тренировочного множества и сравнения полученных результатов с эталонными значениями (для постоянной времени)

```

X(W) :=
  F ← 0
  T0 ← 0
  count ← 0
  countT ← 0
  maxT ← max(T_obj)
  minT ← min(T_obj)
  for k ∈ 0..Nvib
    Y ← L(k)
    dY ← L(k+1)
    count ← 0
    for i ∈ 0..Nstr
      Si ← Yi · Wcount + dYi · Wcount+1
      count ← count + 2
    R ← 0
    for j ∈ 0..Nstr
      R ← R + Sj · Wcount
      count ← count + 1
    TcountT ← R
    countT ← countT + 1
  Result ← (minT - maxT) · (-T + 1) + maxT
Result

```

Вывод результатов обучения нейросети и их сравнения со значениями обучающей выборки:

X(F) =

	0
0	116.061
1	127.338
2	127.235
3	104.244
4	104.183
5	127.327
6	127.282
7	104.157
8	104.238
9	115.942
10	127.572
11	127.11
12	104.038
13	104.2
14	127.627
15	...

T_{obj}^T =

	0
0	115.8
1	127.4
2	127.4
3	104.3
4	104.3
5	127.4
6	127.4
7	104.3
8	104.3
9	115.8
10	127.4
11	127.4
12	104.3
13	104.3
14	127.4
15	...

Программа для воспроизведения всех значений тренировочного множества и сравнения полученных результатов с эталонными значениями (для запаздывания)

```

X_tau(W) :=
  F ← 0
  T_0 ← 0
  count ← 0
  countT ← 0
  maxT ← max(tau_obj)
  minT ← min(tau_obj)
  for k ∈ 0, 2 .. N_vib
    Y ← L_tau^{(k)}
    dY ← L_tau^{(k+1)}
    count ← 0
    for i ∈ 0 .. N_tau_str
      S_i ← Y_i · W_count + dY_i · W_count+1
      count ← count + 2
    R ← 0
    for j ∈ 0 .. N_tau_str
      R ← R + S_j · W_count
      count ← count + 1
    T_countT ← R
    countT ← countT + 1
  Result ← (minT - maxT) · (-T + 1) + maxT
Result

```

Вывод результатов обучения нейросети и их сравнения со значениями обучающей выборки:

X_tau(F_tau) =		0	tau_obj ^T =		0
	0	1.603		0	1.6
	1	1.762		1	1.76
	2	1.451		2	1.44
	3	1.752		3	1.76
	4	1.438		4	1.44
	5	1.763		5	1.76
	6	1.451		6	1.44
	7	1.751		7	1.76
	8	1.438		8	1.44
	9	3.337·10 ⁻³		9	0
	10	4.004		10	4
	11	9.135·10 ⁻³		11	0
	12	4		12	4
	13	-7.368·10 ⁻³		13	0
	14	4.004		14	4
	15	...		15	...

Приложение Д. Реализация адаптивной нейросети для аппроксимации функциональной зависимости «параметры объекта регулирования, частотный показатель колебательности» - «пропорциональная составляющая регулятора»

В скрытой области находится эволюционный алгоритм многопараметрической, многоэкстремальной оптимизации "Optim-MGA" в виде пользовательской версии для программного пакета MathCAD

► MGA

Переменные для нормирования обучающей выборки в диапазоне входов применяемых активационных функций нейронов

$MIN_{NN} := 0$ минимальное значение диапазона

$MAX_{NN} := 1$ максимальное значение диапазона

Чтение массива данных полных факторных экспериментов с различными коэффициентами интервалов варьирования:

$L1 := READPRN("1.55.txt")$ $L3 := READPRN("1.3.txt")$

$L2 := READPRN("1.55_2.txt")$ $L4 := READPRN("1.3_2.txt")$

Объединение массивов данных в одну обучающую выборку:

$Lxx := stack(L1, L2, L3, L4)$

	0	1	2	3	4	5
0	1.17	104.3	1.44	1.55	3.484	169.9
1	1.43	104.3	1.44	1.55	2.861	170.4
2	1.17	127.4	1.44	1.55	3.58	210
3	1.43	127.4	1.44	1.55	2.931	210.1
4	1.17	127.4	1.76	1.55	3.579	213
5	1.43	127.4	1.76	1.55	2.926	212.8
6	1.17	104.3	1.76	1.55	3.489	173
7	1.43	104.3	1.76	1.55	2.851	172.7
8	1.17	104.3	0	1.55	3.922	177.5
9	1.43	104.3	0	1.55	3.193	176.4
10	1.17	104.3	4	1.55	3.094	169.8
11	1.43	104.3	4	1.55	2.528	169.6
12	1.17	127.4	4	1.55	3.111	201.4
13	1.43	127.4	4	1.55	2.545	201.4
14	1.17	127.4	0	1.55	4.091	226.8
15	1.43	127.4	0	1.55	3.318	...

$Lxx =$

$rows(Lxx) = 32$

$cols(Lxx) = 6$

Нормирование обучающей выборки по столбцам:

```

L :=
  for j ∈ 0..cols(Lxx) - 1
    for i ∈ 0..rows(Lxx) - 1
      
$$M_{i,j} \leftarrow \frac{(\text{MIN}_{\text{NN}} - \text{MAX}_{\text{NN}}) \cdot (L_{xx}_{i,j} - \max(L_{xx}^{(j)}))}{(\min(L_{xx}^{(j)}) - \max(L_{xx}^{(j)}))} + \text{MAX}_{\text{NN}}$$

    return M

```

L =

	0	1	2	3	4
0	0	0	0.36	1	0.723
1	1	0	0.36	1	0.439
2	0	1	0.36	1	0.767
3	1	1	0.36	1	0.471
4	0	1	0.44	1	0.767
5	1	1	0.44	1	0.469
6	0	0	0.44	1	0.725
7	1	0	0.44	1	0.435
8	0	0	0	1	0.923
9	1	0	0	1	0.591
10	0	0	1	1	0.545
11	1	0	1	1	0.287
12	0	1	1	1	...

Ввод параметров алгоритмов "Optim-MGA"

$nn := 20$	количество искомым параметров
$j := 0..20$	
$\mu := 300$	количество особей в потомстве
$\varepsilon := 0.01$	точность искомого решения
$xx_j := -10$	начальная точка поискового диапазона
$xx_j := 10$	конечная точка искомого диапазона

Нейронная сеть для выявления функциональной зависимости "параметры объекта регулирования, частотный показатель колебательности" - "Пропорциональная составляющая регулятора K_p "

```

Fit_Kp(W) :=
  S ← 0
  num ← 4
  MIN ← min(Lxx(num))
  MAX ← max(Lxx(num))
  RAZN ← (MIN - MAX)
  for i ∈ 0..rows(L) - 1
    S1 ← Li,0·W0 + Li,1·W1 + Li,2·W2 + Li,3·W3
    S2 ← Li,0·W4 + Li,1·W5 + Li,2·W6 + Li,3·W7
    S3 ← Li,0·W8 + Li,1·W9 + Li,2·W10 + Li,3·W11
    S4 ← Li,0·W12 + Li,1·W13 + Li,2·W14 + Li,3·W15
    f1 ←  $\frac{1}{1 + e^{-S_1}}$ 
    f2 ←  $\frac{1}{1 + e^{-S_2}}$ 
    f3 ←  $\frac{1}{1 + e^{-S_3}}$ 
    f4 ←  $\frac{1}{1 + e^{-S_4}}$ 
    S5 ← f1·W16 + f2·W17 + f3·W18 + f4·W19
    f5 ←  $\frac{1}{1 + e^{-S_5}}$ 
    x ← MAX - RAZN·(f5 - 1)
    S ← S + (x - Lxxi,num)2
  return S

```

Функция обращения к алгоритму "Optim-MGA" для вычисления оптимальных синаптических весов нейросети:

Settings_Kp := MGA(nn, μ , xx, xn, ε , Fit_Kp) ■

Синаптические веса активационных функций нейронов:

	0
0	1.909
1	0.167
2	-2.237
3	-0.373
4	-1.149
5	0.469
6	2.346
7	-6.683
8	7.916
Settings_Kp = 9	0.664
10	-2.964
11	-5.44
12	1.609
13	-0.703
14	1.297
15	-3.411
16	5.411
17	0.748
18	-3.976
19	-3.053
20	0.194

Программа для воспроизведения всех значений тренировочного множества и сравнения полученных результатов с эталонными значениями.

```

PI_Kp(W) :=
  num ← 4
  for j ∈ 0..cols(L) - 1
    for i ∈ 0..rows(L) - 1
      Si,0 ← Li,0·W0 + Li,1·W1 + Li,2·W2 + Li,3·W3
      Si,1 ← Li,0·W4 + Li,1·W5 + Li,2·W6 + Li,3·W7
      Si,2 ← Li,0·W8 + Li,1·W9 + Li,2·W10 + Li,3·W11
      Si,3 ← Li,0·W12 + Li,1·W13 + Li,2·W14 + Li,3·W15
      Si,4 ←  $\frac{1}{1 + e^{-S_{i,0}}}$ 
      Si,5 ←  $\frac{1}{1 + e^{-S_{i,1}}}$ 
      Si,6 ←  $\frac{1}{1 + e^{-S_{i,2}}}$ 
      Si,7 ←  $\frac{1}{1 + e^{-S_{i,3}}}$ 
      Si,8 ← Si,4·W16 + Si,5·W17 + Si,6·W18 + Si,7·W19
      Si,9 ←  $\frac{1}{1 + e^{-S_{i,8}}}$ 
      xi,0 ← (min(Lxx<num>) - max(Lxx<num>)) · (-Si,9 + MAXNN) + max(Lxx<num>)
      xi,1 ← Lxxi,num
      xi,2 ←  $\frac{|x_{i,0} - x_{i,1}|}{x_{i,1}} \cdot 100$ 
  x

```

Значение среднемодульной величины отклонения параметра Kp, воспроизводимого нейросетью от эталонных параметров в обучающей выборке.

$$\text{mean}(\text{PI_Kp}(\text{Settings_Kp})^{(2)}) = 2.234$$

+

Вывод результатов обучения нейросети и их сравнения со значениями обучающей выборки:

	0	1	2	
0	3.55	3.484	1.903	
1	2.897	2.861	1.259	
2	3.642	3.58	1.739	
3	2.974	2.931	1.454	
4	3.572	3.579	0.194	
5	2.899	2.926	0.936	
6	3.474	3.489	0.44	
7	2.836	2.851	0.526	
8	3.85	3.922	1.83	
9	3.186	3.193	0.218	
10	3.022	3.094	2.322	
11	2.548	2.528	0.799	
12	3.144	3.111	1.054	
13	2.55	2.545	0.197	
14	3.9	4.091	4.68	
PI_Kp(Settings_Kp) =	15	3.282	3.318	1.096
	16	2.589	2.64	1.921
	17	2.066	2.169	4.732
	18	2.626	2.657	1.174
	19	2.097	2.169	3.311
	20	2.736	2.89	5.322
	21	2.215	2.37	6.56
	22	2.711	2.53	7.158
	23	2.167	2.07	4.678
	24	2.336	2.317	0.819
	25	1.937	1.898	2.073
	26	2.76	2.697	2.325
	27	2.258	2.207	2.332
	28	2.861	2.933	2.456
	29	2.45	2.398	2.159
	30	2.48	2.482	0.066
	31	1.957	2.033	3.753

Приложение Е. Реализация ИНС идентификации и адаптации в ПЛК ПТК АСУ ТП на примере адаптивной АСР температуры электропечи

Е1. Функциональный блок реализации ИНС параметрической идентификации

Программная реализация нейросети, производящей параметрическую идентификацию постоянной времени и запаздывания объекта регулирования (с передаточной функцией (2.7), представлена ниже:

FUNCTION_BLOCK Identification

VAR_INPUT

PV: REAL; (*Переменная процесса*)

UP : REAL; (*Указатель положения регулирующего органа*)

EXPERIMENT: BOOL; (*Инициализация начала проведения активного эксперимента*)

RES : BOOL; (*Сброс всех параметров функционального блока*)

T_count : INT := 400; (*Интервал записи реперных точек для определения постоянной времени в массив*)

tau_count : INT := 10; (*Интервал записи реперных точек для определения запаздывания в массив*)

END_VAR

VAR_OUTPUT

Kobj : REAL; (*Коэффициент усиления объекта регулирования*)

Tobj: REAL; (*Постоянная времени объекта регулирования*)

tau: REAL; (*Запаздывание объекта регулирования*)

POS: BOOL; (*Изменения положения регулирующего органа*)

Status: BOOL; (*Проверка полученных параметров на достоверность*)

END_VAR

VAR

lLastTime:TIME := T#0ms;

lCurTime :TIME;

uiDerCycle : UINT;

Azveno : A_zv;

Differ : Diff;

START: BOOL; (*Накладка, применяется для инициализации начальных значений PV и UP*)

dUP : REAL; (*Разница начального значения УП и текущего*)

PV0: REAL; (*Начальное значение PV (переменная процесса) при начале эксперимента*)

UP0: REAL; (*Начальное значение UP (указатель положения) при начале эксперимента*)

RealStart: BOOL; (*Начало движения исполнительного механизма*)

VARIABLE : REAL; (*Переменная переходного процесса*)

DERIV : DERIVATIVE; (*Функциональный блок дифференцирования*)

OUT_DERIV : REAL; (*Выход функционального блока производной*)

DIF_PV : REAL; (*Производная от переменной переходного процесса с условием*)

COUNTER_T: INT; (*Счетчик для записи переменных в массив ArrT*)

COUNTER_Tau: INT; (*Счетчик для записи переменных в массив ArrTau*)

Z: INT; (*Счетчик записи данных в массив ArrT*)

J: INT; (*Счетчик записи данных в массив ArrTau*)

K: INT; (*Индекс массива ArrT*)

N: INT; (*Индекс массива ArrTau*)

I: INT; (*Переменная для циклов FOR*)

minK : REAL := 1.17; (*Минимальное значение Kobj для проверки достоверности идентифицируемого значения*)

maxK : REAL := 1.43; (*Максимальное значение Kobj для проверки достоверности идентифицируемого значения*)

minT : REAL := 104.3; (*Минимальное значение Tobj для нормирования и проверки достоверности идентифицируемого значения*)

maxT : REAL := 127.4; (*Максимальное значение Tobj для нормирования и проверки достоверности идентифицируемого значения*)

minTau: REAL := 0.0; (*Минимальное значение Tau для нормирования и проверки достоверности идентифицируемого значения*)

maxTau: REAL := 4.0; (*Максимальное значение Tau для нормирования и проверки достоверности идентифицируемого значения*)

ArrT: ARRAY [0..23] OF REAL := 0; (*Массив для записи ординат реперных точек для определения постоянной времени объекта регулирования*)

ArrTNorm: ARRAY [0..23] OF REAL := 0; (*Массив для записи нормированных ординат реперных точек для определения постоянной времени объекта регулирования*)

SumT : ARRAY [0..11] OF REAL := 0; (*Массив синаптических значений функций нейронов для определения постоянной времени*)

WT : ARRAY [0..32] OF REAL := 0.645, 1.484, -3.85, 1.711, -0.531, -2.476, 3.31, -0.984, 1.161, 1.007, -0.605, -2.69, -0.965, -2.648, 4.299, -1.984, 0.107, 1.149, -0.258, 2.015, -1.455, 0.031, -2.484, 1.747, 0.596, 1.429, -1.038, -1.356, -0.434, -1.535, -0.14, 0.078, -0.493; (*Коэффициенты нейросети для определения T*)

Nakladka_T: BOOL; (*Накладка для выхода из условия записи значений в массив*)

Stop_T: INT; (*Счетчик останова записи значений в массив*)

maxX: REAL; (*Максимальное значение Tobj из массива*)

```

minX: REAL; (*Минимиальное значение Tobj из массива*)
maxDX: REAL; (*Максимальное значение производной Tobj из массива*)
minDX: REAL; (*Минимиальное значение производной Tobj из массива*)
ArrTau : ARRAY [0..15] OF REAL := 0; (*Массив для записи значений
переменной*)
ArrTauNorm : ARRAY [0..15] OF REAL := 0; (*Массив нормированных
данных ArrTau*)
SumTau : ARRAY [0..7] OF REAL := 0; (*Синаптические веса*)
Wtau : ARRAY [0..20] OF REAL := 0.244, -0.838, 1.677, 2.008, 2.228, -2.44,
-0.688, -1.583, -0.346, .793, -0.072, -0.792, 0.222, -1.397, -0.499, -0.032, -0.454,
1.368, 1.226, 1.248, -1.295; (*Коэффициенты нейросети для определения Tau*)
maxY: REAL; (*Максимальное значение Tau из массива*)
minY: REAL; (*Минимиальное значение Tau из массива*)
maxDY: REAL; (*Максимальное значение производной Tau из массива*)
minDY: REAL; (*Минимиальное значение производной Tau из массива*)
Nakladka_Tau: BOOL; (*Накладка для выхода из условия записи значений
в массив*)
Stop_Tau: INT; (*Счетчик останова записи значений в массив*)
MinMax: REAL;
MinMaxD : REAL;
LastVal: REAL;
Dif1000: REAL;
DIF_PV_1: REAL;
END_VAR
(*Счетчики для записи реперных точек через равные промежутки времени в
соответствующие массивы*)
COUNTER_T := T_count - 1;
COUNTER_Tau := tau_count - 1;
IF EXPERIMENT THEN
    (*Запись начальных значений указателя положения регулирующего
органа и переменной процесса регулирования*)
    IF NOT START THEN
        PV0 :=PV;
        UP0 := UP;
        START := TRUE;
        POS := TRUE;
    END_IF
    (*Перемещение регулирующего органа*)
    dUP := UP - UP0;
    IF dUP < 0.2 THEN
        VARIABLE := 0;
        RealStart := FALSE;
    ELSE
        VARIABLE := ABS((PV - PV0)/dUP); (*Получение приведенной
переходной характеристики*)

```

```

        RealStart := TRUE;
    END_IF
    IF (UP - UP0) >= 10 THEN
        POS := FALSE;
    END_IF
    (*Определение коэффициента училения объекта регулирования*)
    Kobj := VARIABLE;
    IF Variable > LastVal AND LastVal <> 0 THEN
        (*2. Cycle time calculation*)
        lCurTime := TIME();
        IF lLastTime <> T#0ms THEN
            uiDerCycle := TIME_TO_UINT(lCurTime - lLastTime);
            IF uiDerCycle <= 0 THEN uiDerCycle := 100; END_IF;
        END_IF
        lLastTime := lCurTime;
        DERIV(IN:= VARIABLE, TM:= uiDerCycle, RESET:= RES,
OUT=>DIF_PV_1); (*Вычисление производной*)
    END_IF
    Azveno(x:= Dif_PV_1, k := 1, T := 2, iDt := CycleTime, y => DIF_PV );
    LastVal := VARIABLE;
    Dif1000 := DIF_PV * 1000.0;
    IF Nakladka_T = 0 AND RealStart THEN
        ArrT[K]:=VARIABLE;
        ArrT[K+1]:=DIF_PV;
        Z:=Z-1;
        IF Z <= 0 THEN
            Stop_T := Stop_T+1;
            IF Stop_T > 10 THEN (*Число X - количество
строк в обучающей выборке Nstr в файле MathCAD*)
                Nakladka_T :=1;
            ELSE
                Nakladka_T :=0;
            END_IF
            Z:=COUNTER_T;
            IF ArrT[22] = 0 THEN (*Определение останова
записи данных в массив и начало записи данных в одни и те же области
массива*)
                K:=K+2;
            END_IF
        END_IF
    ELSE
        Z:=0;
    END_IF
    IF Nakladka_Tau = 0 AND RealStart THEN
        ArrTau[N]:=VARIABLE;

```



```

ArrTau[N+1]:=DIF_PV;
J := J-1;
  IF J <= 0 THEN
    Stop_Tau := Stop_Tau+1;
    IF Stop_Tau > 6 THEN (*Число X - число строк в
обучающей выборке N_tau.str в файле MathCAD*)
      Nakladka_Tau :=1;
    ELSE
      Nakladka_Tau :=0;
    END_IF
    J:=COUNTER_Tau;
    IF ArrTau[14] = 0 THEN
      N:=N+2;
    END_IF
  END_IF
ELSE
  J:=0;
END_IF
IF Nakladka_T = 0 AND RealStart THEN
(*Вычисление максимального и минимального значений входной переменной*)
  maxX := -10.0E+10;
  minX := 10.0E+10;
  maxDX := -10.0E+10;
  minDX := 10.0E+10;
(*Вычисление максимального и минимального значений входной переменной*)
  FOR I := 0 TO 20 BY 2 DO
    IF ArrT[I] > maxX THEN
      maxX := ArrT[I];
    END_IF;
    IF ArrT[I] < minX THEN
      minX := ArrT[I];
    END_IF
  END_FOR
(*Вычисление максимального и минимального значений производной входной
переменной*)
  FOR I := 1 TO 21 BY 2 DO
    IF ArrT[I] > maxDX THEN
      maxDX := ArrT[I];
    END_IF;
    IF ArrT[I] < minDX THEN
      minDX := ArrT[I];
    END_IF
  END_FOR
(*Нормирование значений в массиве*)
  IF maxX <> minX THEN

```

```

        FOR I := 0 TO 20 BY 2 DO
            ArrTNorm[I] := 1 + (-ArrT[I] + maxX) / (minX - maxX);
        END_FOR
    END_IF;

    IF maxDX <> minDX THEN
        FOR I := 1 TO 21 BY 2 DO
            ArrTNorm[I] := 1 + (-ArrT[I] + maxDX) / (minDX - maxDX);
        END_FOR
    END_IF;

    (*Вычисление синаптических значений функций нейронов для определения
    постоянной времени*)
    SumT[0] := ArrTNorm[0]*WT[0]+ArrTNorm[1]*WT[1];
    SumT[1] := ArrTNorm[2]*WT[2]+ArrTNorm[3]*WT[3];
    SumT[2] := ArrTNorm[4]*WT[4]+ArrTNorm[5]*WT[5];
    SumT[3] := ArrTNorm[6]*WT[6]+ArrTNorm[7]*WT[7];
    SumT[4] := ArrTNorm[8]*WT[8]+ArrTNorm[9]*WT[9];
    SumT[5] := ArrTNorm[10]*WT[10]+ArrTNorm[11]*WT[11];
    SumT[6] := ArrTNorm[12]*WT[12]+ArrTNorm[13]*WT[13];
    SumT[7] := ArrTNorm[14]*WT[14]+ArrTNorm[15]*WT[15];
    SumT[8] := ArrTNorm[16]*WT[16]+ArrTNorm[17]*WT[17];
    SumT[9] := ArrTNorm[18]*WT[18]+ArrTNorm[19]*WT[19];
    SumT[10] := ArrTNorm[20]*WT[20]+ArrTNorm[21]*WT[21];
    SumT[11]:=      SumT[0] * WT[22] + SumT[1] * WT[23] + SumT[2] * WT[24] +
    SumT[3] * WT[25] + SumT[4] * WT[26] + SumT[5] * WT[27] + SumT[6] *
    WT[28] + SumT[7] * WT[29] + SumT[8] * WT[30] + SumT[9] * WT[31] +
    SumT[10] * WT[32];
    (*Вычисление постоянной времени объекта регулирования*)
    Tobj := (minT - maxT) * (-SumT[11] + 1) + maxT;
    END_IF
    IF Nakladka_Tau = 0 AND RealStart THEN
        maxY := -10.0E+10;
        minY := 10.0E+10;
        maxDY := -10.0E+10;
        minDY := 10.0E+10;
    (*Вычисление максимального и минимального значений входной переменной
    для запаздывания*)
        FOR I := 2 TO 12 BY 2 DO
            IF ArrTau[I] > maxY THEN
                maxY := ArrTau[I];
            END_IF;
            IF ArrTau[I] < minY THEN
                minY := ArrTau[I];
            END_IF
        END_FOR
    
```

(*Вычисление максимального и минимального значений производной входной переменной для запаздывания*)

```
FOR I := 3 TO 13 BY 2 DO
    IF ArrTau[I] > maxDY THEN
        maxDY := ArrTau[I];
    END_IF
    IF ArrTau[I] < minDY THEN
        minDY := ArrTau[I];
    END_IF
END_FOR
```

(*Нормирование значений в массиве для определения запаздывания*)

```
IF minY <> maxY THEN
    FOR I := 2 TO 12 BY 2 DO
        ArrTauNorm[I] := 1 + (-ArrTau[I] + maxY) / (minY-maxY);
    END_FOR
END_IF
IF minDY <> maxDY THEN
    FOR I := 3 TO 13 BY 2 DO
        ArrTauNorm[I] := 1 + (-ArrTau[I] + maxDY) / (minDY-maxDY);
    END_FOR
END_IF;
```

(*Вычисление синаптических значений функций нейронов для определения запаздывания*)

```
SumTau[0] := ArrTauNorm[0]*Wtau[0]+ArrTauNorm[1]*Wtau[1];
SumTau[1] := ArrTauNorm[2]*Wtau[2]+ArrTauNorm[3]*Wtau[3];
SumTau[2] := ArrTauNorm[4]*Wtau[4]+ArrTauNorm[5]*Wtau[5];
SumTau[3] := ArrTauNorm[6]*Wtau[6]+ArrTauNorm[7]*Wtau[7];
SumTau[4] := ArrTauNorm[8]*Wtau[8]+ArrTauNorm[9]*Wtau[9];
SumTau[5] := ArrTauNorm[10]*Wtau[10]+ArrTauNorm[11]*Wtau[11];
SumTau[6] := ArrTauNorm[12]*Wtau[12]+ArrTauNorm[13]*Wtau[13];
SumTau[7]:= SumTau[0] * Wtau[14] + SumTau[1] * Wtau[15] + SumTau[2] *
Wtau[16] + SumTau[3] * Wtau[17] + SumTau[4] * Wtau[18] + SumTau[5] *
Wtau[19] + SumTau[6] * Wtau[20];
```

(*Вычисление времени запаздывания объекта регулирования*)

```
Tau := (minTau - maxTau) * (-SumTau[7] + 1) + maxTau;
END_IF
```

END_IF (*Завершение самого первого условия*)

(*Проверка идентифицированных параметров на достоверность*)

```
IF (Tobj < maxT AND Tobj > minT) AND (tau < maxTau AND tau > minTau) AND
(Kobj < maxK AND Kobj > minK) THEN
```

```
    Status := TRUE;
```

```
ELSE
```

```
    Status := FALSE;
```

```
END_IF
```

(*Сброс значений переменных функционального блока, обнуление массивов данных*)

```
IF RES THEN
    FOR I := 0 TO 11 DO
        SumT[I] := 0;
    END_FOR
    FOR I := 0 TO 23 DO
        ArrT[I] := 0;
    END_FOR
    FOR I := 0 TO 23 DO
        ArrTNorm[I] := 0;
    END_FOR
    FOR I := 0 TO 14 DO
        ArrTau[I] := 0;
    END_FOR
    FOR I := 0 TO 14 DO
        ArrTauNorm[I] := 0;
    END_FOR
    FOR I := 0 TO 7 DO
        SumTau[I] := 0;
    END_FOR
    Nakladka_T := 0; VARIABLE := 0; Stop_T := 0; Nakladka_Tau := FALSE;
    Stop_Tau := 0; maxX := 0; minX := 0; maxDX := 0; minDX := 0; maxY := 0; minY := 0;
    maxDY := 0; minDY := 0; Z := 0; K := 0; J := 0; N := 0; I := 0; PV := 0; UP := 0;
    POS := FALSE; START := 0;
END_IF
```

Е2. Функциональный блок адаптивной ИНС, воспроизводящей оптимальные параметры ПИ регулятора с возможностью изменения частотного показателя колебательности

```
FUNCTION_BLOCK Adaptation_PI
VAR_INPUT (*Параметры, поступающие от нейросети идентификации*)
    Object_K : REAL;
    Object_T : REAL;
    Object_tau : REAL;
    M_zad : REAL;
END_VAR
VAR
    K : REAL;
    T : REAL;
    tau : REAL; ; (*Нормированные значения параметров объекта регулирования*)
```

```

M : REAL; (*Нормированное значение частотного показателя запаса
устойчивости*)
K_min : REAL := 1.17;
K_max : REAL := 1.43;
T_min : REAL := 104.3;
T_max : REAL := 127.4;
tau_min : REAL := 0;
tau_max : REAL := 4;
M_min : REAL := 1.3;
M_max : REAL := 1.55;
Kp_min : REAL := 1.898;
Kp_max : REAL := 4.091;
Tu_min : REAL := 169.6;
Tu_max : REAL := 247.1;
(*Массивы данных для вычисления Kp*)
E : ARRAY [0..9] OF REAL;
n : ARRAY [0..19] OF REAL := 1.909, 0.167, -2.237, -0.373, -1.149, 0.469,
2.346, -6.683, 7.916, 0.664, -2.964, -5.44, 1.609, -0.703, 1.297, -3.411, 5.411, 0.748,
-3.976, -3.053;
(*Массивы данных для вычисления Tu*)
F : ARRAY [0..9] OF REAL;
z : ARRAY [0..19] OF REAL := 0.12, 4.252, -1.212, -2.16, -0.207, -5.038, -
8.486, -3.17, 0.687, -3.084, -4.031, 5.336, 0.122, 0.335, 3.501, 0.368, 4.404, -4.718, -
0.651, -3.436;
END_VAR
VAR_OUTPUT
Kp : REAL; (*Пропорциональная часть регулятора*)
Tu : REAL; (*Интегральная составляющая регулятора*)
END_VAR
K := 1.0 - (Object_K - K_max) / (K_min - K_max); (*Коэффициент усиления*)
T := 1.0 - (Object_T - T_max) / (T_min - T_max); (*Постоянная времени*)
tau := 1.0 - (Object_tau - tau_max) / (tau_min - tau_max); (*Запаздывание*)
M := 1.0 - (M_zad - M_max) / (M_min - M_max); (*Частотный показатель запаса
устойчивости*)
(*Реализация нейросети для пропорциональной части регулятора*)
E[0] := K * n[0] + T * n[1] + tau * n[2] + M * n[3];
E[1] := K * n[4] + T * n[5] + tau * n[6] + M * n[7];
E[2] := K * n[8] + T * n[9] + tau * n[10] + M * n[11];
E[3] := K * n[12] + T * n[13] + tau * n[14] + M * n[15];
E[4] := 1.0 / (1.0 + EXP(-E[0]));
E[5] := 1.0 / (1.0 + EXP(-E[1]));
E[6] := 1.0 / (1.0 + EXP(-E[2]));
E[7] := 1.0 / (1.0 + EXP(-E[3]));
E[8] := E[4] * n[16] + E[5] * n[17] + E[6] * n[18] + E[7] * n[19];
E[9] := 1.0 / (1.0 + EXP(-E[8]));

```

```

(*Приведение результата к обычному виду*)
Kp := Kp_max - (Kp_min - Kp_max) * (E[9] - 1.0);
(*Реализация нейросети для интегральной составляющей*)
F[0] := K * z[0] + T * z[1] + tau * z[2] + M * z[3];
F[1] := K * z[4] + T * z[5] + tau * z[6] + M * z[7];
F[2] := K * z[8] + T * z[9] + tau * z[10] + M * z[11];
F[3] := K * z[12] + T * z[13] + tau * z[14] + M * z[15];
F[4] := 1.0 / (1.0 + EXP(-F[0]));
F[5] := 1.0 / (1.0 + EXP(-F[1]));
F[6] := 1.0 / (1.0 + EXP(-F[2]));
F[7] := 1.0 / (1.0 + EXP(-F[3]));
F[8] := F[4] * z[16] + F[5] * z[17] + F[6] * z[18] + F[7] * z[19];
F[9] := 1.0 / (1.0 + EXP(-F[8]));
(*Приведение результата к обычному виду*)
Tu := Tu_max - (Tu_min - Tu_max) * (F[9] - 1.0);

```